# 6-4 万维网

- 一、万维网概述
  - 1. 基本概念
    - 万维网（World Wide Web，WWW）是一个分布式、联机式的信息存储空间。
    - 万维网上的资源通过统一资源定位符 URL 标识。
    - 资源通过超文本传输协议 HTTP 传送给用户。
    - 用户通过浏览器单击超链接获取资源。
  - 2. 万维网的构成标准
    - （1）统一资源定位符 URL
      - 负责标识万维网上的各种文档和资源。
      - 使每个文档在整个万维网范围内具有唯一标识符。
    - （2）超文本传输协议 HTTP
      - HTTP 是应用层协议。
      - 使用 TCP 作为传输层协议。
      - 是万维网客户程序和服务器程序之间交互时遵守的协议。
    - （3）超文本标记语言 HTML
      - HTML 是一种文档结构的标记语言。
      - 使用预先约定的标记描述网页中的信息和格式。
      - 浏览器根据 HTML 组织并显示网页。
- 二、统一资源定位符 URL
  - 1. URL 的作用
    - URL 是对互联网上资源的位置和访问方法的一种表示。
    - 用于定位万维网上的网页、文件和其他资源。
  - 2. URL 的一般形式
    - <协议>://<主机>:<端口>/<路径>
  - 3. 各部分含义
    - （1）协议
      - 指明使用什么协议获取万维网文档。
      - 常见协议包括 HTTP、FTP 等。
    - （2）主机
      - 指明万维网文档所在的主机。
      - 通常是主机在互联网上的域名或 IP 地址。
    - （3）端口
      - 指明服务器上提供相应服务的端口。
      - 使用默认端口时通常可以省略。
    - （4）路径
      - 指明资源在服务器上的具体位置。
      - 可以包含目录和文件名。
  - 4. URL 示例
    - https://zhenti.beokayy.club/question/2022-40
    - 协议：HTTPS
    - 主机：zhenti.beokayy.club
    - 路径：question/2022-40
  - 5. 浏览器的简化输入
    - 很多浏览器会自动补全 HTTP 协议。
    - 也可能自动补全主机名前的 www 前缀。
    - 因此用户有时只输入域名即可访问对应网站。
- 三、HTTP 的基本工作过程
  - 1. HTTP 的特点
    - HTTP 是无状态的应用层协议。
    - HTTP 使用 TCP，能够可靠地交换网页文件。
    - 万维网服务器进程通常监听 TCP 80 端口。
  - 2. 基本流程
    - 1. 用户在浏览器中输入 URL。
    - 2. 浏览器作为万维网客户程序，与服务器建立 TCP 连接。
    - 3. 浏览器向服务器发送 HTTP 请求报文。
    - 4. 请求报文中包含需要获取的 URL 和相关信息。
    - 5. 服务器收到请求后，返回 HTTP 响应报文。
    - 6. 响应报文中通常包含 HTML 文件。
    - 7. 浏览器解析 HTML，并继续请求网页中的图片等其他对象。
    - 8. 服务器传输完资源后，根据连接方式保持或释放 TCP 连接。
  - 3. 客户端与服务器
    - 客户端：浏览器或其他万维网客户程序。
    - 服务器：运行万维网服务器程序的主机。
    - 浏览器负责发起连接和请求资源。
    - 服务器负责监听端口、处理请求并返回资源。
- 四、HTTP 连接方式与 RTT
  - 1. HTTP/1.0：非持续连接
    - HTTP/1.0 通常为每个请求建立一条 TCP 连接。
    - 获取一个网页对象通常需要
      - 建立 TCP 连接
      - 发送 HTTP 请求
      - 接收服务器响应
    - 主要的 RTT 开销
      - 第一个 RTT：建立 TCP 连接
      - 第二个 RTT：发送 HTTP 请求并开始接收响应
    - 因此获取一个对象通常至少需要约 2 个 RTT，再加上文件传输时间。
  - 2. HTTP/1.0 的缺点
    - 一个网页通常包含 HTML、图片等多个对象。
    - 如果每个对象都单独建立 TCP 连接，就要反复支付连接建立开销。
    - 网页中对象越多，额外 RTT 越多。
    - 这种非持续连接会增加服务器负担。
  - 3. HTTP/1.1：持续连接
    - HTTP/1.1 默认支持持续连接。
    - 服务器发送响应后，在一段时间内保持 TCP 连接。
    - 同一个客户和服务器可以在同一条连接上传送后续请求和响应。
    - 减少了重复建立 TCP 连接的开销。
  - 4. HTTP/1.1 流水线方式
    - 在收到前一个 HTTP 响应之前，可以继续发送新的请求报文。
    - 多个请求可以连续发送，服务器依次返回响应。
    - 适合一个网页包含多个对象的情况。
    - 需要结合题目是否考虑 TCP 拥塞窗口进行分析。
  - 5. RTT 对比记忆

| 方式 | 连接特点 | 多对象访问特点 |
|---|---|---|
| HTTP/1.0 非持续连接 | 每个对象单独建立 TCP 连接 | 每个对象都要承担连接和请求的 RTT |
| HTTP/1.1 持续连接 | 多个对象共用一条 TCP 连接 | 减少重复建连开销 |
| HTTP/1.1 流水线 | 请求可以连续发送 | 不必等待前一个响应后再发下一个请求 |

- 五、HTTP 报文结构
  - 1. 基本特点
    - HTTP 报文中的字段是 ASCII 码串。
    - 各字段长度不固定。
    - HTTP 报文分为请求报文和响应报文。
  - 2. 请求报文结构
    - 1. 请求行
    - 2. 首部行
    - 3. 空行
    - 4. 实体主体（通常可以没有）
    - 请求行
      - 一般包含：方法、URL、HTTP 版本。
      - 例如：
        - GET /dir/index.htm HTTP/1.1
    - 首部行
      - 形式为：字段名：值
      - 每个首部行以 CRLF 结束。
      - 最后一个首部行之后有一个空行。
  - 3. 响应报文结构
    - 1. 状态行
    - 2. 首部行
    - 3. 空行
    - 4. 实体主体（有些响应报文没有）
    - 状态行
      - 一般包含 HTTP 版本、状态码和短语。
      - 状态码用于说明请求处理结果。
- 六、HTTP 请求方法
  - 1. GET
    - 请求读取 URL 标识的信息。
    - 浏览网页、获取文件时最常见。
  - 2. HEAD
    - 请求读取 URL 标识的信息，但只返回首部。
    - 不返回实体主体。
  - 3. POST
    - 向服务器提交或添加信息。
    - 例如提交评论、表单等。
  - 4. CONNECT
    - 用于代理服务器。
    - 建立通向目标资源的连接。
  - 5. OPTIONS
    - 请求查询服务器支持的选项或功能。
  - 6. PUT
    - 在指定 URL 下存储一个文档。
  - 7. DELETE
    - 删除 URL 所标识的资源。
  - 8. TRACE
    - 进行环回测试。
    - 用于诊断请求报文经过的路径。
- 七、HTTP 请求报文示例
  - GET /dir/index.htm HTTP/1.1
  - Host: www.xyz.edu.cn
  - Connection: close
  - User-Agent: Mozilla/5.0
  - Accept-Language: cn
  - （最后还有一个空行）
- 八、HTTP 的无状态性与 Cookie
  - 1. HTTP 无状态
    - HTTP 本身是无状态协议。
    - 同一个客户第二次访问同一个服务器时，服务器通常不记得之前服务过该客户。
    - HTTP 不会自动保存用户的访问状态。
  - 2. Cookie 的作用
    - 网站通常使用 Cookie 加数据库跟踪用户活动。
    - Cookie 可以让服务器识别同一个用户的连续访问。
    - Cookie 不是 HTTP 协议本身自动提供的状态，而是由网站和浏览器配合实现。
  - 3. Cookie 工作过程
    - 1. 用户首次访问使用 Cookie 的网站。
    - 2. 服务器为用户生成唯一的 Cookie 识别码。
    - 3. 服务器在后端数据库中建立对应记录。
    - 4. 服务器在响应报文中通过 Set-Cookie 告知浏览器识别码。
    - 5. 浏览器把服务器主机名和 Cookie 识别码保存到本地 Cookie 文件。
    - 6. 用户再次访问该服务器时，浏览器在请求报文中带上 Cookie。
    - 7. 服务器根据 Cookie 从数据库中找到对应用户记录。
  - 4. 易错点
    - HTTP 无状态不等于网站不能识别用户。
    - 网站可以利用 Cookie、数据库等机制实现用户状态跟踪。
    - Cookie 主要用于识别和关联用户，不等于把全部用户信息直接存放在浏览器中。
- 九、常见应用层协议与熟知端口

| 应用层协议 | 传输层协议 | 熟知端口 |
|---|---|---|
| FTP 数据连接 | TCP | 20 |
| FTP 控制连接 | TCP | 21 |
| TELNET | TCP | 23 |
| SMTP | TCP | 25 |
| DNS | UDP | 53 |
| TFTP | UDP | 69 |
| HTTP | TCP | 80 |
| POP3 | TCP | 110 |
| SNMP | UDP | 161 |

本文档打印5分/页包邮