1 计算机系统与程序执行的层次

1.1 系统组成与五大功能部件

计算机系统由硬件和软件组成。主机通常包含 CPU 与主存；CPU 包含运算器、控制器和寄存器。辅存、输入设备、输出设备合称外部设备。功能部件与物理芯片的划分可不同，一个 CPU 芯片可集成多个核、Cache 和存储控制器。

功能部件	基本任务	典型状态或部件
运算器	算术、逻辑与移位运算	ALU、操作数与结果寄存器
控制器	取指、译码、产生控制信号、决定后继指令	PC、IR、控制逻辑
存储器	按地址保存指令与数据	主存保存执行所需内容，辅存提供大容量非易失空间
输入设备	将外部信息转换成机器能处理的形式	经接口输入程序和数据
输出设备	将内部结果转换成外部所需形式	经接口输出数据

CPU 数据通路包括寄存器、运算部件及其连接；控制器决定数据流向和操作时刻。早期冯·诺依曼机以运算器为中心，现代组织通常以存储器为中心，外设可经接口、总线和 DMA 与主存交换数据。

1.2 存储程序与指令执行

存储程序：执行前将指令和数据存入存储器，运行时自动取指、译码、执行。指令与数据均为二进制位串，其用途由当前执行阶段、地址和指令语义确定。冯·诺依曼机由指令控制执行次序，属于控制流驱动。

执行阶段	地址或数据来源	结果
取指	PC 给出指令地址	指令经存储器读入 IR
译码与取操作数	IR 操作码、地址字段及寻址规则	确定操作、操作数和有效地址
执行与写回	数据通路完成运算、访存或转移	更新寄存器、存储器和标志
后继地址形成	顺序地址或转移、调用、异常入口	更新 PC，继续取指

PC 的顺序增量由地址单位和指令长度决定：按字节编址、定长 4 B 指令时通常加 4。流水线可使多条指令的各阶段重叠；程序可见效果仍须符合 ISA。

MAR 保存本次主存访问地址，MDR 保存本次交换的位串；二者可在不同阶段分别传送指令地址、数据地址以及指令、数据。

程序 $y = ab + c$ 的寄存器状态

按字编址，地址 0～4 存取数、乘法、加法、存数和停机指令，地址 5～8 存 $a = 2, b = 3, c = 1, y = 0$。

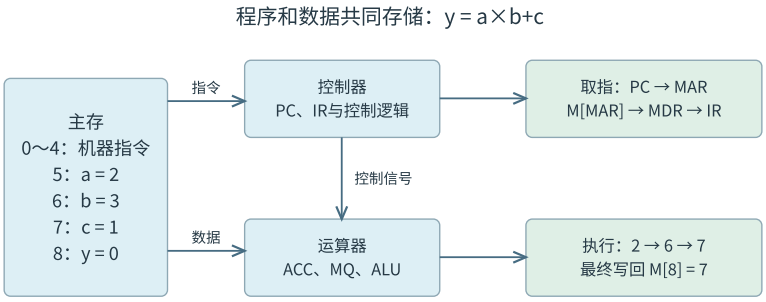


Figure 1.1: 主存按地址保存程序与数据，控制器组织取指与执行

指令地址	数据操作	完成状态
0	$M[5] \rightarrow \text{ACC}$	ACC=2，后继地址 1
1	$\text{ACC} \times M[6] \rightarrow \text{ACC}$	ACC=6，后继地址 2
2	$\text{ACC} + M[7] \rightarrow \text{ACC}$	ACC=7，后继地址 3
3	$\text{ACC} \rightarrow M[8]$	$M[8] = 7$，后继地址 4
4	停机	计算结束

示意机器中 ACC 暂存操作数或结果，MQ 辅助保存乘数或乘积低位，X 暂存另一个输入。具体寄存器配置以题设数据通路为准。

1.3 ISA、系统层次与软件

对象	规定或提供的内容
ISA（指令集体系结构）	软件可见的指令功能与编码、寄存器、数据类型、寻址方式和存储访问规则
微体系结构	ISA 的内部实现：流水级、转发、Cache 组织、加法器结构等
操作系统	资源管理、进程运行环境和服务接口
系统软件	操作系统、语言处理程序、数据库管理系统、相关工具和库
应用软件	面向用户具体任务的程序

相同 ISA 可由不同微体系结构实现，具有不同 CPI。机器码执行还受操作系统、ABI、库及可执行文件格式约束。软硬件逻辑功能等价表示同一功能可由软件算法或专用硬件实现，选择取决于时间、空间、成本、功耗与可修改性。

常用抽象层次自下而上为微程序机器级、传统机器语言级、操作系统级、汇编语言级、高级语言级。微程序级适用于采用微程序控制的机器。“透明” 表示上层使用者无需处理下层实现细节。

程序翻译与装入

$$\text{源程序} \xrightarrow{\text{预处理}} \text{展开后的源程序} \xrightarrow{\text{编译}} \text{汇编程序} \xrightarrow{\text{汇编}} \text{可重定位目标文件} \xrightarrow{\text{链接}} \text{可执行文件}.$$

预处理展开头文件、宏等；链接合并目标与库，完成符号解析和重定位；装入建立进程地址空间并准备执行入口。宏和伪指令可展开为零条、一条或多条机器指令，一条高级语言语句与机器指令条数无固定对应关系。

解释器在运行时读取源程序或中间表示并完成操作，解释器自身由机器指令运行。语言实现可组合解释、预编译和即时编译。

例 1-1

计算机硬件能够直接执行的是（ ）。

I. 机器语言程序　II. 汇编语言程序　III. 硬件描述语言程序

A. 仅 I　B. 仅 I、II　C. 仅 I、III　D. I、II、III

1.4 字长、编址与容量

名称	含义
机器字长	CPU 一次整数运算通常能处理的基本位宽
存储字长	一个存储单元保存的位数
指令字长	一条指令编码所占位数，可定长或变长
MAR 位数	可编码的主存地址位数
MDR 位数	一次主存数据交换的位宽

若 m 位完整地址全部可用，每个地址对应 w 位，则容量为 $2^m w$ bit。按字节编址时为 2^m B。已安装物理容量可以小于可编址空间。

- 20 位字节地址：1 MiB；20 位、16 位字地址：2 MiB。
- 2^{10} 个 16 位单元：2 KiB；按字编址需 10 位，改为按字节编址需 11 位。
- 4 KiB 主存、存储字长 32 位：按字编址需 10 位，按字节编址需 12 位。

容量常用 $1\text{KiB} = 2^{10}\text{B}$、$1\text{MiB} = 2^{20}\text{B}$；频率、速率的 k、M、G 通常按 $10^3, 10^6, 10^9$。带宽为每次传送字节数乘每秒传送次数，单位进制服从题设。

1.5 CPU 执行时间与性能指标

响应时间为从请求到得到结果的总历时；吞吐量为单位时间完成的任务量。程序总时间可包含 CPU 工作、I/O 等待和调度等。CPU 时间按实际动态执行的指令计算。

设第 i 类指令执行 n_i 条、平均占 c_i 个周期，主频为 f：

$$N = \sum_i n_i, \qquad C = \sum_i n_i c_i, \qquad \overline{\text{CPI}} = \frac{C}{N} = \sum_i \frac{n_i}{N} c_i,$$

$$T_{\text{CPU}} = \frac{N\overline{\text{CPI}}}{f} = N\overline{\text{CPI}} T_{\text{clk}}, \qquad T_{\text{clk}} = \frac{1}{f}.$$

平均 CPI 以指令条数为权重；Cache 缺失、流水停顿等也计入统计范围内的周期。多发射处理器的平均 CPI 可以小于 1，单条指令仍可能经历多个周期的延迟。

指标	定义及计算条件
IPC	每周期平均完成指令数；同一统计区间下 IPC $= 1/\overline{\text{CPI}}$
MIPS	每秒百万条指令，$f/(\overline{\text{CPI}} \times 10^6)$
MFLOPS ／ GFLOPS ／ TFLOPS	每秒浮点运算数分别除以 $10^6/10^9/10^{12}$
同一任务性能比	$P_A/P_B = T_B/T_A$

不同 ISA、编译器和优化方案可改变动态指令数与指令组成。比较同一任务优先使用实际执行时间，主频、CPI、MIPS 和字长各自只描述部分条件。

例 1-2

某计算机主频为 1 GHz，程序 P 运行过程中共执行 10000 条指令，其中 80% 的指令执行平均需 1 个时钟周期，20% 的指令执行平均需 10 个时钟周期。程序 P 的平均 CPI 和 CPU 执行时间分别是（ ）。

A. 2.8，28 μs　B. 28，28 μs　C. 2.8，28 ms　D. 28，28 ms

性能变化的时间比

同一任务，前后两方案满足同一 CPU 时间模型时：

$$\frac{T'}{T} = \frac{N'}{N}\,\frac{\text{CPI}'}{\text{CPI}}\,\frac{f}{f'}.$$

编译优化可同时改变 N 与 CPI；Cache 改进通常减少停顿；升频还可能伴随 CPI 变化。若 20 s 程序指令数变为 70%、CPI 变为 1.2 倍且主频不变，时间为 $20 \times 0.7 \times 1.2 = 16.8$ s。

1.6 局部加速与 Amdahl 定律

原时间中比例 p 的部分加快为原速度的 s 倍，其他部分不变，各部分时间可相加且无新增开销时：

$$T' = T[(1-p) + p/s], \qquad S = \frac{T}{T'} = \frac{1}{(1-p) + p/s}.$$

当 $s \to \infty$ 且 $p < 1$，加速比上限为 $1/(1-p)$。“速度提高 50%” 对应 $s = 1.5$。计算与 I/O 重叠、通信或同步开销变化时，先按实际时间关系重新建模。

例 1-3

假定基准程序 A 在某计算机上的运行时间为 100 s，其中 90 s 为 CPU 时间，其余为 I/O 时间。若 CPU 速度提高 50%，I/O 速度不变，则运行基准程序 A 所耗费的时间是（ ）。

A. 55 s　B. 60 s　C. 65 s　D. 70 s

增加处理器可让独立任务并发，提高吞吐量。两个各需单核 2 s 的任务在双核上同时开始，全部完成历时可由 4 s 变为 2 s；每个无排队任务的执行时间仍为 2 s。

1.7 器件发展阶段

电子管 → 晶体管 → 中小规模集成电路 → 大规模与超大规模集成电路。集成度提高推动可靠性、容量、速度和微型化、多核与并行计算发展。摩尔定律描述晶体管数量增长的历史经验趋势，程序加速仍由具体执行时间模型判断。

2 数据表示、位级运算与浮点数

2.1 进位计数制与位串解释

位串的真值由位宽、编码和小数点位置共同确定。1 B=8 bit，B 表示字节，b 表示位。

$$(a_k \cdots a_0.a_{-1} \cdots)_r = \sum_i a_i r^i, \qquad 0 \le a_i < r.$$

转换	规则
十进制整数转 r 进制	除 r 取余，余数倒序排列
十进制小数转 r 进制	乘 r 取整，整数顺序排列
二进制与八进制	从小数点向两侧每 3 位一组；整数端左补 0，小数端右补 0
二进制与十六进制	从小数点向两侧每 4 位一组，补 0 规则同上

有限十进制小数可有无限二进制展开，如 0.1；有限位存储时须按规定截断或舍入。

例 2-1

若十进制数为 137.5，则其八进制数为（　）。

A. 89.8　　B. 211.4　　C. 211.5　　D. 1011111.101

2.2 定点数编码与范围

真值是数学数值，机器数是约定编码下的位串。定点表示约定固定小数点位置。

n 位整数编码	数值规则	范围与零
无符号	全部位为正权	$0 \sim 2^n - 1$
原码	最高位符号，其余为绝对值	$-(2^{n-1}-1) \sim 2^{n-1}-1$，两个零
反码	正数同原码，负数数值位逐位取反	同原码范围，两个零
补码	最高位权 -2^{n-1}，其余正权	$-2^{n-1} \sim 2^{n-1}-1$，一个零

补码值：

$$x = -b_{n-1}2^{n-1} + \sum_{i=0}^{n-2} b_i 2^i = \begin{cases} u, & u < 2^{n-1}; \\ u - 2^n, & u \ge 2^{n-1}, \end{cases}$$

其中 u 为该位串的无符号值。负数补码可由同宽绝对值逐位取反加 1 得到。8 位 `FDH` 表示 -3，`80H` 表示 -128。最小负数的数学相反数超出同宽补码范围，同宽取反加 1 会保留原位串。

原码的 -0 为 `1000…0`，反码的 -0 为 `1111…1`。一位符号、$n-1$ 位小数时，原码、反码范围为 $[-(1-2^{-(n-1)}), 1-2^{-(n-1)}]$；补码范围为 $[-1, 1-2^{-(n-1)}]$。

整数移码采用偏置 2^{n-1} 时，$E = x + 2^{n-1}$，其编码由同宽补码翻转最高位得到。IEEE 阶码采用另一偏置，按字段定义计算。

2.3 截断、扩展与 C 类型转换

变换	位级规则与条件
缩短位宽	题设截断模型保留低位；保值需被删除高位满足原值扩展关系
无符号扩展	高位补 0
补码扩展	高位复制原符号位
转 n 位无符号数	按模 2^n 的值转换
补码扩大后保值	新增高位均为原符号位

源数的解释决定扩展方式。16 位无符号 65530 扩为 32 位是 `0000 FFFAH`；16 位补码 -32767 转 32 位无符号是 $2^{32}-32767$，位串 `FFFF 8001H`。

例 2-2

假定编译器规定 int 型和 short 型长度分别为 32 位和 16 位，执行下列 C 语言语句：

```
unsigned short x = 65530;
unsigned int y = x;
```

得到 y 的机器数为（ ）。

A. 0000 7FFAH　B. 0000 FFFAH　C. FFFF 7FFAH　D. FFFF FFFAH

例 2-3

在 32 位计算机上执行下列 C 语言代码段后，ui 的值是（ ）。

```
short si = -32767;
unsigned int ui = si;
```

A. $2^{15}-1$　B. $2^{15}+1$　C. $2^{32}-2^{15}-1$　D. $2^{32}-2^{15}+1$

C 表达式先作整数提升和通常算术转换，再确定比较与运算类型。32 位 `int i=-1; unsigned u=1;` 的常见模型中，`i<u` 为假，因 i 转换为 $2^{32}-1$。

本章 C11/C17 口径下：无符号运算按模 2^n；有符号算术溢出属未定义行为；超范围转有符号类型涉及实现规定。题设机器的截断、绕回模型应与语言保证分别使用。

逻辑移位与算术移位

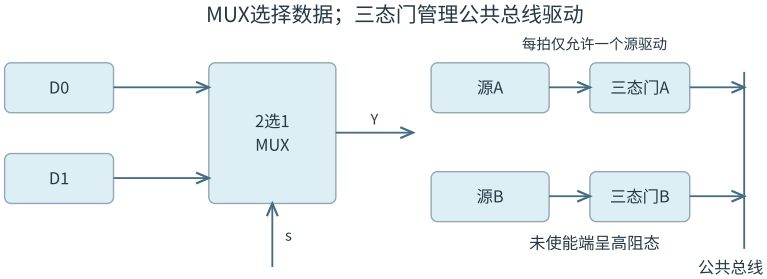


Figure 2.1: 选择器选择数据源，三态门控制公共线驱动

操作	补入位与保值条件
逻辑右移	高位补 0，无符号值除 2^k 向下取整
补码算术右移	高位补符号位，值除 2^k 向负无穷取整
左移	低位补 0；高位丢失可能导致溢出

8 位补码 -3 算术右移 1 位为 -2；C 整数 $-3/2$ 向零截断为 -1。C11/C17 负有符号数右移涉及实现规定，使用题设算术右移模型时须明确该条件。左移按位结果与 C 有符号左移的合法性分别检查。

2.4 逻辑门、选择器与三态门

A, B	与 AB	或 $A+B$	异或 $A \oplus B$
0,0	0	0	0
0,1	0	1	1
1,0	0	1	1
1,1	1	1	0

逻辑非、与、或的通常优先级依次降低；括号及非号覆盖范围优先。德摩根律：$\overline{A+B}=\bar{A}\bar{B}$，$\overline{AB}=\bar{A}+\bar{B}$。多个位异或为 1，当且仅当其中 1 的个数为奇数；可用于本位和与奇偶校验。

k 选 1 MUX 至少需 $\lceil \log_2 k \rceil$ 位选择编码；2 选 1：$Y=\bar{s}D_0+sD_1$。32 位 MUX 同时选择 32 条对应位。

三态门关闭时输出高阻态，开启时驱动 0 或 1。高阻表示不主动驱动公共线。共享总线同一时刻须满足驱动源控制约束，多个源输出相反电平会争用。

2.5 加减运算器与进位逻辑

规定 C_i 为第 i 位输入进位，C_{i+1} 为输出进位：

$$S_i = A_i \oplus B_i \oplus C_i, \qquad G_i = A_i B_i, \quad P_i = A_i \oplus B_i,$$

$$C_{i+1} = G_i + P_i C_i.$$

例如 $C_2 = G_1 + P_1G_0 + P_1P_0C_0$。串行进位逐级传播；先行进位用组合逻辑展开进位，增加电路复杂度以缩短关键路径。“并行输入各位” 与 “并行生成进位” 是两项实现性质。

加减控制位 Sub 令第二输入为 $B \oplus \text{Sub}$、最低进位 $C_0 = \text{Sub}$：

$$\text{Sub} = 0:\ A + B; \qquad \text{Sub} = 1:\ A + \overline{B} + 1 = A - B \pmod{2^n}.$$

ALU 按操作控制选择算术、与、或、异或等功能，移位器位置以具体通路为准。数据位宽与操作选择编码位宽分别确定。

例 2-4

某计算机字长为 8 位，CPU 中有一个 8 位加法器。已知无符号数 $x = 69, y = 38$，若在该加法器中计算 $x - y$，则加法器的两个输入端信息和输入的低位进位信息分别为（　）。

A. 0100 0101、0010 0110、0
B. 0100 0101、1101 1001、1
C. 0100 0101、1101 1010、0
D. 0100 0101、1101 1010、1

2.6 运算标志与条件转移

本章采用 CF=1 表示减法借位的约定。设 n 位加减器最高输出进位为 C_n：

$$\text{CF} = C_n \oplus \text{Sub}, \quad \text{OF} = C_{n-1} \oplus C_n, \quad \text{SF} = S_{n-1}, \quad \text{ZF} = [S = 0].$$

CF 判断无符号溢出或借位；OF 判断补码有符号溢出。同号相加结果异号时加法溢出；异号相减结果与被减数异号时减法溢出。采用 “无借位” 进位约定的 ISA 应按其定义改判 CF。

8 位运算	低 8 位	CF	OF	SF	ZF
`7FH+01H`	`80H`	0	1	1	0
`FFH+01H`	`00H`	1	0	0	1
`80H-01H`	`7FH`	0	1	0	0
`00H-01H`	`FFH`	1	0	1	0

计算 $a - b$ 后的比较条件：

条件	标志表达式
相等	ZF=1
无符号 $a < b$	CF=1
无符号 $a > b$	CF=0 且 ZF=0
有符号 $a < b$	SF ≠ OF
有符号 $a > b$	SF=OF 且 ZF=0

例 2-5

假定有符号整数采用补码表示，若 int 型变量 x 和 y 的机器数分别是 FFFF FFDFH 和 0000 0041H，则 x、y 的值及 x−y 的机器数分别是（　）。

A. x=−65，y=41，x−y 的机器数溢出
B. x=−33，y=65，x−y 的机器数为 FFFF FF9DH
C. x=−33，y=65，x−y 的机器数为 FFFF FF9EH
D. x=−65，y=41，x−y 的机器数为 FFFF FF96H

例 2-6

已知 x、y 为 int 类型，当 x=100、y=200 时，执行 “x 减 y” 指令得到的溢出标志 OF 和借位标志 CF 分别为 0、1。那么当 x=10、y=−20 时，执行该指令得到的 OF 和 CF 分别是（ ）。

A. OF=0，CF=0　B. OF=0，CF=1　C. OF=1，CF=0　D. OF=1，CF=1

2.7 无符号乘法与乘法器组织

两个 n 位数完整乘积最多需 $2n$ 位。无符号顺序乘法初态 $P=0$，Y 装乘数，X 装被乘数。每轮：检查 $Y_0 \to$ 若为 1 则 $P \leftarrow P+X$ 并保留进位 $\to (C,P,Y)$ 整体逻辑右移；共 n 轮。

$X=1101, Y=1011$ 时：

轮次	Y_0；加法后 C,P	右移后 P,Y
初态	—	0000,1011
1	1；0,1101	0110,1101
2	1；1,0011	1001,1110
3	0；0,1001	0100,1111
4	1；1,0001	1000,1111

结果 `10001111`=143。若只保存低 n 位，高 n 位非零表示无符号乘积溢出。

乘法器组织	特征
顺序乘法器	复用加法器与移位器，跨多周期完成
阵列乘法器	并行生成并压缩部分积，延迟由组合路径决定
流水线乘法器	多级寄存器分隔组合路径，多组运算可重叠，提高吞吐率

常数乘法可在语义与位宽允许时化为移位加减，如 $13x=(x\ll 3)+(x\ll 2)+x$。

Booth 补码一位乘法

乘数后附 $q_{-1}=0$，每轮观察 (Y_0,q_{-1})：00、11 加 0，01 加 X，10 减 X；随后 (P,Y,q_{-1}) 整体算术右移。符号位参加运算，跨寄存器边界传位。

$X=1101=-3, Y=0110=6$：

轮次	观察位与操作	右移后 P,Y,q_{-1}
初态	—	0000,0110,0
1	00，加 0	0000,0011,0
2	10，减 X	0001,1001,1
3	11，加 0	0000,1100,1
4	01，加 X	1110,1110,0

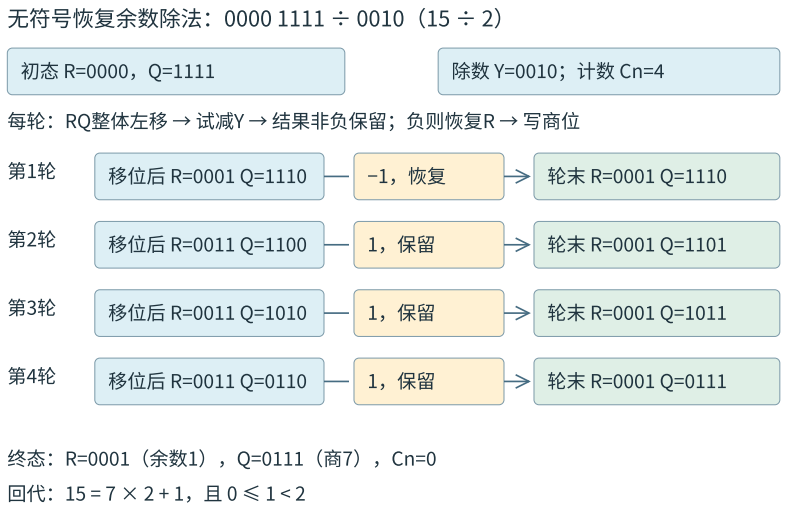


Figure 2.2: 15 除以 2 的试减、恢复和商位写入

完整乘积 `11101110`=−18。保留低 n 位补码时，未溢出条件为完整积的高 n 位均为低半部符号位的扩展，即完整积最高 $n+1$ 位全部相同。最小负数的取负及中间操作须配置足够保护位。

2.8 除法、商溢出与余数校正

无符号双精度被除数以 (R, Q) 保存，各 n 位，除数 Y 为 n 位。单精度被除数先零扩展。除数 $Y > 0$ 时，初始高半部 $R \geq Y$ 意味着商至少为 2^n，产生商溢出。4 位商中，255/15=17 溢出，200/15=13 余 5 可表示。

算法	每轮更新与结束条件
恢复余数法	移入下一被除数位，试减除数；非负保留差、商位 1；负则加回除数、商位 0
不恢复余数法	根据上一轮余数符号决定本轮减或加除数；按新余数生成商位；最终负余数须按规则校正

无符号最终结果必须满足 $N = QY + R$ 且 $0 \leq R < Y$。试减的暂时负值需符号或借位状态支持。

恢复余数法的寄存器轨迹

15/2 初态 $R = 0000, Q = 1111, Y = 0010$，每轮先整体左移 RQ，再试减并记录商位，共 4 轮，得到 $Q = 0111, R = 0001$。

不恢复余数法的 7/3，取 4 位有符号 R、3 位 Q：

轮次	整体左移后 R	本轮操作	操作后 R	记商后 Q
初态	—	—	0	111
1	1	减 3	−2	110
2	−3	加 3	0	101
3	1	减 3	−2	010

末轮 $R < 0$，再加 3 校正为 1；商 2、余 1。

有符号除法与异常

按向零截断约定，商符号由两操作数符号异或确定，非零余数与被除数同号，$X = QY + R$。例如 $-15/2$ 的商 -7、余 -1；$15/(-2)$ 的商 -7、余 1。

课件 4 位补码 $-7/3$：被除数符号扩展为 $R = 1111, Q = 1001, Y = 0011$。本例负余数试加正除数；试加改变原负号时恢复，否则保留并生成商的绝对值位。

轮次	左移后 R、Q	试加 R	轮末 R、Q
1	1111、0010	0010，恢复	1111、0010
2	1110、0100	0001，恢复	1110、0100
3	1100、1000	1111，保留	1111、1001
4	1111、0010	0010，恢复	1111、0010

最后商绝对值 2，异号取补为 1110=-2；余数 1111=-1。整除时需单独正确接受试算零。也可在足够宽的内部表示中先求绝对值，完成无符号除法后恢复符号。

除数 0 须异常处理；$-2^{n-1}/(-1)$ 超出 n 位补码商范围。固定轮数除法器按位宽迭代；提前退出须由题设明确给出。

2.9 IEEE 754 字段与特殊值

设尾数字段整数值为 F、位数为 p、阶码为 E、偏置为 B，符号为 s。

参数	binary32	binary64
符号／阶码／尾数字段位数	1 ／ 8 ／ 23	1 ／ 11 ／ 52
偏置 B	127	1023
规格化有效精度	24 位	53 位
规格化真阶码	–126～127	–1022～1023
最小正规格化数	2^{-126}	2^{-1022}
最小正次正规数	2^{-149}	2^{-1074}
最大有限正数	$(2-2^{-23})2^{127}$	$(2-2^{-52})2^{1023}$

字段条件	数值／含义
$E=0, F=0$	正零或负零，由 s 区分
$E=0, F\neq 0$	次正规数（非规格化数），$(-1)^s(F/2^p)2^{1-B}$，隐含前导 0
E 既非全 0 也非全 1	规格化数，$(-1)^s(1+F/2^p)2^{E-B}$，隐含前导 1
E 全 1，$F=0$	正无穷或负无穷
E 全 1，$F\neq 0$	NaN

binary32 位串 `00000001H` 为 2^{-149}，`00800000H` 为 2^{-126}。编码前先规格化绝对值，最后独立写符号位；负浮点数按符号、指数、尾数解读。比较有限同号负数时，绝对值较大者数值较小。

例 2-7

-0.4375 的 IEEE 754 单精度浮点数表示为（　）。

A. BEE0 0000H　B. BF60 0000H　C. BF70 0000H　D. C0E0 0000H

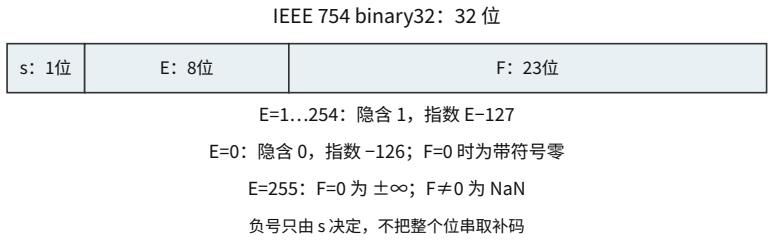


Figure 2.3: 单精度字段与指数编码

例 2-8

float 型数据常用 IEEE 754 单精度浮点格式表示。假设两个 float 型变量 x 和 y 分别存放在 32 位寄存器 f1 和 f2 中，若 `(f1)=CC90 0000H`、`(f2)=B0C0 0000H`，则 x 和 y 之间的关系为（　）。

A. x<y 且符号相同　B. x<y 且符号不同　C. x>y 且符号相同　D. x>y 且符号不同

2.10 浮点加减与舍入

顺序为：对阶 → 尾数加减 → 规格化 → 舍入 → 检查规格化与阶码范围。

步骤	规则与边界
对阶	小阶向大阶对齐，小阶尾数右移；最终阶码为原合法大阶，可能损失低位
右规	尾数出现 $10.xxx_2$ 时右移 1 位、阶码加 1，可能上溢
左规	抵消后左移尾数、阶码减少，可能触及次正规区或下溢边界；精确零单独处理
舍入	可能使尾数进位，再右规并检查上溢
渐进下溢	指数过小时可能形成次正规数，接近 0 后才舍入为零

最近偶数舍入：被舍部分小于半个间隔取低端，大于半个间隔取高端，恰好居中取保留有效数最低位为 0 的候选。保护位 G、舍入位 R、粘滞位 S 保留舍入依据，S 为更低被舍位的逻辑或；最近偶数下，$G=1$ 且 $(R \vee S \vee \text{LSB})=1$ 时向保留部分进 1。

例 2-9

下列有关浮点数加减运算的叙述中，正确的是（　）。

I. 对阶操作不会引起阶码上溢或下溢
II. 右规和尾数舍入都可能引起阶码上溢
III. 左规时可能引起阶码下溢
IV. 尾数溢出时，结果不一定溢出

A. 仅 II、III　B. 仅 I、II、IV　C. 仅 I、III、IV　D. I、II、III、IV

浮点加法可能不满足结合律。binary32 取 $a=2^{25}, b=-2^{25}, c=1$，则 $(a+b)+c=1$，而 $b+c$ 先舍入回 b，得到 $a+(b+c)=0$。

浮点精度与数值范围

binary32 在 $[2^e, 2^{e+1})$ 中的相邻正规格化数间隔为 2^{e-23}。所有 $[-2^{24}, 2^{24}]$ 内整数可精确表示，界外部分整数仍可精确表示；在 $[2^{24}, 2^{25})$ 中间隔

2，在 $[2^{25}, 2^{26})$ 中间隔 4。

精确数学结果	binary32 最近偶数结果
$2^{24}+0.5$	16777216
$2^{24}+1$	16777216
$2^{24}+1.5$	16777218
$(2^{24}+2)+1$	16777220

精确性由有效位与舍入决定，有限范围由指数和尾数上界共同决定。32 位补码在其范围内表示连续整数；binary32 的数值范围较大、有效精度为 24 位。

例 2-10

已知 $f(n)=\sum_{i=0}^{n}2^i=2^{n+1}-1=\underbrace{11\cdots1}_{n+1位}{}_2$，计算 $f(n)$ 的 C 语言函数 f1 如下。

```c
int f1(unsigned n) {
    int sum = 1, power = 1;
    for (unsigned i = 0; i <= n - 1; i++) {
        power *= 2;
        sum += power;
    }
    return sum;
}
```

将 f1 中的 int 都改为 float，可得到计算 $f(n)$ 的另一个函数 f2。假设 unsigned 和 int 型数据都占 32 位，float 采用 IEEE 754 单精度标准。请回答下列问题。

(1) 当 n=0 时，f1 会出现死循环，为什么？若将 f1 中的变量 i 和 n 都定义为 int 型，则 f1 是否还会出现死循环？为什么？

(2) f1(23) 和 f2(23) 的返回值是否相等？机器数各是什么（用十六进制表示）？

(3) f1(24) 和 f2(24) 的返回值分别为 33 554 431 和 33 554 432.0，为什么不相等？

(4) $f(31)=2^{32}-1$，而 f1(31) 的返回值却为 -1，为什么？若使 f1(n) 的返回值与 f(n) 相等，则最大的 n 是多少？

(5) f2(127) 的机器数为 7F80 0000H，对应的值是什么？若使 f2(n) 的结果不溢出，则最大的 n 是多少？若使 f2(n) 的结果精确（无舍入），则最大的 n 是多少？

32 位 int 转 binary64 可精确，转 binary32 可能丢低位。binary32 有限值扩为 binary64 可精确保留，已经丢失的信息无法恢复。浮点转整数向零截断且须检查目标范围；NaN 与任何值含自身的相等比较为假。

2.11 字节序、边界对齐与数组地址

存放规则	最低地址保存的字节
大端	最高有效字节；12345678H 依次 12、34、56、78
小端	最低有效字节；12345678H 依次 78、56、34、12

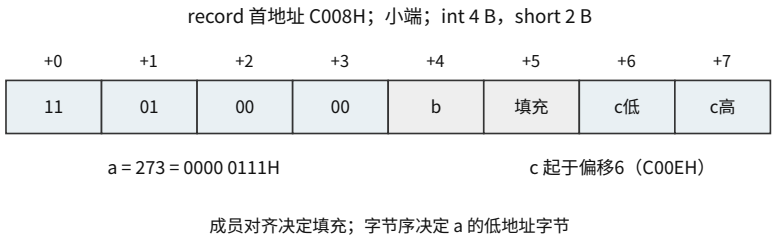


Figure 2.4: 结构体成员与填充位置

字节序只改变一个多字节对象内部各字节的位置，字节内位序、数组元素先后次序保持各自规定。–6 的 16 位补码 FFFAH 按小端存为 FA、FF。

自然对齐模型下，2 B 对象起点为 2 的倍数，4 B 对象起点为 4 的倍数。成员前填充满足各成员对齐，结构末尾填充满足相邻数组元素对齐，具体规则由题设或 ABI 给出。

成员偏移可按 $\lceil d/a \rceil a$ 对齐，其中 d 为前一成员结束后的偏移，a 为当前成员对齐要求。结构总长按结构对齐要求取整。

例 2-11

某计算机存储器按字节编址，采用小端方式存放数据。假定编译器规定 int 型和 short 型长度分别为 32 位和 16 位，并且数据按边界对齐存储。某 C 语言程序段如下：

```
struct {
    int a;
    char b;
    short c;
} record;
record.a = 273;
```

若 record 变量的首地址为 0xC008，则地址 0xC008 中的内容及 record.c 的地址分别为（　）。

A. 0x00，0xC00D　　B. 0x00，0xC00E
C. 0x11，0xC00D　　D. 0x11，0xC00E

按字节编址、元素宽 w B、行优先二维数组列数 C：

$$\text{addr}(a[i][j]) = \text{base}(a) + (iC + j)w.$$

`struct { int id; char name[10]; int salary; }` 在 int 为 4 B 且自然对齐时，id 偏移 0，name 偏移 4，salary 偏移 16，结构长 20 B。数组首址 A0B0H，第二元素 id=12345678H 时，小端字节 56H 位于 A0C5H。

机器字长、存储字长与指令字长分别确定。按字节编址的 32 位整数占 4 个地址，按 32 位字编址则占 1 个地址；容量与跨界访问均先统一地址单位。

3 存储层次、地址与 Cache

3.1 存储层次与性能指标

寄存器 → Cache → 主存 → 外存，通常速度逐级降低、容量逐级增大、每位成本逐级降低。Cache—主存层次利用局部性缓解 CPU 与主存速度差；主存—辅存层次由硬件与操作系统配合实现虚拟存储。

存取方式	定位规则	典型对象
随机存取 RAM	按地址访问任意单元，寻址步骤基本与位置无关	SRAM、DRAM
顺序存取 SAM	按记录次序定位	磁带
直接存取 DAM	先选区域，再在局部定位	磁盘
相联存取 CAM	按内容或标记比较	TLB 相联查找

指标	定义与条件
容量	单元数 × 每单元位数；2^{20} 个 8 位单元为 1 MiB
存取时间 t_a	启动一次读写到完成该操作的延迟
存取周期 T	连续两次独立访问的最短启动间隔，可含恢复时间
带宽	单位时间最大传送信息量；简单单端口模型为每次传送位数／存取周期
单位成本	总成本／总位数

容量中的 KiB、MiB 按 $2^{10}, 2^{20}$ B；频率和速率中的 M、G 通常按 $10^6, 10^9$。题源采用 KB、MB 时先依据题设确认进制。

3.2 SRAM、DRAM 与 ROM

器件	保存机制	读出与保持	常见用途
SRAM	双稳态电路	非破坏性读出，供电期间无需刷新；易失	Cache
DRAM	电容电荷	读后再生，周期刷新；易失，集成密度高	主存
Flash	非易失性闪存单元	按规定粒度编程与擦除，寿命有限	SSD 等

随机存取、是否易失、是否破坏性读出是不同分类维度。主存与 Cache 是系统层次角色，SRAM、DRAM 是器件技术。

ROM 类别	写入与修改方式
掩膜 ROM	制造时写入，使用阶段固定
PROM	用户一次编程
EPROM	紫外线擦除后重写，通常整片擦除
EEPROM	电擦除、电改写，速度和次数受器件限制
Flash	通常按块擦除，读、编程、擦除粒度分别规定

DRAM 刷新与地址复用

读后再生恢复刚读单元的电荷；定时刷新保持长期未访问单元的信息。刷新通常按行进行，保持时间内所有行均须刷新。

刷新方式	时间安排
集中刷新	固定时段连续刷新全部行，形成集中死时间
分散刷新	正常存取与刷新交替，扩大存取周期
异步刷新	将各行刷新均匀分散在保持时间内，定期插入短刷新周期

有 R 行、保持时间 T_r、每行刷新占 t_f 时，理想均匀刷新间隔为 T_r/R，总占用比例为 Rt_f/T_r。128 行、2 ms、每行 0.5 μs：间隔 15.625 μs，占比 3.2%；4096 行、64 ms、每行 100 ns：间隔 15.625 μs，占比 0.64%。命令粒度和内部刷新行为服从题设。

$2^k \times w$ 芯片含 2^k 个 w 位单元。普通非复用 SRAM 通常需 k 根地址线、w 根数据线。DRAM 将行、列地址分时送到复用地址引脚；若行列各 $k/2$ 位，则需 $k/2$ 根地址引脚，另配行列选通及其他控制线。

例 3-1

某容量为 256 MB 的存储器由若干 $4\text{M} \times 8$ 位的 DRAM 芯片构成，该 DRAM 芯片的地址引脚和数据引脚总数是（　）。

A. 19　B. 22　C. 30　D. 36

双端口 RAM 有两套地址、数据和控制线，可并行访问不同单元。同一单元的读写、写写冲突按忙信号、仲裁和芯片规定处理。

3.3 主存地址空间与 MAR

MAR 位数由可编码主存地址空间与编址单位决定，MDR 位数反映一次交换数据的宽度。已安装容量可以小于可编址空间。

例 3-2

某计算机存储器按字节编址，主存地址空间大小为 64 MB，现用 $4\text{M} \times 8$ 位的 RAM 芯片组成 32 MB 的主存储器，则存储器地址寄存器 MAR 的位数至少是（　）。

A. 22 位　B. 23 位　C. 25 位　D. 26 位

3.4 单体多字与多体交叉存储

单体多字通过扩宽一次读写数据量，提高顺序访问的带宽；多体存储包含可相对独立工作的模块。高位交叉以高位选模块，同一连续区间落在同体；低位交叉以低位选模块，连续字轮流分布到不同体。

m 体低位交叉、按字编址：

$$\text{模块号} = A \bmod m, \qquad \text{模块内地址} = \lfloor A/m \rfloor .$$

若给字节地址、每字 w B，先用 $\lfloor A/w \rfloor$ 求字地址。模块存取周期 T、连续启动间隔 τ，连续访问无其他冲突且 $m\tau \geq T$ 时：

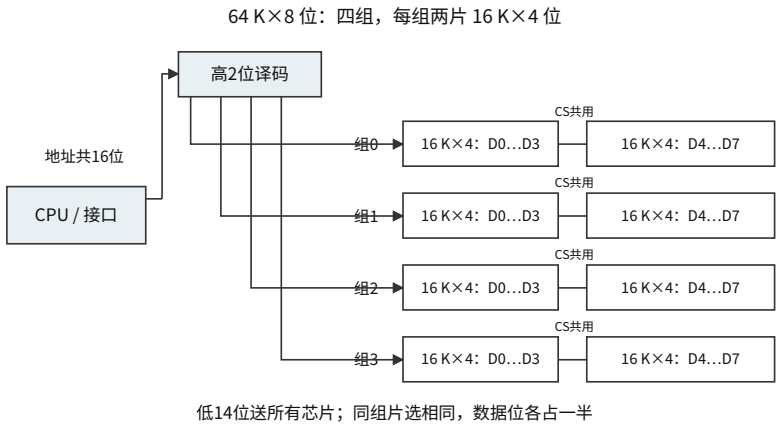


Figure 3.1: 同组并联扩位，四组译码扩字

$$t_n = T + (n-1)\tau, \qquad m \geq \lceil T/\tau \rceil.$$

$T = 200$ ns、$\tau = 50$ ns 至少需 4 体，连续 8 字为 550 ns。4 体步长 4 访问始终选同体；再次请求到达时该体尚忙才冲突。低位交叉提高连续吞吐率，第一字延迟仍由 T 决定。

例 3-3

某计算机使用 4 体交叉编址存储器，假定在存储器总线上出现的主存地址（十进制）序列为 8005、8006、8007、8008、8001、8002、8003、8004、8000，则可能发生访存冲突的地址对是（　）。

A. 8004 和 8008　　B. 8002 和 8007　　C. 8001 和 8008　　D. 8000 和 8004

3.5 主存芯片字位扩展

以 $n \times b$ 芯片组成 $N \times W$ 存储器，且两维均为整数倍时：

$$\text{并行片数} = W/b, \quad \text{地址组数} = N/n, \quad \text{总片数} = \frac{N}{n}\frac{W}{b}.$$

扩展	地址与数据连接	片选
位扩展	同组地址并联，各片负责不同数据位	同组选中信号相同
字扩展	低位送片内地址，高位选择地址区间	各组片选互斥
字位同时扩展	先按目标字长组成并行组，再增加地址组	组内共同选中，组间译码选择

两片 16K $\times$ 4 构成一组 16K $\times$ 8，四组共 8 片构成 64K $\times$ 8。低 14 位选片内单元，高 2 位作 2–4 译码。

例 3-4

某计算机主存容量为 64 KB，其中 ROM 区为 4 KB，其余为 RAM 区，按字节编址。现要用 2K $\times$ 8 位的 ROM 芯片和 4K $\times$ 4 位的 RAM 芯片

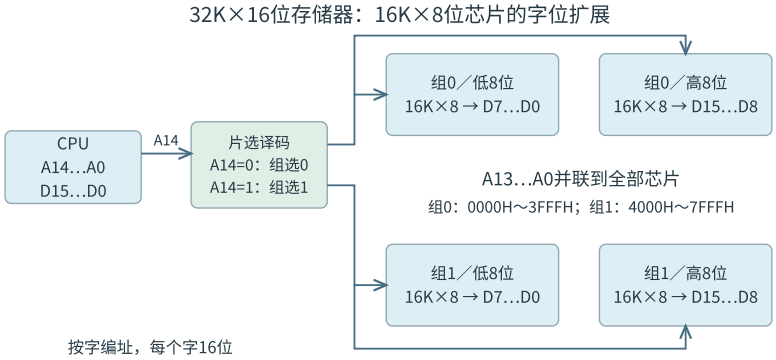


Figure 3.2: 两片作位扩展，A14 选择两组

来设计该存储器，则需要上述规格的 ROM 芯片数和 RAM 芯片数分别是（ ）。

A. 1、15　　B. 2、15　　C. 1、30　　D. 2、30

片选译码与地址范围

译码方式	特征
全译码	使用全部需要判别的高位地址，地址映射唯一
部分译码	省略部分高位，可能多个地址选中同一物理单元，形成地址重叠
线选法	直接用地址线选片，连线简单，可用组合和连续性受限制

片选表达式同时考虑地址译码、访存使能及有效电平。地址线高低位由题干定义，通常 A0 最低，也可有 A0 最高的题设。

首地址由片选编码接片内全 0 组成，末地址接片内全 1 组成。按字编址的 32K × 16 芯片需 15 位片内地址，高 3 位片选 111 时，范围 38000H～3FFFFH；改按字节编址后，每字 2 B，须增加字节选择与字节使能信息并重算范围。

16K × 8 组成 32K × 16：4 片，2 片一组、2 组。$A_{13} \sim A_0$ 接所有芯片，A_{14} 选组；按字编址组范围 0000H～3FFFH、4000H～7FFFH。

3.6 磁盘结构、容量与访问时间

盘面包含磁道，磁道划分为扇区；不同盘面同半径的磁道组成柱面。典型定位字段为柱面号、磁头号、扇区号，磁头号确定盘面。

$$\text{容量} = \text{有效盘面数} \times \text{每面磁道数} \times \text{每道扇区数} \times \text{每扇区字节数}.$$

$$T_{\text{access}} = T_{\text{seek}} + T_{\text{rotation}} + T_{\text{transfer}}.$$

转速 r 转/分，一圈 $60/r$ s；随机到达、角位置均匀时，平均旋转等待为 $30/r$ s。每道 S 扇区、连续传 k 扇区且忽略其他开销时，传输时间为 $(k/S)(60/r)$。控制器与排队开销按题设增加。

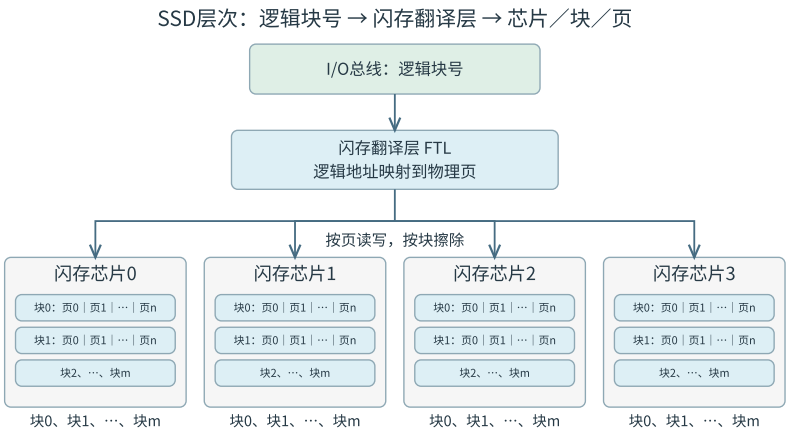


Figure 3.3: 逻辑块经 FTL 映射到闪存芯片、块与页

例 3-5

若磁盘转速为 7200 转/分，平均寻道时间为 8 ms，每个磁道包含 1000 个扇区，则访问一个扇区的平均存取时间大约是（　）。

A. 8.1 ms　　B. 12.2 ms　　C. 16.3 ms　　D. 20.5 ms

RAID 组织

级别	数据与冗余组织	典型性质
RAID0	条带化，无冗余	提高并行带宽，单盘故障可使阵列数据丢失
RAID1	镜像	常见双副本有效容量约为总容量一半
RAID3	细粒度条带，专用校验盘	数据盘协调并行传输
RAID4	块级条带，专用校验盘	校验盘可能成为写热点
RAID5	块级条带，分布式校验	分散校验写入，通常容忍单盘故障

容错范围由具体级别和故障分布决定，更新数据还可能引入校验一致性开销；冗余副本会同步误写或误删，备份承担历史恢复功能。

3.7 SSD 的页、块与磨损均衡

NAND Flash 通常按页读取或编程、按块擦除。FTL 将主机逻辑块地址映射为闪存物理页地址。具体页、块尺寸依器件而定，示例可取页 512 B～4 KiB、块 16～512 KiB。

管理动作	作用
异地更新	新数据写入空闲已擦除位置，更新映射，旧页失效
垃圾回收	搬走块中有效页，擦除旧块，回收空间
写放大	实际闪存写入量因有效页搬移等大于主机写入量
动态磨损均衡	新写入优先使用擦除次数较少的空闲块
静态磨损均衡	进一步搬移冷数据，让长期少用的块参加新写入

SSD 无机械寻道和旋转等待，仍有闪存、控制器、接口传输和写入管理延迟；擦写次数、写放大和管理开销须按具体模型考虑。

3.8 Cache 局部性与平均访问时间

时间局部性：近期访问过的同一信息可能很快再访问；空间局部性：相邻位置可能很快被访问。Cache 按块调入利用空间局部性。

$$h = \frac{N_{\text{hit}}}{N_{\text{hit}} + N_{\text{miss}}}.$$

时间定义／访问模型	平均访问时间
先查 Cache，缺失后额外耗时 p	$t_c + (1-h)p$
完整缺失访问耗时 t_{miss}，已含查 Cache	$ht_c + (1-h)t_{\text{miss}}$
Cache 与主存同时启动，命中取 Cache 结果	$ht_c + (1-h)t_m$
先 Cache、缺失后启动主存，主存耗时 t_m	$t_c + (1-h)t_m$

$t_m = 5t_c, h = 0.95$ 时，并行模型为 $1.2t_c$、加速约 4.17 倍；串行为 $1.25t_c$、加速 4 倍。$t_c = 2$ ns、缺失额外 80 ns、$h = 0.95$ 时平均 6 ns；若 80 ns 已含查 Cache，则平均 5.9 ns。

两级 Cache 的简单串行模型：AMAT $= t_1 + m_1(t_2 + m_2 p_2)$，其中 m_2 为进入二级后的局部缺失率，二级全局缺失率为 $m_1 m_2$。回写、调块、重访等开销是否计入缺失损失服从题设。

例 3-6

有如下 C 语言程序段：

```
for (k = 0; k < 1000; k++)
    a[k] = a[k] + 32;
```

若数组 a 和变量 k 均为 int 型，int 型数据占 4 B，数据 Cache 采用直接映射方式，数据区大小为 1 KB、块大小为 16 B，该程序段执行前 Cache 为空，则该程序段执行过程中访问数组 a 的 Cache 缺失率约为（　）。

A. 1.25%　　B. 2.5%　　C. 12.5%　　D. 25%

块传送与突发访问

取 64 B 块、每次传 8 B，若每次均需地址 1 周期、准备 8 周期、传输 1 周期，独立访问需 $8(1+8+1) = 80$ 周期。支持一次地址、一次首数据等待、连续 8 次传输的突发模型时，共 $1 + 8 + 8 = 17$ 周期。

3.9 Cache 映射与地址字段

设数据区容量 C B、块大小 B B、r 路、m 位字节地址。先求行数 $L = C/B$、组数 $G = L/r$。B, G 均为 2 的幂时：

$$b = \log_2 B, \quad g = \log_2 G, \quad t = m - b - g.$$

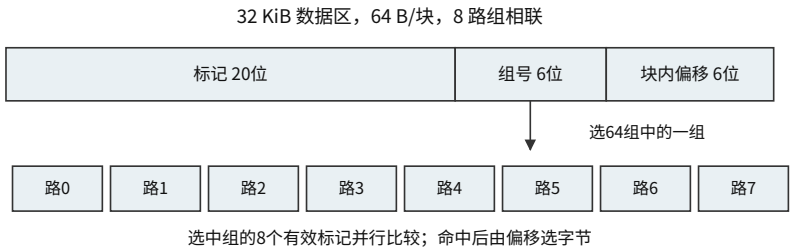


Figure 3.4: 块内偏移、组号与标记

$$q = \lfloor A/B \rfloor, \quad d = A \bmod B, \quad s = q \bmod G, \quad \text{tag} = \lfloor q/G \rfloor,$$

$$A = (\text{tag}\, G + s)B + d.$$

映射	可放位置	组选位数	比较范围	替换范围
直接映射	唯一一行	$\log_2(C/B)$	该行 1 个标记	唯一位置
r 路组相联	唯一一组内 r 行	$\log_2(C/(Br))$	该组 r 个有效标记	组内
全相联	任一行	0	全部有效标记	全 Cache

命中须同时满足有效位为 1、标记匹配。组号用于选组，块内偏移用于选块中字节，二者均无需保存到每行标记。

固定地址位数、数据容量和块大小时，相联度增大使组号变短、标记变长，可能减少冲突缺失。强制缺失与容量限制仍存在。比较器数、布线、扇入和编码共同影响实际延迟，具体快慢需依据电路模型。

例 3-7

若计算机主存地址为 32 位，按字节编址，某 Cache 的数据区容量为 32 KB，主存块大小为 64 B，采用 8 路组相联映射方式，该 Cache 中比较器的个数和位数分别为（ ）。

A. 8，20　B. 8，23　C. 64，20　D. 64，23

Cache 总容量

$$\text{总位数} = L(8B + t + V + D + \cdots) + \text{替换状态位}.$$

V 为有效位，回写通常需脏位 D；替换位、校验位等按题设计入。给出的数据容量 C 与含标记和状态位的总容量分别使用。

32 位字节地址、4 KiB 数据区、16 B 块、2 路：偏移 4 位、组号 7 位、标记 21 位；含有效和脏位且暂不计替换位，每行 151 位。直接映射无需行间替换状态。

例 3-8

假定主存地址为 32 位，按字节编址，主存和 Cache 之间采用直接映射方式，主存块大小为 4 个字，每字 32 位，采用回写方式，则能存放 4 K 字数据的 Cache 的总容量的位数至少是（ ）。

A. 146 K　B. 147 K　C. 148 K　D. 158 K

3.10 Cache 替换与写策略

优先使用目标组空行；满组后在本组选择牺牲行。

策略	状态依据	命中更新
FIFO	装入先后	保持装入次序
LRU	最近使用次序	置为最近使用
LFU	累计使用频次	更新计数，初值及并列规则须给定
随机	随机选择	无需维护精确最近次序

两路一组访问 A、B、A、C、B，LRU 状态从最近到最久依次为 [A]、[B,A]、[A,B]、[C,A]、[B,C]，仅第 3 次命中。

4 行全相联、初始空，访问 $1,2,3,4,1,2,5,1,2,3,4,5$：FIFO 命中第 5、6 次；LRU 命中第 5、6、8、9 次。访问块 5 前，FIFO 淘汰 1，LRU 淘汰 3。

写命中、写缺失与脏块

事件与策略	动作
写命中，直写	同时更新 Cache 和下层，可用写缓冲；缓冲满时可能阻塞
写命中，回写	只更新 Cache 并置脏位，淘汰脏块时写回
写缺失，写分配	调块进入 Cache 再写
写缺失，非写分配	绕过当前 Cache，直接写下层

回写常配写分配、直写常配非写分配，具体组合按题设执行。干净块可直接淘汰；脏块需按回写规则保存。多核副本及 DMA 访问还需相应一致性机制。

3.11 虚拟存储、页表与 TLB

虚拟存储将进程虚拟地址映射为物理地址，支持部分内容驻留外存、隔离与保护。操作系统建立并维护映射、分配和换入换出；MMU 执行运行时地址转换及权限检查。TLB 命中路径可由硬件完成。

页大小 $P = 2^p$ B、虚址 v 位、物理地址 a 位：

$$\mathrm{VA} = \mathrm{VPN} \times P + d, \quad \mathrm{PA} = \mathrm{PPN} \times P + d,$$

VPN 为 $v - p$ 位，PPN 为 $a - p$ 位，页内偏移 d 原样保留。

TLB 是页表项的高速缓存。若 TLB 共 K 项、r 路、低位选组，组数 $G_T = K/r$，组号 $g_T = \log_2 G_T$ 位，TLB 标记为 $v - p - g_T$ 位；物理页框号位数由物理地址决定。

查找对象	保存内容	未命中或异常处理
TLB	页映射、权限等	未命中转页表，页面仍可能已驻留
页表	页框号、存在位、权限、管理状态	合法且未驻留时缺页；非法映射、保护失败分别处理
物理地址 Cache	主存数据块或指令块副本	未命中访问下一层，按策略调块

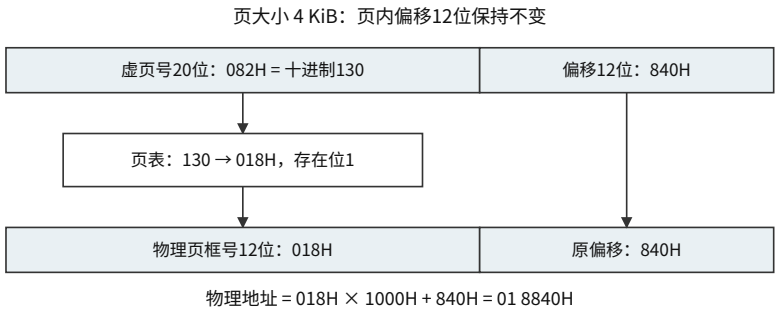


Figure 3.5: 虚页号查映射，页框号与原偏移形成物理地址

TLB 命中与 Cache 命中分别判断；页表存在位为 1 说明页面驻留，数据 Cache 仍可缺失。Cache 标记与页框号按各自字段求取。

例 3-9

某计算机主存地址为 24 位，采用分页虚拟存储管理方式，虚拟地址空间大小为 4 GB，页大小为 4 KB，按字节编址。某进程的页表部分内容如下。

虚页号	实页号（页框号）	存在位
82	024H	0
…	…	…
129	180H	1
130	018H	1

当 CPU 访问虚拟地址 0008 2840H 时，虚—实地址转换的结果是（　）。

A. 得到主存地址 02 4840H　　B. 得到主存地址 18 0840H
C. 得到主存地址 01 8840H　　D. 检测到缺页异常

例 3-10

某计算机按字节编址，采用页式虚拟存储管理方式，虚拟地址为 32 位，主存地址为 30 位，页大小为 1 KB。若 TLB 共有 32 个表项，采用 4 路组相联映射方式，则 TLB 表项中标记字段的位数至少是（　）。

A. 17　　B. 18　　C. 19　　D. 20

地址转换路径与平均时间

先转换、后查物理 Cache 的串行模型：拆 VPN、页内偏移 → 查 TLB → 未命中时查各级页表 → 检查存在位与权限 → 形成物理地址 → 查 Cache → 缺失时访问下层。

缺页时先处理并重试当前指令，普通数据 Cache 查找须等待可用映射。页表访问是否经过 Cache、TLB 与 Cache 能否并行均由题设决定。

单级页表、不计缺页、TLB 和主存串行且主存数据无 Cache 时，TLB 命中率 h_T、时间 t_T、每次主存访问 t_M：

$$\bar{t} = h_T(t_T + t_M) + (1 - h_T)(t_T + 2t_M).$$

多级页表增加相应查表访问；缺页需另加外存与操作系统处理时间。MMU 在地址转换中检测 TLB 缺失、缺页及权限问题，数据 Cache 缺失由 Cache 查找确定。

3.12 段式与段页式存储

段式地址含段号和段内偏移。段表保存基址、段长和权限；段长 L 表示字节数时，合法条件为 $0 \le d < L$，物理地址为 base+d，末字节地址为 base+$L-1$。

段页式先由段号定位该段页表，再由段内页号查页框，最后拼接页内偏移。段界限仍须检查，最后一页的填充空间可能超出段长。

段基址 10000 B、长 3000 B，偏移 2999 对应 12999 B；偏移 3000 越界。1 KiB 页的段页式模型中，页号 2、偏移 952 恰为段内 3000，也越界。

3.13 数组访问次序与 TLB、Cache 综合推演

行优先数组、每元素 w B、每行 C 个元素：addr$(a[i][j]) = A_0 + (iC + j)w$。先分别求触及页面、Cache 块和每组工作集，再计算缺页与命中数。

首地址偏移 d、连续区域长 n B、页或块大小 P 时，非空区域覆盖数为 $\lceil (d+n)/P \rceil$。每组工作集超过路数才存在相应组容量压力，总容量可容纳仍可能发生组冲突。

若 Cache 组选位全部落在页内偏移中，虚实转换保留这些位，可直接从虚址提取本题组号。超出页内偏移时需按指定地址模型取得相关物理位。

例 3-11

已知计算机 M 字长为 32 位，按字节编址，采用请求调页策略的虚拟存储管理方式，虚拟地址 32 位，页面大小为 4 KB；数据 Cache 采用 4 路组相联映射方式，数据区大小为 8 KB，主存块大小为 32 B。现有 C 语言程序段如下：

```
int a[24][64];
/* ... */
for (i = 0; i < 24; i++)
    for (j = 0; j < 64; j++) a[i][j] = 10;
```

已知二维数组 a 按行优先存放，在虚拟地址空间中分配的起始地址为 0042 2000H，`sizeof(int)=4`。假定在 M 上执行上述程序段之前数组 a 不在主存，且在该程序执行过程中不会发生页面置换。请回答下列问题。

(1) 数组分布在几个页面中？对于数组 a 的访问，会发生几次缺页异常？页故障地址各是什么？

(2) 不考虑变量 i 和 j，该程序段的数据访问是否具有时间局部性？为什么？

(3) 计算机 M 的虚拟地址（A31～A0）中哪几位用作块内地址？哪几位用作 Cache 组号？a[1][0] 的虚拟地址是多少？其所在主存块对应的 Cache 组号是多少？

(4) 数组 a 占用多少主存块？假设上述程序段执行过程中数组 a 的访问不会和其他数据发生 Cache 访问冲突，则数组 a 的 Cache 命中率是多少？若将循环中 i 和 j 的次序按如下方式调换，则数组 a 的 Cache 命中率又是多少？

```
for (j = 0; j < 64; j++)
    for (i = 0; i < 24; i++) a[i][j] = 10;
```

例 3-12

假设计算机 M 的主存地址为 24 位，按字节编址；采用分页存储管理方式，虚拟地址为 30 位，页大小为 4 KB；TLB 采用 2 路组相联方式和 LRU 替换策略，共 8 组。请回答下列问题。

(1) 虚拟地址中哪几位表示虚页号？哪几位表示页内地址？

(2) 已知访问 TLB 时虚页号高位部分用作 TLB 标记，低位部分用作 TLB 组号，M 的虚拟地址中哪几位是 TLB 标记？哪几位是 TLB 组号？

(3) 假设 TLB 初始时为空，访问的虚页号依次为 10、12、16、7、26、4、12 和 20，在此过程中，哪一个虚页号对应的 TLB 表项被替换？说明理由。

(4) 若将 M 中的虚拟地址位数增加到 32 位，则 TLB 表项的位数增加几位？

例 3-13

某系统按字节编址，虚拟地址为 14 位，物理地址为 12 位，页大小为 64 B。TLB 共 16 项，采用 4 路组相联；数据 Cache 使用物理地址，采用直接映射，共 16 行，每行 4 B。

按 “先完成地址转换，再查数据 Cache” 的串行模型分析。所有待访问的虚拟地址均合法，且允许读；页表存在位 $P = 1$ 表示页面已在主存，$P = 0$ 表示合法但尚未驻留，需要处理缺页。读 Cache 未命中时，从主存调入对应的 4 B 数据块。

以下给出本题所需的初始状态。表中页号、页框号、标记、Cache 行号和字节数据均用十六进制，后缀 H 表示十六进制；V 为有效位，“—” 表示没有可用信息。TLB 的组号和路号均在 0 至 3 之间。

表 A　TLB 初始状态

组号	路号	标记	有效位 V	页框号
0	0	03H	0	—
0	1	00H	0	—
0	2	09H	1	0DH
0	3	07H	1	02H
3	0	07H	0	—
3	1	0AH	1	34H
3	2	03H	1	0DH
3	3	02H	0	—

表 B　页表中与本题有关的表项

虚页号	存在位 P	页框号
03H	1	02H
08H	0	—

表 C　Cache 初始状态，数据按块内偏移排列

行号	标记	V	偏移 0	偏移 1	偏移 2	偏移 3
5H	0DH	1	36H	72H	F0H	1DH
CH	02H	0	—	—	—	—

（1）写出查 TLB 时虚拟地址的字段划分，以及查 Cache 时物理地址的字段划分，并求各字段位数。

（2）分别读取虚拟地址 03D4H、00F1H、0229H 处的一个字节，依次说明 TLB 查找、必要的页表检查和 Cache 查找，指出最终从哪里取数，或在哪一步转入异常处理。能确定字节值时给出结果。

三次访问相互独立，均从上述初始状态开始。某次访问引起的回填不影响另两次；不推演缺页后的页框分配与替换，也不计算访问时间。

指令系统与 C 程序的机器级表示 4

4.1 指令格式、地址字段与操作码扩展

指令由操作码、操作数/地址及寻址方式等字段组成。指令字长为编码位数，机器字长为整数处理的基本位宽，存储字长为一个存储单元的位数；三者分别确定。一个地址字段可表示寄存器编号、立即数、形式地址或位移。

格式	典型运算语义	隐含位置
三地址	$M[A_3] \leftarrow M[A_1] + M[A_2]$	由指令定义
二地址	$M[A_1] \leftarrow M[A_1] + M[A_2]$	一个源兼目的
一地址	ACC $\leftarrow$ ACC $+ M[A]$	累加器
零地址	弹出栈顶两项运算，再压入结果	栈顶、SP

地址字段数只计显式编码；实际操作数还包括隐含操作数。三地址运算若取指一次、源与目的均在主存，需取指 1 次、读源 2 次、写结果 1 次，共 4 次访存。多字指令、寄存器源、间接寻址分别改变对应次数。

固定操作码 k 位至多编码 2^k 种操作。扩展操作码逐层保留前缀：本层剩余 r 个前缀，下一段扩展 a 位，得到 $r2^a$ 个可分配编码；扣除已用编码后继续扩展。短操作码与更长操作码的前缀必须互斥。

16 位指令、地址字段 4 位：分配 15 条三地址后剩 1 个 4 位前缀；扩为 16 个 8 位码，分配 12 条二地址后剩 4 个；扩为 64 个 12 位码，分配 62 条一地址后剩 2 个；最终可分配 32 条零地址。指令总长始终 16 位。

例 4-1

设计某指令系统时，假设采用 16 位定长指令字格式，操作码使用扩展编码方式，地址码为 6 位，包含零地址、一地址和二地址 3 种格式的指令。若二地址指令有 12 条，一地址指令有 254 条，则零地址指令的条数最多为（ ）。

A. 0　B. 2　C. 64　D. 128

4.2 数据寻址、相对地址与访存次数

记形式地址 A、寄存器内容 (R)、存储单元内容 $M[x]$。表中读主存次数仅统计取得一个源操作数，取指与写回另计。

寻址方式	操作数或有效地址 EA	读主存次数
立即	操作数为指令内的立即数字段	0
直接	EA $= A$，操作数 $M[A]$	1
一次主存间接	EA $= M[A]$，操作数 $M[\text{EA}]$	2
寄存器	操作数 (R)	0
寄存器间接	EA $= (R)$	1
基址	EA $=$ (BR) $+$ 位移	主存源 1 次
变址	EA $= A +$ (IX)	主存源 1 次
相对	目标 $= \text{PC}_{base} + \text{sext}(\text{位移}) \times$ 缩放因子	按指令语义确定

间接寻址可利用比指令地址字段更宽的中间地址扩大寻址范围。基址寄存器通常存程序/数据段起点，支持重定位；变址寄存器通常存变化偏移，支持数组访问。位移的符号扩展和缩放按 ISA 规定。

按字节编址、int 占 4 B 时，addr$(a[i]) = \text{base} + 4i$。有比例变址可直接形成偏移；其他机器需先计算 $4i$。相对转移常取后继指令地址为基准，具体以题设 PC 更新时机为准。

例 4-2

某机器字长为 16 位，主存按字节编址，转移指令采用相对寻址，由两个字节组成，第一个字节为操作码字段，第二个字节为相对位移量字段。假定取指令时，每取一个字节 PC 自动加 1。若某转移指令所在主存地址为 2000H，相对位移量字段的内容为 06H，则该转移指令成功转移后的目标地址是（ ）。

A. 2006H　B. 2007H　C. 2008H　D. 2009H

无 Cache、无预取、指令与操作数各占一个存储字时，读取一个直接寻址源、一次主存间接源、寄存器间接源分别至少访存 2、3、2 次，均已计一次取指。32 位指令在 16 位存储字中跨两个字，取指所需访问次数按存储组织确定。

堆栈寻址隐含使用 SP。向低地址增长、SP 指向栈顶、每槽 4 B 的模型：push 为先 SP 减 4 再写，pop 为先读再 SP 加 4。初值 1000H，两次 push、一次 pop 后 SP=0FFCH。硬堆栈使用寄存器组，软堆栈使用主存，访存开销分别计算。

4.3 RISC、CISC 与指令副作用

维度	RISC 典型设计	CISC 典型设计
功能	常用简单操作，复杂操作由指令组合	丰富指令，可表达较复杂操作
编码与寻址	格式规整，常用定长，寻址方式较少	格式及寻址较多，常见变长
数据访存	Load/Store 访问数据，ALU 主要操作寄存器	多类指令可带主存操作数
寄存器与传参	通用寄存器较多，常用寄存器传参	传统设计寄存器较少，操作数来源丰富
控制与流水	常用硬布线，便于流水	复杂指令常用微程序，也可流水
编译	重视选指令、分配寄存器和调度	同样需要编译优化

表中为常见倾向。指令长度、寄存器数、控制器实现和调用约定须以具体 ISA、微架构和 ABI 为准；执行时间按指令数、CPI 及周期共同计算。

数据传送复制值；算术逻辑、移位指令产生新值并可能改标志；控制转移改变 PC；I/O 及系统控制可能涉及权限。每条指令的访存、改标志、特权等副作用依给定语义判断。

例 4-3

下列关于 RISC 的叙述中，错误的是（ ）。

A. 多采用硬连线方式实现控制器
B. 通常采用 Load/Store 型指令设计风格
C. 难以采用流水线数据通路实现微架构
D. 多采用寄存器传递过程调用时的参数

4.4 编译工具链与重定位

阶段	输入与主要结果
预处理	源文件 → 展开宏、包含文件等后的源程序
编译	高级语言 → 汇编表示
汇编	汇编表示 → 机器码目标文件，保留符号与重定位信息
链接	合并节、解析跨模块符号、修改地址引用 → 可执行文件

动态链接可将部分链接工作推迟至装入或运行时。目标/可执行文件可含符号表、调试、重定位和装入组织信息。优化后的变量可在寄存器中、成为常量或被消除。

例 4-4

将高级语言源程序转换为可执行目标文件的主要过程是（　）。

A. 预处理 → 编译 → 汇编 → 链接
B. 预处理 → 汇编 → 编译 → 链接
C. 预处理 → 编译 → 链接 → 汇编
D. 预处理 → 汇编 → 链接 → 编译

4.5 x86 操作数、有效地址与条件转移

32 位示例中 EAX、EBX、ECX、EDX 为通用寄存器，ESP 为栈顶、EBP 常作帧基址。AX 为 EAX 低 16 位，AL 与 AH 为最低、次低 8 位。

含义	Intel 格式：目的在前	AT&T 格式：源在前
立即数 5→EAX	`mov eax, 5`	`movl $5, %eax`
EBX→EAX	`mov eax, ebx`	`movl %ebx, %eax`
读取 32 位主存数	`mov eax, dword ptr [ebx+ecx*4+8]`	`movl 8(%ebx,%ecx,4), %eax`

AT&T 的 b、w、l 常表示 8、16、32 位。x86 比例因子可取 1、2、4、8。`lea` 仅计算有效地址表达式；`mov` 传数据；`cmp` 形成减法标志；`test` 形成按位与标志；后两者均不保存运算结果。`shl/sal` 左移，`shr` 逻辑右移，`sar` 符号扩展右移。

以 Intel 的 `cmp eax, ebx` 为例，标志来自 EAX−EBX：

关系	有符号条件	无符号条件
等于	ZF=1	ZF=1
小于	SF ≠ OF	CF=1
小于等于	ZF = 1 ∨ SF ≠ OF	CF=1 或 ZF=1
大于	ZF = 0 ∧ SF = OF	CF=0 且 ZF=0
大于等于	SF=OF	CF=0

`loop` 在 32 位计数约定下先 ECX 减 1，再按 ECX 是否非零决定转移；其标志副作用须依指令定义。

4.6 分支、循环与动态执行次数

还原控制流时标出初始化、条件、循环体、更新和回边。入口测试型 n 次循环通常测试 n+1 次；后测循环从循环体起步时通常至少执行一次。signed 与 unsigned 选择不同分支条件。

```
// R0=数组基址，R3=元素个数，元素4 B
R1 <- 0; R2 <- 0
TEST:
    if R1 >= R3 jump EXIT
    R4 <- R1 << 2
    R5 <- M[R0 + R4]
    R2 <- R2 + R5
    R1 <- R1 + 1
    jump TEST
EXIT:
```

R3=0 时不访问数组；R3=3 时访问偏移 0、4、8。指针遍历每次加 4，终止指针为 base+4R3。动态指令数、取指次数与数据访问次数按实际路径累计。

4.7 调用约定、栈帧和递归状态

调用需传参、保存返回位置、安排局部区、传回返回值。ISA 提供 call/ret 或链接寄存器等机制，ABI 规定参数位置、栈对齐、返回值及寄存器保存责任。

控制方式	后继地址	额外状态
顺序	当前地址 + 指令长度	按指令副作用更新
条件分支	条件成立取目标，否则取顺序后继	条件及目标
调用	被调入口	保存调用后的后继地址
返回	已保存的返回地址	恢复约定现场与栈

链接寄存器保存返回地址时，叶子函数可无需写主存；嵌套调用/递归在再次覆盖它前保存旧返回地址。调用者保存寄存器由调用者在调用前保存仍需使用的值；被调用者保存寄存器由被调过程修改前保存、返回前恢复。

向低地址增长、SP 指栈顶、槽 4 B、call 压入返回地址的模型：SP=1000H，返回地址 2004H；call 后 SP=0FFCH，M[0FFCH]=2004H；保存旧 FP 后 SP=0FF8H；分配 8 B 局部区后 SP=0FF0H；按逆序撤销后 SP 恢复 1000H。

32 位 x86 标准建帧示例：`push ebp; mov ebp, esp`，再减 ESP 分配局部区；返回前 `mov esp, ebp; pop ebp; ret`。整数返回值常在 EAX。

地址	标准建帧后的内容
`[ebp]`	旧 EBP
`[ebp+4]`	返回地址
`[ebp+8]`、`[ebp+12]`	前两个栈参数
`[ebp-4]` 等	局部变量

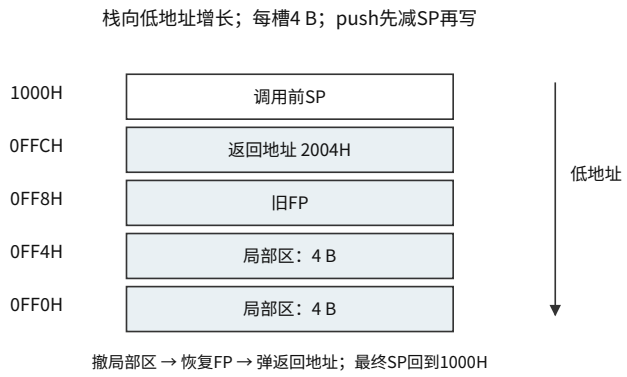


Figure 4.1: 调用、建立栈帧和返回时 SP 移动

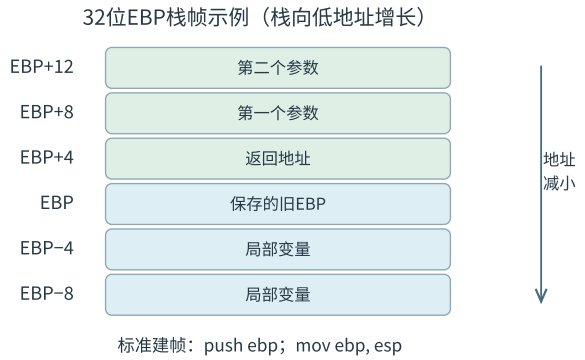


Figure 4.2: 32 位示例栈帧布局

具体布局以调用约定为准。递归每层保存独立参数、返回位置和局部状态；全局变量共享。递归空间按最大同时存活层数计算。

例 4-5

已知 $f(n) = n! = n \times (n-1) \times (n-2) \times \cdots \times 2 \times 1$，计算 $f(n)$ 的 C 语言函数 f1 的源程序及其在 32 位计算机 M 上的部分机器级代码如下。

```c
int f1(int n) {
    if (n > 1)
        return n * f1(n - 1);
    else
        return 1;
}
```

以下按“行号／虚拟地址／机器指令（字节按地址递增排列）／汇编指令”四列给出，每行是一条代码记录；省略行仍保留四列。

```
 1  00401000  55              push ebp
 …  …         …               …
11  00401018  83 7D 08 01     cmp dword ptr [ebp+8], 1
12  0040101C  7E 17           jle f1+35h (00401035)
13  0040101E  8B 45 08        mov eax, dword ptr [ebp+8]
14  00401021  83 E8 01        sub eax, 1
15  00401024  50              push eax
16  00401025  E8 D6 FF FF FF  call f1 (00401000)
 …  …         …               …
19  00401030  0F AF C1        imul eax, ecx
20  00401033  EB 05           jmp f1+3Ah (0040103A)
21  00401035  B8 01 00 00 00  mov eax, 1
 …  …         …               …
26  00401040  3B EC           cmp ebp, esp
 …  …         …               …
30  0040104A  C3              ret
```

其中，机器级代码行包括行号、虚拟地址、机器指令和汇编指令，计算机 M 按字节编址，int 型数据占 32 位。请回答下列问题。

（1）计算 f(10) 需要调用函数 f1 多少次？执行哪条指令会递归调用 f1？

（2）上述代码中，哪条指令是条件转移指令？哪几条指令一定会使程序跳转执行？

（3）根据第 16 行的 call 指令，第 17 行指令的虚拟地址应是多少？已知第 16 行的 call 指令采用相对寻址方式，该指令中的偏移量应是多少（给出计算过程）？已知第 16 行的 call 指令的后 4 字节为偏移量，M 采用大端方式还是小端方式？

（4）$f(13) = 6\,227\,020\,800$，但 f1(13) 的返回值为 1 932 053 504，为什么两者不相等？要使 f1(13) 能返回正确的结果，应如何修改 f1 的源程序？

（5）第 19 行的 imul 指令（带符号整数乘）的功能是 R[eax] $\leftarrow$ R[eax] $\times$ R[ecx]，当乘法器输出的高、低 32 位乘积之间满足什么条件时，溢出标志 OF=1？要使 CPU 在发生溢出时转异常处理，编译器应在 imul 指令后加一条什么指令？

5 中央处理器

5.1 CPU 功能、寄存器与状态元件

CPU 完成指令控制、操作控制、时间控制、数据加工及规定的异常/中断处理。数据通路完成数据传送和运算，控制部件 CU 生成选择、运算、写使能与存储器读写等控制信号。

部件	内容或作用	组织层次
ALU、MUX、移位器	按当前输入形成运算或选择结果	组合逻辑操作元件
GPRs、ACC、临时寄存器	操作数、地址、中间结果	状态元件
PC	程序执行位置，更新规则依 ISA 与时序	程序级状态
IR	当前指令编码	通常属实现内部
MAR	本次主存访问地址	通常属实现内部
MDR	本次与主存交换的指令或数据	通常属实现内部
PSW/FR	条件码及规定的特权、中断等状态	可见性与写权限依 ISA
CMAR、CMDR	微地址、当前微指令	微程序控制器内部

GPRs、PC 及规定的状态属于程序员可见模型；可见性与用户指令能否直接读写分别由 ISA 及权限定义。MAR 位数按可寻址单元数确定，MDR 位数按一次数据交换位宽确定。例如 26 位字节地址、32 位数据通路，可有 26 位 MAR 与 32 位 MDR。

例 5-1

数据通路由组合逻辑元件（操作元件）和时序逻辑元件（状态元件）组成。以下给出的元件中，属于操作元件的是（ ）。

I. 算术逻辑部件（ALU）　II. 程序计数器（PC）
III. 通用寄存器组（GPRs）　IV. 多路选择器（MUX）

A. 仅 I、II　B. 仅 I、IV　C. 仅 II、III　D. 仅 I、II、IV

5.2 指令周期与三种执行组织

指令周期覆盖一条指令从开始到完成；机器周期为某实现划分的访存等基本操作周期；时钟周期为同步状态推进的时间单位。三者倍数由具体组织给出。

指令阶段	动作	进入条件
取指	PC 给地址、读指令入 IR、更新 PC	每条指令
间址	取得有效地址	需要主存间接寻址等
执行	完成指令语义	每条指令，动作不同
中断	保存返回状态、进入处理入口	有请求且满足响应条件

组织	时钟约束	同一时刻与资源复用
单周期	最慢完整指令路径	一条指令占一长拍；同拍资源需求须同时满足
多周期	最慢基本步骤	一条指令分多拍；资源可跨拍复用
简单标量流水	最慢段 + 段寄存器开销	多条指令不同段重叠；同拍资源争用须消除

单周期 CPI=1、理想标量流水稳态 CPI 约 1，周期长度可不同。性能比较用执行时间 $N \times \mathrm{CPI} \times \tau$。

5.3 单总线数据通路与微操作时序

微操作是部件可执行的基本动作；微命令为驱动该动作的控制命令。同一内部总线每拍通常只允许一个驱动源，多个目的在有实际通路和独立写使能时可同时接收同一值。

ALU 一端由 Y 保存第一个操作数，另一端接总线；结果先存 Z，后续再上总线写回。例 $R_1 \leftarrow R_1 + R_2$：

拍	微操作
1	$R_1 \rightarrow Y$
2	$R_2 \rightarrow \mathrm{BUS}$，$Y + \mathrm{BUS} \rightarrow Z$
3	$Z \rightarrow R_1$

`R1→Y` 与 `R2→MAR` 同拍争用总线；`R1→Y` 与 `R1→MAR` 可同时接收。结果尚未产生、访存尚未完成时，目的寄存器应等待。

取指依赖：PC → MAR，主存读入 MDR，MDR → IR；指令地址字段需间接求址时，再送 MAR 并读出有效地址。PC 增量能否与访存并行取决于独立增量器、总线占用与图示通路。

例 5-2

某 CPU 中部分数据通路如下图所示，其中，GPRs 为通用寄存器组；FR 为标志寄存器，用于存放 ALU 产生的标志信息；带箭头虚线表示控制信号，如控制信号 Read、Write 分别表示主存读、主存写，MDRin 表示内部总线上数据写入 MDR，MDRout 表示 MDR 的内容送内部总线。

（1）设 ALU 的输入端 A、B 及输出端 F 的最高位分别为 A15、B15 及 F15，FR 中的符号标志和溢出标志分别为 SF 和 OF，则 SF 的逻辑表达式是什么？A 加 B、A 减 B 时 OF 的逻辑表达式分别是什么？要求逻辑表达式的输入变量为 A15、B15 及 F15。

（2）为什么要设置暂存器 Y 和 Z?

（3）若 GPRs 的输入端 rs、rd 分别为所读、写的通用寄存器的编号，则 GPRs 中最多有多少个通用寄存器？rs 和 rd 来自图中的哪个寄存器？已知 GPRs 内部有一个地址译码器和一个多路选择器，rd 应连接地址译码器还是多路选择器?

（4）取指令阶段（不考虑 PC 增量操作）的控制信号序列是什么？若从发出主存读命令到主存读出数据并传送到 MDR 共需 5 个时钟周期，则取指令阶段至少需要几个时钟周期?

（5）图中控制信号由什么部件产生？图中哪些寄存器的输出信号会连到该部件的输入端?

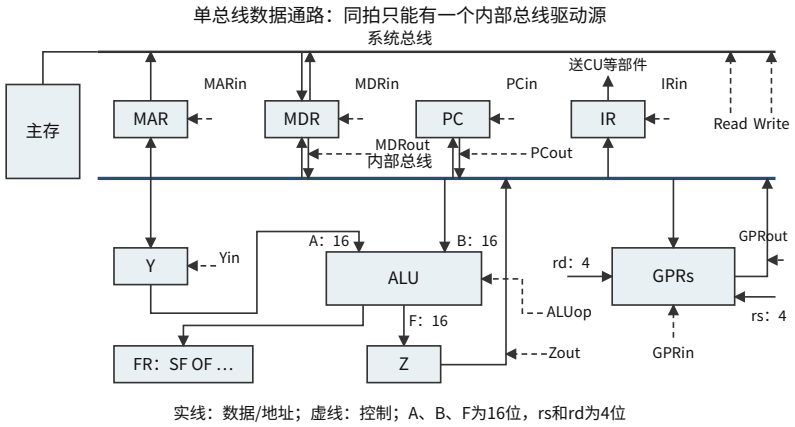


Figure 5.1: 单条内部总线连接 Y、ALU 与 Z；rs、rd 为 4 位寄存器编号

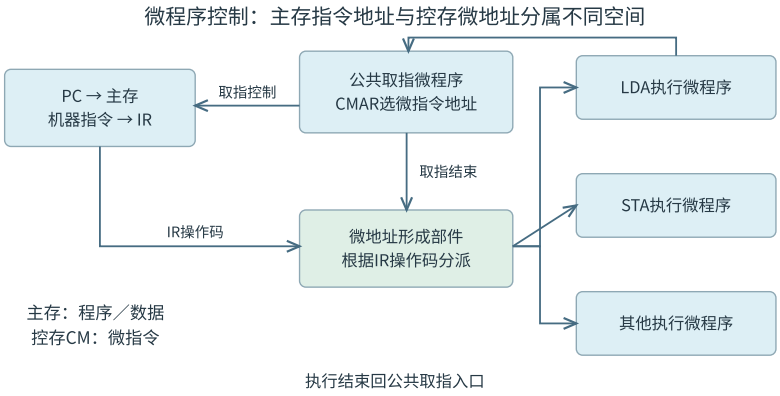


Figure 5.2: 取指入口、操作码映射和执行微程序

例 5-3

某指令功能为 $\mathrm{R}[r2] \leftarrow \mathrm{R}[r1] + \mathrm{M}[\mathrm{R}[r0]]$，其两个源操作数分别采用寄存器、寄存器间接寻址方式。对于下列给定部件，该指令在取数及执行过程中需要用到的是（ ）。

I. 通用寄存器组（GPRs） II. 算术逻辑单元（ALU）
III. 存储器（Memory） IV. 指令译码器（ID）

A. 仅 I、II B. 仅 I、II、III C. 仅 II、III、IV D. 仅 I、III、IV

5.4 硬布线与微程序控制器

维度	硬布线控制	微程序控制
控制信号来源	操作码、节拍、周期状态及标志经逻辑电路形成	控存微指令的控制字段直接或译码形成
常见特点	控制延迟较短；修改复杂功能需改逻辑	便于组织复杂控制；受控存与微周期开销影响
设计步骤	列微操作 → 排节拍 → 合成控制逻辑	列微操作/节拍 → 选编码与下址方式 → 分配控存 → 编微码

硬布线中某信号在指令 A 的 T_1 或指令 B 的 T_2 发生，可写 $C = A \cdot T_1 + B \cdot T_2$；加、乘分别为逻辑或、与，条件标志乘入相应项。

微程序对象	含义
机器指令	ISA 规定的一次软件可见操作
微程序	实现一条机器指令等功能的微指令序列
微指令	一个微周期的操作控制和顺序控制信息

控制字段编码	位数与并行性
字段直接编码	互斥微命令同组，各组可并行；含 k 条命令及空操作需 $\lceil \log_2(k+1) \rceil$ 位
字段间接编码	利用字段间依赖解释；进一步压缩并增加译码层次

水平型通常控制字较宽、并行微操作较多；垂直型编码较强、字短，可能需更多微指令；混合型折中。下微地址可来自下地址字段、顺序增量、操作码映射、条件测试或硬件强制入口。控存含 M 个可区分地址时，地址至少 $\lceil \log_2 M \rceil$ 位。

静态微程序通常固化于 ROM；动态微程序使用可改写控存；毫微程序在微指令之下再设解释层。修改能力取决于硬件支持。

例 5-4

某计算机的控制器采用微程序控制方式，微指令中的操作控制字段采用字段直接编码法，共有 33 个微命令，构成 5 个互斥类，分别包含 7、3、12、5 和 6 个微命令，则操作控制字段至少有（　）。

A. 5 位　B. 6 位　C. 15 位　D. 33 位

例 5-5

某计算机采用微程序控制器，共有 32 条指令，公共的取指令微程序包含 2 条微指令，各指令对应的微程序平均由 4 条微指令组成，采用断定法（下地址字段法）确定下条微指令地址，则微指令中下地址字段的位数至少是（　）。

A. 5　B. 6　C. 8　D. 9

5.5 异常、中断与返回断点

事件	检测与处理	常见返回位置
故障 fault，如缺页	当前指令未完成；修复后重试	当前指令起点
陷阱 trap，如系统调用	执行有意通知/服务请求	通常为后继位置
终止 abort	严重异常，通常无法可靠恢复	依体系结构
外部中断	设备、定时器等；通常在指令边界响应	下一条尚未执行指令

具体分类、保存 PC 及可恢复规则由 ISA 确定。硬件响应保存规定的断点与处理器状态、切换状态并进入入口；软件继续保存所需通用寄存器现场。“中断隐指令” 为硬件响应动作的教材称呼。中断服务程序为软件。

进入内核态后可返回原进程，也可由调度器切换进程；模式切换与上下文切换分开判断。

例 5-6

异常事件在当前指令执行过程中进行检测，中断请求则在当前指令执行后进行检测。下列事件中，相应处理程序执行后，必须回到当前指令重新执行的是（　）。

A. 系统调用　B. 页缺失　C. DMA 传送结束　D. 打印机缺纸

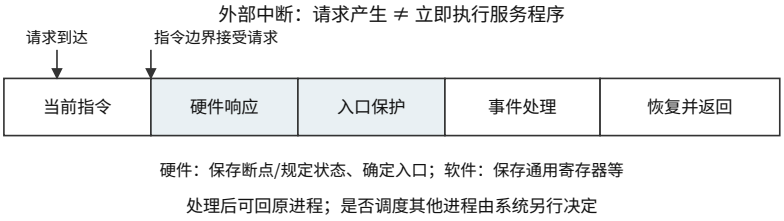


Figure 5.3: 外部请求、硬件入口与软件处理

5.6 流水线阶段、时钟与性能公式

阶段	典型工作
IF	取指
ID	译码、读源寄存器
EX	ALU 运算、计算有效地址
MEM	LOAD 读数据、STORE 写数据
WB	写回寄存器

ALU 结果在 EX 末形成，LOAD 数据通常在 MEM 末形成；STORE 通常无寄存器写回。固定五段题可要求所有指令流出五段后才计完成。阶段寄存器须携带数据、立即数、目的寄存器号、控制位、指令地址和必要异常信息。

冻结保持原有状态；气泡是不会改变有效状态的空操作。二者须配合写使能，避免重复写入或错误访存。

等时 k 段、时钟 τ、每拍启动一条、无冒险时：

$$T=(k+n-1)\tau,\quad \mathrm{TP}=\frac{n}{T},\quad S=\frac{nk}{k+n-1},\quad E=\frac{n}{k+n-1}.$$

S 以非流水每条耗 $k\tau$ 为基线；E 假定每条有效使用全部 k 段。实际有用面积、原机器周期不同须重新计算。整体延长 s 拍时，$T=(k+n-1+s)\tau$。$\tau \geq \max t_i + t_r$，t_r 为段寄存器开销；单条延迟约 $k\tau$，稳态完成间隔为 τ。

例 5-7

某计算机的指令流水线由四个功能段组成，指令流经各功能段的时间（忽略各功能段之间的缓存时间）分别为 90 ns、80 ns、70 ns 和 60 ns，则该计算机的 CPU 时钟周期至少是（　）。

A. 90 ns　　B. 80 ns　　C. 70 ns　　D. 60 ns

按层次分部件级、处理机级、处理机间流水；按功能分单/多功能；按同一时刻功能配置分静态/动态；按有无反馈分线性/非线性。动态流水线的功能分类与指令动态调度分别判断。

5.7 结构、数据与控制冒险

类别	冲突及处理
结构冒险	同拍争用不足的资源；停顿、加端口、分离指令/数据存储器
RAW 写后读	消费者需前指令新值；等待、转发、合法指令调度
WAR 读后写	后写覆盖尚未读取的旧值；重命名可消除名字冲突
WAW 写后写	两次写完成次序改变最终值；重命名、按序提交
控制冒险	条件或后继目标未定；阻塞、预测、合法调度

固定五段、顺序发射、ID 读且 WB 顺序写的简单模型通常只需处理 RAW；乱序或不同延迟写回可能产生 WAR/WAW。无条件转移在目标尚未获得时也可能造成控制冒险。

时序/旁路条件	消费者最早可用时刻
无转发，同寄存器不能同拍读写	ID 晚于生产者 WB 至少 1 拍
无转发，同拍先写后读	ID 可与生产者 WB 同拍
EX 结果向 EX 转发	生产者 EX 末产生，下一拍消费者 EX 可用
LOAD 的 MEM 结果向 EX 转发	消费者 EX 须晚于生产者 MEM；紧邻 load-use 常停 1 拍

转发仅能传已有结果；STORE 数据端、分支比较端是否有旁路须按图确认。硬件阻塞让前级保持、后级插气泡；编译调度只移动保持语义和副作用的指令。

例 5-8

下列指令序列中，指令 I1 和 I3、I2 和 I3 之间发生数据相关。假定采用“取指、译码/取数、执行、访存、写回” 五段流水线方式，那么在采用转发技术时，需要在指令 I3 之前加入（ ）条空操作指令才能使这段程序不发生数据冒险。

```
I1: add  r1, r0, 1    // R[r1] <- R[r0] + 1
I2: load r3, 12(r2)   // R[r3] <- M[R[r2] + 12]
I3: add  r5, r3, r1   // R[r5] <- R[r3] + R[r1]
```

A. 3　B. 2　C. 0　D. 1

例 5-9

在采用 “取指、译码/取数、执行、访存、写回”5 段流水线的 RISC 处理器中，执行如下指令序列，其中 s0、s1、s2、s3 和 t2 表示寄存器编号。

```
I1: add  s2, s1, s0  // R[s2] <- R[s1] + R[s0]
I2: load s3, 0(s2)   // R[s3] <- M[R[s2] + 0]
I3: beq  t2, s3, L1  // if R[t2] = R[s3] jump to L1
I4: addi t2, t2, 20  // R[t2] <- R[t2] + 20
I5: L1: ...
```

若采用转发（旁路）技术处理数据冒险，采用硬件阻塞方式处理控制冒险，则在指令 I1～I4 的执行过程中，发生流水线阻塞的指令有（ ）。

A. 仅 I3　B. 仅 I2、I4　C. 仅 I3、I4　D. I2、I3、I4

分支预测错误时清除错误路径结果并重新取指。若分支比例为 f_b、误判率 p_m、每次损失 d 拍，且无重复计费，则 $\mathrm{CPI} = \mathrm{CPI}_0 + f_b p_m d$。

5.8 多发射、动态调度与精确异常

技术	并行方式与约束
超标量	每周期可发射多条；实际吞吐受依赖、资源、分支及带宽约束
超流水	细分阶段以缩短周期；寄存器及冒险开销限制收益
VLIW	编译器将可并行操作打包到长指令；需要相应硬件支持
动态调度	后续就绪指令可先执行，减少长延迟造成的空闲
寄存器重命名	新逻辑写分配不同物理寄存器，消除 WAR/WAW 假相关；RAW 保留
按序提交	保持软件可见结果符合程序顺序，支持精确异常

最大发射宽度 w 给出理想每拍最多完成 w 条的上限，程序速度仍须按实际 CPI 与周期计算。

5.9 Flynn 分类、硬件线程与共享内存

分类	指令流/数据流	典型组织
SISD	单/单	传统单指令流执行
SIMD	单/多	向量处理器，同类操作处理多个数据
MISD	多/单	按定义识别
MIMD	多/多	多核、多处理器、多计算机

向量执行有启动开销，长向量利于摊薄；分支发散可能降低利用率。SMP 中处理器地位对等，共享单一物理地址空间，各自寄存器及部分 Cache 可私有。多计算机各有私有主存，通过消息通信。

硬件多线程	线程选择粒度
粗粒度	长延迟事件时切换，可付清空与重填代价
细粒度	按周期等较细粒度交替，每拍选择一个线程，可从该线程发多条
SMT	同一拍从多个线程选择就绪指令，共享执行槽

硬件线程需分别保存体系结构状态，可用于单核；多核为单芯片集成多个执行核。单线程加速、功耗和线程数均依实现及负载确定。共享物理地址空间还需要原子操作、同步、Cache 一致性和存储顺序约束。

例 5-10

下列关于并行处理技术的叙述中，不正确的是（　）。

A. 多核处理器属于 MIMD 结构
B. 向量处理器属于 SIMD 结构
C. 硬件多线程技术只可用于多核处理器
D. SMP 中所有处理器共享单一物理地址空间

例 5-11

某 16 位计算机中，带符号整数用补码表示，数据 Cache 和指令 Cache 分离。下面给出了指令系统中部分指令的汇编格式及对应功能，其中 Rs 和 Rd 表示寄存器，mem 表示存储单元地址，(x) 表示寄存器 x 或存储单元 x 的内容。

```
ADD   Rs, Rd
SHL   Rd
SHR   Rd
LOAD  Rd, mem
STORE Rs, mem
```

上面每行给出一种汇编格式；下表逐项给出各助记符对应的名称和功能，不改变源、目的操作数的次序。

名称	助记符	指令功能
加法	ADD	(Rs) + (Rd) → Rd
算术/逻辑左移	SHL	2(Rd) → Rd
算术右移	SHR	(Rd)/2 → Rd
取数	LOAD	(mem) → Rd
存数	STORE	(Rs) → mem

该计算机采用 5 段流水方式执行指令，各流水段分别是取指 IF、译码/读寄存器 ID、执行/计算有效地址 EX、访问存储器 M 和结果写回寄存器 WB。流水线采用 “按序发射、按序完成” 方式，没有采用转发技术处理数据相关，并且同一个寄存器的读和写操作不能在同一个时钟周期内进行。请回答下列问题。

(1) 若 int 型变量 x 的值为 −513，存放在寄存器 R1 中，则执行指令 SHR R1 后，R1 的内容是多少（用十六进制表示)?

(2) 若某个时间段中有连续 4 条指令进入流水线，在其执行过程中没有发生任何阻塞，则执行这 4 条指令需要多少个时钟周期?

(3) 若赋值语句为 x=a+b，x、a、b 均为 int 型变量，其存储单元地址分别为 [x]、[a]、[b]。对应指令序列及流水过程如下，I3 的 ID 段和 I4 的 IF 段被阻塞的原因各是什么?

```
I1  LOAD  R1, [a]
I2  LOAD  R2, [b]
I3  ADD   R1, R2
I4  STORE R2, [x]
```

指令	成功推进的阶段与周期	因依赖或前级冻结而等待
I1	IF1，ID2，EX3，M4，WB5	无
I2	IF2，ID3，EX4，M5，WB6	无
I3	IF3，ID7，EX8，M9，WB10	第 4～6 拍在 ID 端等待
I4	IF7，ID11，EX12，M13，WB14	第 4～6 拍未获准取指；第 8～10 拍在 ID 端等待

上表将原图时空格紧凑写成 “阶段名 + 周期数”，另列等待状态：I3 第 4～6 拍在 ID 端等待，I4 第 4～6 拍尚未获准取指，第 8～10 拍又在 ID

端等待；这些等待状态保留了原图中的阻塞信息；其他未列时刻表示该指令尚未进入或已经离开流水线。

（4）若赋值语句为 `x=x*2+a`，x 和 a 均为 unsigned int 型变量，其存储单元地址分别为 [x]、[a]，执行这条语句至少需要多少个时钟周期？要求模仿上图，画出对应指令序列及流水线执行过程示意图。

6 总线

6.1 总线组成、特性与连接结构

总线是多个部件分时共享的信息传输线路及配套协议。每次事务由主设备发起，从设备按地址响应；CPU、取得使用权的 DMA 控制器均可作主设备。读事务的数据由从设备给出，写事务的数据由主设备给出。

信息组	作用与传送内容
地址总线	指定存储单元或 I/O 端口，宽度影响地址组合数
数据总线	传指令、操作数、状态字、命令字、中断类型号等编码值
控制总线	规定读写、有效时刻、请求、应答及状态

写控制端口时，命令字可经数据线传输，控制线说明读写性质。地址的驱动者由当前主设备决定。可寻址容量还需结合编址单位计算；数据线数决定一次并行数据量。

总线特性	规范内容
机械	连接器、尺寸、形状、引脚布局
电气	电平、电压、负载等
功能	每根信号线的意义
时间	建立、采样、保持与撤销关系

分类维度	类别及特点
位置/用途	片内总线；连接 CPU、主存、I/O 接口的系统总线；系统/设备间通信总线
数据传送	串行逐位发送；并行多线同拍传多位
连接结构	单总线共享，结构简单、争用集中；双/三/多总线分离主存及 I/O 等流量
桥接	缓冲数据、转换协议、协调控制与速率

多总线可减少争用，并增加连接与控制成本；跨桥及主存带宽仍可成为瓶颈。并行的线间偏斜、串扰及接插件复杂度限制频率和距离；高速串行可用多条 lane 并行传包。具体总线时钟及速度分别确定。

6.2 位宽、传送率、峰值与有效带宽

设每次有效数据 W 位，每秒 R 次传送，时钟频率 f、每周期传 a 次：

$$B_{\text{peak}} = R\frac{W}{8} = af\frac{W}{8} \quad (\text{B/s}).$$

MHz 为每秒时钟次数，MT/s 为每秒数据传送次数；已给 MT/s 时直接作 R。总线周期为一次规定操作的时间，可能占多拍。若每事务有效载荷 Q B、实际耗时 T，则 $B_{\text{eff}} = Q/T$，分母应含相应地址、等待、仲裁等开销。

计算对象	分子/分母
峰值带宽	数据节拍的有效载荷/数据节拍时间
事务有效带宽	一次事务有效载荷/事务总历时
设备速率	设备产生或消耗的数据/时间
CPU 占用	CPU 执行查询、服务、设置收尾的时间/总时间

校验位、包头等按题设从载荷中扣除；多通道仅在可并行且负载允许时相加；全双工分别计算单方向与双向合计。端到端持续吞吐受最慢环节限制。

例 6-1

假设某系统总线在一个总线周期中并行传输 4 B 信息，一个总线周期占用 2 个时钟周期，总线时钟频率为 10 MHz，则总线带宽是（ ）。

A. 10 MB/s　B. 20 MB/s　C. 40 MB/s　D. 80 MB/s

例 6-2

某 64 位并行总线每时钟周期传 4 次数据，实际数据传送率已明确给为 1333 MT/s，求单方向理想峰值带宽。若改给的是 333.25 MHz 时钟频率，结果是否相同?

32 位、100 MHz、每拍两次时，峰值 $4 \times 2 \times 100 \times 10^6 = 800$ MB/s。32 位、每秒 33×10^6 次有效传送时为 132 MB/s。

6.3 总线事务与突发传送时间

一次事务通常经过申请/分配、寻址、传输、结束。读操作：主设备发地址和读命令 → 从设备译码与准备 → 从设备给出有效数据 → 主设备采样 → 结束。写操作由主设备提供写数据。

地址/数据复用线路须分时使用；独立地址、数据线允许的重叠依协议确定。突发传送给一个首地址后连续传多个相邻数据，摊薄地址与启动开销；非突发按每个数据分别计地址、准备及传送。

模型	n 个数据的总时间（无额外重叠）
非突发，每数据均付启动	$n(t_a + t_p + t_d)$
突发，只付一次启动	$t_a + t_p + n t_d$

主存准备是否每字重复、是否可流水/重叠须按题设确认。

例 6-3

某存储器总线宽度为 64 位，总线时钟频率为 1 GHz，在总线上传输一个数据或地址需要一个时钟周期，不支持突发传送方式。若通过该总线连接 CPU 和主存，主存每次准备一个 64 位数据需要 6 ns，主存块大小为 32 B，则读取一个主存块所需的时间是（ ）。

A. 8 ns　B. 11 ns　C. 26 ns　D. 32 ns

例 6-4

某存储器总线的时钟频率为 420 MHz，总线宽度为 64 位，每个时钟周期传送 2 次数据；其总线事务支持突发传送方式，最多传送 8 次数据，第 1 个时钟周期传送地址和读/写命令，从第 4 个至第 7 个时钟周期连续传送 8 次数据。该总线的总线带宽（最大数据传输率）为（ ）。

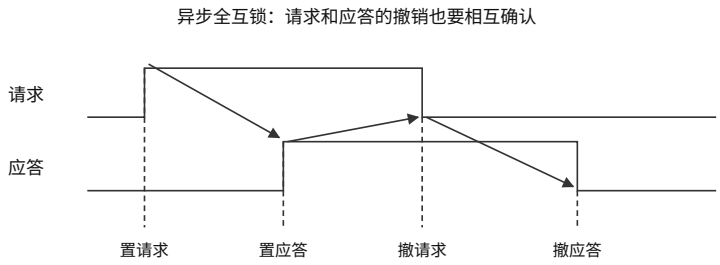


Figure 6.1: 全互锁握手的建立与撤销顺序

A. 3.84 GB/s　B. 6.72 GB/s　C. 30.72 GB/s　D. 53.76 GB/s

50 MHz 同步总线：传 8 个 4 B 字，1 拍地址 +3 拍等待 +8 拍数据，共 12 拍 =240 ns，有效速率约 133.3 MB/s。每个字独立占 1+3+1 拍时，共 40 拍 =800 ns，有效速率 40 MB/s。

等待期间若保持总线占有权，等待计入总线资源占用；若释放总线，总历时与占用时间分别累计。DMA 的总线占用与 CPU 开销分别计算。

6.4 同步、异步与半同步定时

定时	推进依据	时序条件
同步	共同的时钟边沿	周期容纳传播、译码、准备及建立时间；慢设备可插等待
异步	请求/应答等握手	各步按规定建立和撤销信号，适应速度差异
半同步	时钟加等待/应答	按规定边沿采样，慢设备请求延长准备阶段

异步握手按撤销信号是否等待对方确认分类：

类型	主设备撤请求	从设备撤应答
不互锁	发送后按预定时间撤销	按预定时间撤销
半互锁	等应答出现后撤销	按预定时间撤销
全互锁	等应答出现后撤销	等请求撤销后撤销

全互锁四阶段：请求置位 → 应答置位 → 请求撤销 → 应答撤销。建立和释放均相互确认，增加相应握手等待。

读时序图须标明：有效电平、地址稳定、读写命令有效、数据有效、采样点及事务起止。低有效信号以低电平为有效，重叠动作按协议判断。

串行异步字符帧需计起始、数据、校验、停止位。例如 7 数据 +1 校验 +1 起始 +1 停止 =10 位/字符；480 字符/s 对应线路 4800 bit/s、有效数据 3360 bit/s。

6.5 仲裁优先级与分离事务

仲裁决定多个主设备中谁获使用权；定时决定信号何时有效和事务何时推进。优先级给出先后关系，公平性衡量低优先级请求能否长期得到服务。

集中式仲裁	选择机制	特点
链式查询	允许信号沿链传播	控制线少；靠近仲裁器者通常优先，链路故障敏感，低位可能长期等待
计数器定时查询	输出设备编号，请求者比较匹配	起始编号、循环规则可改变优先级与公平性
独立请求	各设备独立请求/允许	响应快、优先级灵活；线路和逻辑开销较大

按公共请求、忙、允许的教材计线口径：n 设备链式 3 条；计数器式 $\lceil \log_2 n \rceil + 2$ 条；独立请求式每设备请求/允许加公共忙，$2n+1$ 条。8 设备独立请求为 17 条。计算先确认公共信号是否计入。

分布式仲裁由各参与者按共同规则竞争或判定使用权。分离事务将请求和响应分两次占用总线：发请求后释放，准备好再申请返回结果；需用标识与排队机制匹配请求/响应。它可与同步/异步定时组合，总历时可大于总线实际占用时长。

6.6 常见总线和接口标准

标准	组织与主要对象
ISA/EISA	早期 PC 并行扩展总线
VESA 局部总线	早期显示等高速局部外设
PCI	共享并行局部总线，支持总线主控、突发和配置
AGP	历史图形加速接口
PCI Express	点到点串行、多 lane、全双工
USB	主机与外设串行连接，支持集线器、即插即用、热插拔
SATA	串行存储接口
SCSI	设备寻址、命令与控制的接口体系
RS-232	串行通信连接、电平与信号规范
PCMCIA/CardBus	历史便携设备卡式扩展

代际、lane 数、编码效率、包头与方向共同决定载荷带宽；具体版本标称值须按题给条件使用。DDR 每周期在两个边沿传数据，已给传送率时直接按该传送率计算。

7 输入/输出系统

7.1 外部设备、显示存储与缓冲

I/O 硬件包括设备、接口/控制器及连接通路；软件包括驱动与上层管理程序。输入设备将外界信息采样编码，输出设备将编码转换成显示、声音或纸面记录，外存提供持久保存。

设备	基本机制或参数
键盘、鼠标	按键扫描编码，位移和按键形成报告
扫描仪、摄像设备	光学信息采样编码
显示器	屏幕尺寸、分辨率、每像素位数、刷新频率
针式打印机	撞针经色带成像，可用于多联复写
喷墨打印机	喷墨滴成像
激光打印机	感光鼓成像、转印、定影

分辨率 $W \times H$、每像素 b 位、刷新率 f 时，无压缩有效像素量：

$$Q_{\text{frame}} = \frac{WHb}{8}\ \text{B}, \qquad R_{\text{pixel}} = \frac{WHbf}{8}\ \text{B/s}.$$

双缓冲容量为两帧，实际输出率按刷新频率计算。字模库存每种字符点阵，帧缓冲存当前画面像素；消隐、编码、包头与压缩按题设计入。1920×1080、24 位、60 帧/s：单帧 6220800 B，双缓冲 12441600 B，有效速率 373248000 B/s。

接口缓冲吸收瞬时速率差；持续输入高于长期消耗能力时，有限缓冲终会填满。

7.2 I/O 接口、端口、编址与通道

接口连接系统总线与设备，承担设备选择、地址识别、命令译码、数据缓冲、状态记录、串并转换、速度匹配，以及中断/DMA 请求。端口是 CPU 可访问的接口寄存器或地址位置，一个接口通常包含多个端口。

端口	内容与操作
数据	读已接收数据、写待发送数据
状态	读就绪、忙、错误等状态
控制	写启动、复位、工作方式等命令

状态读与控制写可共享地址并由读写方向区分。端口地址定位接口位置，扇区地址定位设备内部数据。命令字、状态字、中断类型号均可经数据线传送；读写等控制线规定事务性质。

例 7-1

下列选项中，在 I/O 总线的数据线上传输的信息包括（　）。

I. I/O 接口中的命令字　II. I/O 接口中的状态字　III. 中断类型号

A. 仅 I、II　B. 仅 I、III　C. 仅 II、III　D. I、II、III

编址	地址空间	访问方式
统一编址/存储器映射 I/O	与主存共用；译码须区分内存和设备区域	普通访存指令
独立编址	单独 I/O 空间；同数值可各对应内存和端口	通常用专门 I/O 指令

接口与设备交换数据、命令和状态；接口向 CPU 提出中断请求。通道为执行通道程序的专用 I/O 处理部件，CPU 启动后由其组织系列设备操作；通道指令由通道执行，I/O 指令由 CPU 执行。DMA 主要搬运设定数据块，通道可承担更完整控制组织。

7.3 程序查询与服务期限

查询流程：设置命令、地址与数量 → 检查状态 → 就绪后 CPU 读/写数据端口 → 更新地址和计数 → 完成或继续。忙等查询持续检查，等待及搬运均占 CPU；定时查询在两次检查间可运行其他程序。

设设备速率 R B/s、缓冲/每次交换 q B，持续到达且每次取走一缓冲时：

$$\Delta t_{\text{buffer}} = \frac{q}{R}, \qquad \lambda = \frac{R}{q}\ \text{次/s}, \qquad U_{\text{CPU}} = \lambda t_{\text{service}}.$$

查询与取数必须在缓冲覆盖前完成；单缓冲的服务间隔至多为 q/R，还须将服务时长、相位及最长延迟纳入期限。已给每次服务 c 个周期、主频 f 时，$U = \lambda c/f$；已给 I 条指令时，$c = I \times \text{CPI}$。

例 7-2

某计算机处理器主频为 50 MHz，采用定时查询方式控制设备 A 的 I/O，查询程序运行一次所用的时钟周期数至少为 500。在设备 A 工作期间，为保证数据不丢失，每秒需对其查询至少 200 次，则 CPU 用于设备 A 的 I/O 的时间占整个 CPU 时间的百分比至少是（　）。

A. 0.02%　　B. 0.05%　　C. 0.20%　　D. 0.50%

50 MHz、每次查询 100 周期：鼠标每秒 30 次占 0.006%；磁盘 2 MiB/s、每次 4 B 需 2^{19} 次/s，占约 104.86%，说明该组织服务能力不足。查询开销已包含搬运时，搬运费用只计一次。

7.4 中断响应、现场与返回

中断 I/O 流程：CPU 启动设备 → 执行其他程序 → 设备/接口发请求并用触发器保留 →CPU 在允许边界判定未屏蔽请求 → 硬件响应 → 服务程序搬运与处理 → 恢复返回。请求产生、允许响应、开始处理及完成分别计时。

环节	典型动作
硬件响应	暂时禁止相应中断、保存断点和规定状态、定位入口
软件入口	保存将修改且须恢复的通用寄存器及旧屏蔽字
服务主体	读写数据端口、处理事件、设置控制信息
软件退出/返回	关中断、恢复现场与屏蔽字、按 ISA 规则恢复断点和状态

中断向量为定位入口的信息，向量地址为保存向量的位置，处理程序入口为代码地址，具体映射由实现规定。单重中断在处理期间关闭相应可屏蔽中断。多重中断在现场保护和屏蔽设置完成后开放允许的嵌套。

教材单重序列常写“保护现场 → 事件处理 → 恢复现场 → 开中断 → 中断返回”；实际 ISA 也可由返回指令原子恢复状态与允许位。非屏蔽中断的响应时点及保存规则仍由体系结构规定。

7.5 中断判优、屏蔽字与嵌套

响应优先级由硬件在当前未屏蔽请求中选谁先响应；处理优先级规定服务程序间谁可打断谁，通过屏蔽字组织。屏蔽改变可参与响应的集合，保留已经发生的请求记录。

按屏蔽位 1= 禁止、0= 允许的约定，服务程序通常屏蔽本级及不允许打断它的源，只开放更高处理优先级。每层进入时保存旧屏蔽字，退出时恢复上一层状态。

例 7-3

有 A、B、C 三个请求源，硬件响应优先级 A>B>C。屏蔽字按 A、B、C 排列，1 表示屏蔽。要求处理优先级 C>B>A，服务程序均在保存现场并设置屏蔽字后开中断。给出三者的屏蔽字，并追踪三请求同时待处理时的一次嵌套过程。

请求的到达时间、屏蔽状态、嵌套关系和服务时长共同决定开始及完成顺序。初始响应按硬件优先级，嵌套返回按栈顺序。

例 7-4

若某设备中断请求的响应和处理时间为 100 ns，每 400 ns 发出一次中断请求，中断响应所允许的最长延迟时间为 50 ns，则在该设备持续工作过程中，CPU 用于该设备的 I/O 时间占整个 CPU 时间的百分比至少是（　）。

A. 12.5%　　B. 25%　　C. 37.5%　　D. 50%

允许响应的最长延迟为期限；CPU 占用只计实际响应/服务执行时间。每 400 ns 请求一次、服务 100 ns，CPU 占 25%；允许延迟 50 ns 另作实时性约束。

7.6 DMA 控制器、传送阶段与访存方式

DMA 由控制器在设备接口与主存之间直接传数据。典型组成：主存地址寄存器/计数器、传送长度计数器、数据缓冲寄存器、设备地址、请求触发器、控制/状态逻辑及完成中断机构。

阶段	执行主体与动作
预处理	CPU 驱动设置方向、主存起址、设备、长度等参数并启动
数据传送	设备准备 → 请求 DMA→DMA 申请总线 → 授权后传送 → 更新地址和计数
后处理	块结束/出错通知 CPU，软件检查结果、处理错误、唤醒后续工作

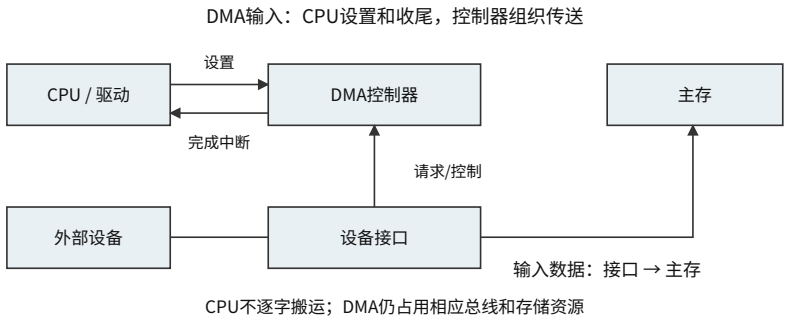


Figure 7.1: CPU 设置收尾，DMA 在接口与主存间搬运

DMA 访存方式	占用与 CPU 行为
停止 CPU 访存/成组传送	集中占用相关总线，期间 CPU 所需同资源访存受阻
周期挪用	准备好一个/若干单位后借用存储周期，通常让已开始 CPU 访存先完成
交替访存	CPU 与 DMA 按固定时隙分配，减少重复仲裁，需组织时序

DMA 占用共享资源时，CPU 可在可用寄存器、Cache 或其他独立资源上继续；停顿由实际资源需求决定。设备向 DMA 请求服务、DMA 向系统申请总线为两层请求；DMA 申请与请求 CPU 运行服务程序的中断分别判断。

例 7-5

若设备采用周期挪用 DMA 方式进行输入和输出，每次 DMA 传送的数据块大小为 512 字节，相应的 I/O 接口中有一个 32 位数据缓冲寄存器。对于数据输入过程，下列叙述中，错误的是（ ）。

A. 每准备好 32 位数据，DMA 控制器就发出一次总线请求
B. 相对于 CPU，DMA 控制器的总线使用权的优先级更高
C. 在整个数据块的传送过程中，CPU 不可以访问主存储器
D. 数据块传送结束时，会产生 “DMA 传送结束” 中断请求

例 7-6

下列关于 DMA 方式的叙述中，正确的是（ ）。

I. DMA 传送前由设备驱动程序设置传送参数
II. 数据传送前由 DMA 控制器请求总线使用权
III. 数据传送由 DMA 控制器直接控制总线完成
IV. DMA 传送结束后的处理由中断服务程序完成

A. 仅 I、II　B. 仅 I、III、IV　C. 仅 II、III、IV　D. I、II、III、IV

7.7 查询、中断和 DMA 的开销预算

设持续设备速率 R B/s、每次数据交换 q B、每块 Q B、每次 CPU 服务 t s、每块预后处理 u s、每数据单位占总线 b s：

量	计算式	条件
查询/中断事件率	R/q	每次交换 q B
查询/中断 CPU 比例	$(R/q)t$	服务开销均已计入

量	计算式	条件
DMA 完成事件率	R/Q	每块正常完成通知一次
DMA 软件 CPU 比例	$(R/Q)u$	预处理及后处理按块计
数据总线占用比例	$(R/q)b$	单位传输不重叠，无额外未计开销

CPU 预算与总线预算分别核算。比例大于 1 表示处理能力不足；平均 CPU 开销低于 100% 后，还需核最长响应时间及缓冲期限。多级缓冲、批量中断、突发合并等条件改变事件粒度时，重新计数。

方式	CPU 介入	搬运主体
忙等查询	连续检查、逐单位搬运	CPU 指令
定时查询	定期查询并搬运	CPU 指令
中断 I/O	每请求响应后运行服务程序	CPU 指令
DMA	每块设置、完成后收尾	DMA 控制器

字符等低速设备常用查询/中断，大批量块传送常用 DMA；选择依速率、粒度、缓冲和实现。512 B 块、4 B 缓冲为 128 次数据单位传送，正常完成通知一次。1024 B 块则为 256 次 4 B 单位；总线事务数还取决于突发合并。

例 7-7

假定计算机的主频为 500 MHz，CPI 为 4。现有设备 A 和 B，其数据传输率分别为 2 MB/s 和 40 MB/s，对应 I/O 接口中各有一个 32 位数据缓冲寄存器。请回答下列问题，要求给出计算过程。

（1）若设备 A 采用定时查询 I/O 方式，每次输入/输出都至少执行 10 条指令。设备 A 最多间隔多长时间查询一次才能不丢失数据？CPU 用于设备 A 输入/输出的时间占 CPU 总时间的百分比至少是多少？

（2）在中断 I/O 方式下，若每次中断响应和中断处理的总时钟周期数至少为 400，则设备 B 能否采用中断 I/O 方式？为什么？

（3）若设备 B 采用 DMA 方式，每次 DMA 传送的数据块大小为 1000 B，CPU 用于 DMA 预处理和后处理的总时钟周期数为 500，则 CPU 用于设备 B 输入/输出的时间占 CPU 总时间的百分比最多是多少？

1 MB/s、每中断 4 B、CPU 开销 2 μs，需 50% CPU；改为 1024 B 块、每块 CPU 开销 20 μs，约 1.953%。两值均仅计软件执行，另核总线占用和服务期限。

7.8 设备准备与服务执行的重叠时间

计算总历时先标出 “启动下一单位” 的时刻，CPU 占用累计实际响应和服务指令。CPU 50 MHz、CPI=4；每字符设备准备 0.5 ms=25000 周期；每字符 10 线路位（1 起始、7 数据、1 校验、1 停止），持续设备最多 2000 字符/s。

若每中断响应 10 周期，服务 20 条指令，第 15 条启动下一字符，则后 5 条服务指令可与下一次准备重叠。稳定重复间隔为 $25000+10+15\times4=25070$ 周期；1000 字符约 25070000 周期，CPU 实际用 $1000(10+20\times4)=90000$ 周期。

若从首次启动准备计到第 1000 次服务完全结束，最后 5 条无后续准备可重叠，精确总历时为 $1000\times25070+5\times4=25070020$ 周期。