计算机系统与程序执行的层次 1

1.1 系统组成与五大功能部件

计算机系统由硬件和软件组成。主机通常包含 CPU 与主存；CPU 包含运算器、控制器和寄存器。辅存、输入设备、输出设备合称外部设备。功能部件与物理芯片的划分可不同，一个 CPU 芯片可集成多个核、Cache 和存储控制器。

功能部件	基本任务	典型状态或部件
运算器	算术、逻辑与移位运算	ALU、操作数与结果寄存器
控制器	取指、译码、产生控制信号、决定后继指令	PC、IR、控制逻辑
存储器	按地址保存指令与数据	主存保存执行所需内容，辅存提供大容量非易失空间
输入设备	将外部信息转换成机器能处理的形式	经接口输入程序和数据
输出设备	将内部结果转换成外部所需形式	经接口输出数据

CPU 数据通路包括寄存器、运算部件及其连接；控制器决定数据流向和操作时刻。早期冯·诺依曼机以运算器为中心，现代组织通常以存储器为中心，外设可经接口、总线和 DMA 与主存交换数据。

1.2 存储程序与指令执行

存储程序：执行前将指令和数据存入存储器，运行时自动取指、译码、执行。指令与数据均为二进制位串，其用途由当前执行阶段、地址和指令语义确定。冯·诺依曼机由指令控制执行次序，属于控制流驱动。

执行阶段	地址或数据来源	结果
取指	PC 给出指令地址	指令经存储器读入 IR
译码与取操作数	IR 操作码、地址字段及寻址规则	确定操作、操作数和有效地址
执行与写回	数据通路完成运算、访存或转移	更新寄存器、存储器和标志
后继地址形成	顺序地址或转移、调用、异常入口	更新 PC，继续取指

PC 的顺序增量由地址单位和指令长度决定：按字节编址、定长 4 B 指令时通常加 4。流水线可使多条指令的各阶段重叠；程序可见效果仍须符合 ISA。

MAR 保存本次主存访问地址，MDR 保存本次交换的位串；二者可在不同阶段分别传送指令地址、数据地址以及指令、数据。

程序 $y = ab + c$ 的寄存器状态

按字编址，地址 0～4 存取数、乘法、加法、存数和停机指令，地址 5～8 存 $a = 2, b = 3, c = 1, y = 0$。

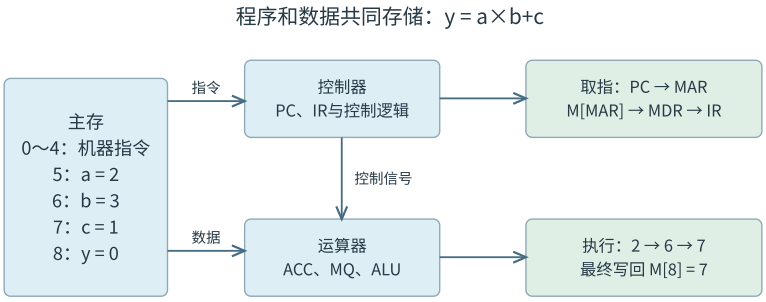


Figure 1.1: 主存按地址保存程序与数据，控制器组织取指与执行

指令地址	数据操作	完成状态
0	$M[5] \rightarrow \text{ACC}$	ACC=2，后继地址 1
1	$\text{ACC} \times M[6] \rightarrow \text{ACC}$	ACC=6，后继地址 2
2	$\text{ACC} + M[7] \rightarrow \text{ACC}$	ACC=7，后继地址 3
3	$\text{ACC} \rightarrow M[8]$	$M[8] = 7$，后继地址 4
4	停机	计算结束

示意机器中 ACC 暂存操作数或结果，MQ 辅助保存乘数或乘积低位，X 暂存另一个输入。具体寄存器配置以题设数据通路为准。

1.3 ISA、系统层次与软件

对象	规定或提供的内容
ISA（指令集体系结构）	软件可见的指令功能与编码、寄存器、数据类型、寻址方式和存储访问规则
微体系结构	ISA 的内部实现：流水级、转发、Cache 组织、加法器结构等
操作系统	资源管理、进程运行环境和服务接口
系统软件	操作系统、语言处理程序、数据库管理系统、相关工具和库
应用软件	面向用户具体任务的程序

相同 ISA 可由不同微体系结构实现，具有不同 CPI。机器码执行还受操作系统、ABI、库及可执行文件格式约束。软硬件逻辑功能等价表示同一功能可由软件算法或专用硬件实现，选择取决于时间、空间、成本、功耗与可修改性。

常用抽象层次自下而上为微程序机器级、传统机器语言级、操作系统级、汇编语言级、高级语言级。微程序级适用于采用微程序控制的机器。“透明” 表示上层使用者无需处理下层实现细节。

程序翻译与装入

$$\begin{aligned} \text{源程序} &\xrightarrow{\text{预处理}} \text{展开后的源程序} \\ &\xrightarrow{\text{编译}} \text{汇编程序} \xrightarrow{\text{汇编}} \text{可重定位目标文件} \\ &\xrightarrow{\text{链接}} \text{可执行文件}. \end{aligned}$$

预处理展开头文件、宏等；链接合并目标与库，完成符号解析和重定位；装入建立进程地址空间并准备执行入口。宏和伪指令可展开为零条、一条或多条机器指令，一条高级语言语句与机器指令条数无固定对应关系。

解释器在运行时读取源程序或中间表示并完成操作，解释器自身由机器指令运行。语言实现可组合解释、预编译和即时编译。

例 1-1

计算机硬件能够直接执行的是（ ）。

I. 机器语言程序　II. 汇编语言程序　III. 硬件描述语言程序

A. 仅 I　B. 仅 I、II　C. 仅 I、III　D. I、II、III

例 1-1
选 A。汇编源文本须经汇编器生成机器指令；硬件描述语言描述电路结构或行为，其可综合部分用于生成电路结构，仿真运行也依赖机器指令形式的程序。题目的“直接执行”指 CPU 按 ISA 译码并执行指令。

1.4 字长、编址与容量

名称	含义
机器字长	CPU 一次整数运算通常能处理的基本位宽
存储字长	一个存储单元保存的位数
指令字长	一条指令编码所占位数，可定长或变长
MAR 位数	可编码的主存地址位数
MDR 位数	一次主存数据交换的位宽

若 m 位完整地址全部可用，每个地址对应 w 位，则容量为 $2^m w$ bit。按字节编址时为 2^m B。已安装物理容量可以小于可编址空间。

- 20 位字节地址：1 MiB；20 位、16 位字地址：2 MiB。
- 2^{10} 个 16 位单元：2 KiB；按字编址需 10 位，改为按字节编址需 11 位。
- 4 KiB 主存、存储字长 32 位：按字编址需 10 位，按字节编址需 12 位。

容量常用 $1\text{KiB} = 2^{10}\text{B}$、$1\text{MiB} = 2^{20}\text{B}$；频率、速率的 k、M、G 通常按 $10^3, 10^6, 10^9$。带宽为每次传送字节数乘每秒传送次数，单位进制服从题设。

1.5 CPU 执行时间与性能指标

响应时间为从请求到得到结果的总历时；吞吐量为单位时间完成的任务量。程序总时间可包含 CPU 工作、I/O 等待和调度等。CPU 时间按实际动态执行的指令计算。

设第 i 类指令执行 n_i 条、平均占 c_i 个周期，主频为 f：

$$N = \sum_i n_i, \qquad C = \sum_i n_i c_i, \qquad \overline{\text{CPI}} = \frac{C}{N} = \sum_i \frac{n_i}{N} c_i,$$

$$T_{\text{CPU}} = \frac{N\overline{\text{CPI}}}{f} = N\overline{\text{CPI}}\,T_{\text{clk}}, \qquad T_{\text{clk}} = \frac{1}{f}.$$

平均 CPI 以指令条数为权重；Cache 缺失、流水停顿等也计入统计范围内的周期。多发射处理器的平均 CPI 可以小于 1，单条指令仍可能经历多个周期的延迟。

指标	定义及计算条件
IPC	每周期平均完成指令数；同一统计区间下 IPC $= 1/\overline{\text{CPI}}$
MIPS	每秒百万条指令，$f/(\overline{\text{CPI}} \times 10^6)$
MFLOPS ／ GFLOPS ／ TFLOPS	每秒浮点运算数分别除以 $10^6/10^9/10^{12}$
同一任务性能比	$P_A/P_B = T_B/T_A$

不同 ISA、编译器和优化方案可改变动态指令数与指令组成。比较同一任务优先使用实际执行时间，主频、CPI、MIPS 和字长各自只描述部分条件。

例 1-2

某计算机主频为 1 GHz，程序 P 运行过程中共执行 10000 条指令，其中 80% 的指令执行平均需 1 个时钟周期，20% 的指令执行平均需 10 个时钟周期。程序 P 的平均 CPI 和 CPU 执行时间分别是（　）。

A. 2.8，28 μs　　B. 28，28 μs　　C. 2.8，28 ms　　D. 28，28 ms

性能变化的时间比

同一任务，前后两方案满足同一 CPU 时间模型时：

$$\frac{T'}{T} = \frac{N'}{N}\,\frac{\text{CPI}'}{\text{CPI}}\,\frac{f}{f'}.$$

编译优化可同时改变 N 与 CPI；Cache 改进通常减少停顿；升频还可能伴随 CPI 变化。若 20 s 程序指令数变为 70%、CPI 变为 1.2 倍且主频不变，时间为 $20 \times 0.7 \times 1.2 = 16.8$ s。

1.6 局部加速与 Amdahl 定律

原时间中比例 p 的部分加快为原速度的 s 倍，其他部分不变，各部分时间可相加且无新增开销时：

$$T' = T[(1-p) + p/s], \qquad S = \frac{T}{T'} = \frac{1}{(1-p) + p/s}.$$

当 $s \to \infty$ 且 $p < 1$，加速比上限为 $1/(1-p)$。“速度提高 50%” 对应 $s = 1.5$。计算与 I/O 重叠、通信或同步开销变化时，先按实际时间关系重新建模。

例 1-3

假定基准程序 A 在某计算机上的运行时间为 100 s，其中 90 s 为 CPU 时间，其余为 I/O 时间。若 CPU 速度提高 50%，I/O 速度不变，则运行基准程序 A 所耗费的时间是（　）。

A. 55 s　　B. 60 s　　C. 65 s　　D. 70 s

增加处理器可让独立任务并发，提高吞吐量。两个各需单核 2 s 的任务在双核上同时开始，全部完成历时可由 4 s 变为 2 s；每个无排队任务的执行时间仍为 2 s。

原时间中比例 p 的部分加快
按例 1-2 的周期可相加模型，某类指令在 Amdahl 公式中的原时间占比为 $p_i = n_i c_i / \sum_j n_j c_j$。两类指令分别占 8000、20000 周期，故 10 周期那类指令的 20% 条数比例对应 5/7 的时间比例。若仅将这类指令从 10 周期降至 5 周期，主频与指令数不变，则新总周期 $= 8000 + 2000 \times 5 = 18000$，执行时间 18 μs，加速比 $= 28000/18000 = 14/9$。

1.7 器件发展阶段

电子管 → 晶体管 → 中小规模集成电路 → 大规模与超大规模集成电路。集成度提高推动可靠性、容量、速度和微型化、多核与并行计算发展。摩尔定律描述晶体管数量增长的历史经验趋势，程序加速仍由具体执行时间模型判断。