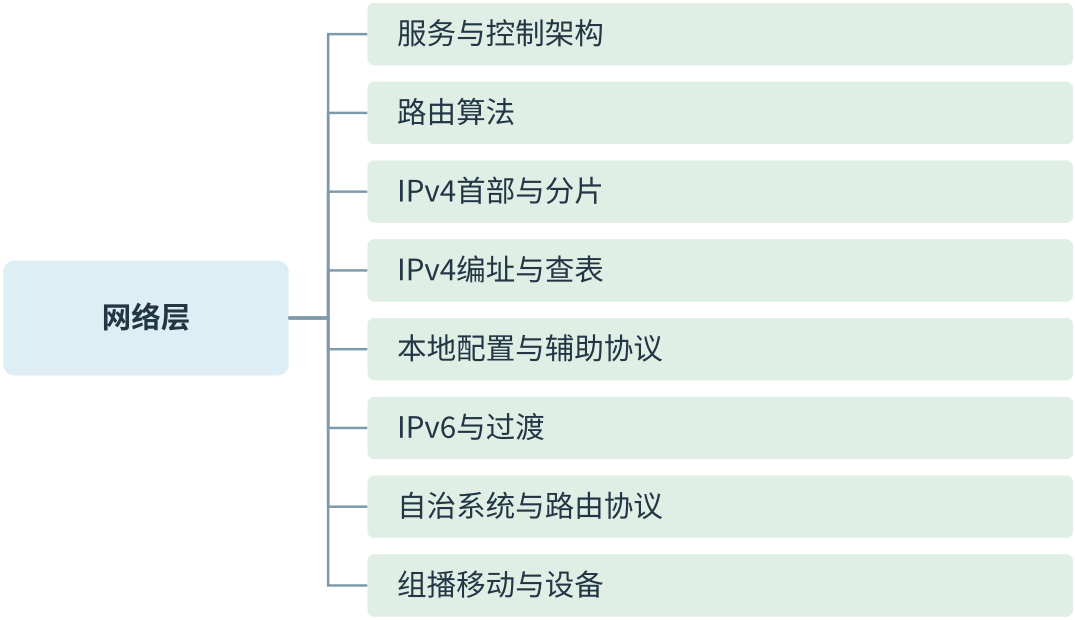
网络层 4

章节脉络



网络层要把分组从源主机送向目的主机；链路层每次只完成当前一跳。做地址题时，先分清“分组最终到谁”和“这一帧先交给谁”，再根据子网、路由表和地址解析决定下一步。

本章 IPv4 地址按 32 位无符号值处理，掩码按位与记为 &。普通多址子网计算可分配地址数时，除去网络地址和广播地址；点到点 `/31`、主机路由 `/32` 等特殊用途另论，不强套 $2^h - 2$。

不变量·路径形成与查表分开

动态路由更新可以较慢，当前分组的查表转发仍须高速执行。题目给出“路由器收到一份分组”并不意味着它立刻运行一次全网最短路；应先使用已经形成的转发表判断下一跳与出口。

4.1 路由与转发：先选路径，再逐包查表

定义 4.1.1 (路由选择与逐包转发)

路由选择根据网络可达性、度量和策略建立到各目的的路径信息；**转发**在分组实际到达时，查询目的地址等信息，选出输出接口和下一跳。前者决定表怎样形成，后者决定当前分组怎样走。路由协议通常运行较慢，转发需要按分组高速执行。

IP 把底层不同的物理链路和链路层协议联在一起，对外提供统一的网络层服务。一段可以是以太网，下一段可以是点到点链路；路由器取出 IP 分组后，用下一跳所需的链路格式重新封装。源和目的主机可以使用不同操作系统，不影响它们共同遵守 IP 协议。

普通 IP 路由转发不自动翻译任意两种网络层协议。IPv4/IPv6 转换需要明确的转换机制，应用协议转换也需要相应网关功能。王道书 §4.1 个别题把特定转换路由器纳入“路由器”讨论，解释时应限定这项额外能力，不能由此推出所有路由器都能在任何协议之间互译。转发经过路由器的正常流量，也不意味着每份数据都由路由器本机应用处理。

4.2 SDN：控制平面与数据平面怎样分工

课程连接·控制像策略数据像执行

操作系统调度器决定策略，CPU 按选定上下文执行；SDN 也把规则计算与逐包执行分开。这个类比只帮助理解分工，不能据此认定控制器必须单机、必须在每份分组的实际转发路径上。

传统设备既参与路由计算，也执行分组转发。软件定义网络 SDN 在逻辑上分离这两项职责：控制平面由控制器掌握网络状态并计算规则，数据平面的交换设备按下发的流表处理分组。逻辑集中不要求整个网络只能有一台物理控制服务器。

流表通常包含匹配字段、优先级、计数器和动作，匹配不必只看目的 IP，也可看入端口、MAC、协议、传输层端口等。动作可转发、丢弃、改写字段或上送控制器。已匹配既有规则的分组不必逐包等待控制器批准；未匹配时如何处理由表项与系统配置决定。

控制器向数据平面设备下发规则的接口称为**南向接口**；上层应用向控制器表达需求的接口称为北向接口。OpenFlow 是南向通信的一种协议，不等于 SDN 的一切实现。SDN 改变的是控制架构，不是新发明一种星形或环形物理拓扑；控制器也不必位于每台 OpenFlow 交换机内部。〖4.1-018〗

4.3 拥塞与流量控制：瓶颈究竟在哪里

多个输入流竞争同一输出链路，短期到达量超过服务量就会排队；持续过载且缓存有限则会丢包。路由器处理器很快，不代表输出链路的发送能力没有上限。增加缓存可以吸收部分突发，但长期到达速率大于发送速率时仍会积压，并增加排队时延。

流量控制保护一个接收端的处理或缓存能力，拥塞控制保护网络中共享链路与节点的承载能力。接收方窗口很大，路径中间仍可能拥塞；某个接收端窗口很小，也不能证明全网已拥塞。控制思路包括准入与资源安排、整形、合理调度、主动丢弃/标记、反馈并降低注入量等。第 5 章将用 TCP 窗口具体推演端系统的反馈控制。

分析树形网络，要对每个方向分别合计可能进入该输出链路的流量，再与该方向带宽比较。全双工的两个方向各有发送能力，不能把正反向流量先混加；同样，上层链路比单条下层链路快，并不意味着可以忽略多条下层链路的汇聚。〖4.7-018〗相关模型应在输出接口处画出所有竞争输入。

4.4 静态、动态与层次路由

静态路由由管理员配置，开销低、行为明确，但无法自行适应所有故障。动态路由根据协议交换信息、更新路径，能适应拓扑变化，也会付出报文、计算和收敛成本。动态不等于每个分组都重新运行完整路由算法。

把全网所有细节交给所有路由器会增加表项和更新范围。层次路由把网络划为区域或自治系统，对外按汇总信息处理，减少全局细节。代价是路径选择可能受到层次和策略约束，不保证按一种简单全局权值永远得到最短路。讨论 “最优” 必须先说明优化的是跳数、时延、费用还是政策要求。

4.5 距离—向量：邻居报出的距离还要加哪一段

距离—向量算法让节点向邻居通告自己到各目的的距离。节点 x 收到邻居 v 的通告后，候选距离为 “x 到 v 的直接链路代价” 加 “v 通告的到

目的距离”，即

$$D_x(d) = \min_{v \in N(x)} \{c(x,v) + D_v(d)\}.$$

不能只在邻居报告中取最小数，也不能把本机到邻居的链路代价当成最终目的距离。下一跳是使总和最小的邻居；同值时按题目规则保留或选定。

不变量·暂定距离尚可变小

Dijkstra 的未确定点距离只是当前最好候选，选定最小点后再松弛其他点。A 到 C 初值 4，在经 B 的路径代价 1+2 出现后应降为 3；算法正确性还依赖非负边权，不能省略条件。

4.5.1 例 4-1　逐列做加法，再比较候选

例 4.5.1 (配套例题)

配套例题。某网络中的所有路由器均采用距离向量路由算法。路由器 E 与邻居 A、B、C、D 的直接链路距离分别是 8、10、12、6，收到的距离向量如下。E 更新后到 Net1～Net4 的距离分别是（　）。

目的网络	A、B 的通告	C、D 的通告
Net1	1，23	20，22
Net2	12，35	30，28
Net3	24，18	16，36
Net4	36，30	8，24

A. 9，10，12，6　　B. 9，10，28，20

C. 9，20，12，20　　D. 9，20，28，20

解析。对 Net1，经 A、B、C、D 的总距离为 9、33、32、28，取 9；Net2 为 20、45、42、34，取 20；Net3 为 32、28、28、42，取 28；Net4 为 44、40、20、30，取 20。因此选 **D**。Net3 经 B、C 并列最优，不影响距离答案；若另问下一跳，就须保留并列或按指定规则选择。

这种算法只掌握邻居的距离摘要，坏消息传播时可能形成互相误导的路由环并 “计数到无穷”。水平分割等规则可以抑制部分环路，但并不意味着所有异步故障情形都已解决。

4.6 链路状态：全网拓扑怎样变成最短路径树

链路状态算法先发现邻居并测量链路代价，再把本机相邻链路状态洪泛到规定范围。各节点获得同一区域的拓扑数据库后，各自以自身为根计算最短路径树；不是收到一条通告就把通告者选成所有目的的下一跳。

Dijkstra 算法从源点开始，维护已确定最短距离的集合和各未确定点的暂定距离。每轮取暂定距离最小的点，加入集合，再用该点的出边更新其他点。对非负链路代价可使用该过程；若题设出现负权，不能无条件沿用这一结论。

用四点网络作最小推演：边 AB=1、AC=4、BC=2、BD=5、CD=1，边为双向。以 A 为源，初始 B=1、C=4、D=∞；选 B 后 C 降为 3、D 降为 6；选 C 后 D 降为 4；最后选 D。到 D 的路径为 A—B—C—D，下一跳 B。暂定 C=4 不是最终结论，不能把初始值当成最终值。

链路状态报文需要序号、老化等机制区别新旧信息，洪泛也不等于把每个收到的副本都无限次重发。与距离向量相比，链路状态通告的是本地连接信息，接收者据拓扑独立计算；二者的 “已知信息” 不同。

4.7 IPv4 首部、MTU 与分片重组

IPv4 分组由首部和数据组成。首部固定部分 20 B，共 5 个 32 bit 行；其后可有选项与填充，首部总长 20～60 B。下图固定部分按位宽比例绘制，可变区单独压缩示意。读字段时先确定它在首部中的位数，再将字段数值按指定单位换成字节量。

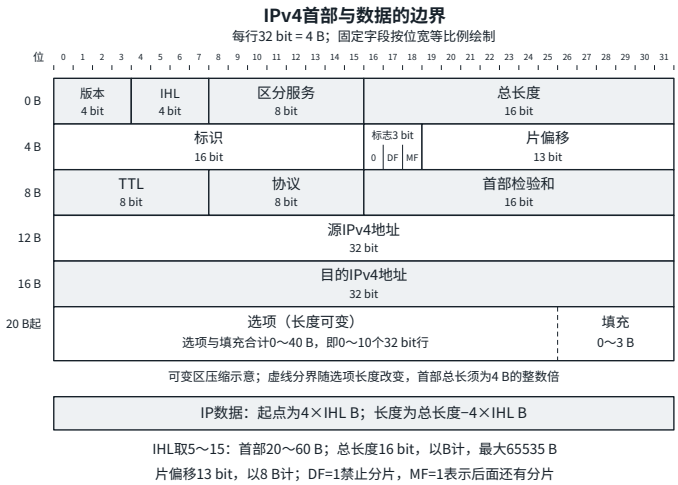


Figure 4.1: IPv4 固定首部五行，每行 32 bit；选项与填充合计 0～40 B，IP 数据在首部之后

版本字段 4 bit，IPv4 取 4；IHL（首部长度）4 bit，合法值为 5～15；区分服务 8 bit，用于携带服务类别与拥塞标记信息。总长度 16 bit，最大可表示 65535 B，包含整个 IP 首部与数据。源、目的 IPv4 地址各 32 bit，分别标识这次通信的两端，也是地址与路由题读取的字段；它们不直接替代当前链路的 MAC 地址。

三种与长度相关的字段尤其容易混用，应固定同一换算顺序：

字段	位数与单位	换成实际字节量	对应的边界
IHL	4 bit，以 4 B 为单位	首部长 $H = 4 \times IHL$	从 IP 首部起点到 IP 数据起点
总长度	16 bit，以 1 B 为单位	IP 数据长 $D =$ 总长度 $- H$	当前这个 IP 分组的首部与数据总和
片偏移	13 bit，以 8 B 为单位	本片数据起点 $O = 8 \times$ 片偏移	相对原始 IP 数据区，排除原始首部与各片首部

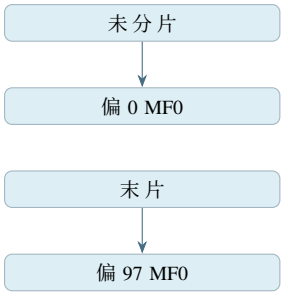
例如 IHL=6、总长度 =100，表示首部 24 B、IP 数据 76 B；不能把 6 直接当字节数。选项结束后只在必要时补 0，使首部达到 4 B 的整数倍，填充也包含在 IHL 所计的首部中。读取原始十六进制首部时，首字节 `0x45` 要拆成版本 4 与 IHL=5，总长度则读取后面的独立 16 bit 字段。

TTL 占 8 bit，实际按路由跳数递减：转发路由器减 1，耗尽时丢弃，并在允许条件下报告超时。协议字段 8 bit，标识承载的数据交给哪个协议，例如 ICMP=1、TCP=6、UDP=17；它是网络层分用依据，目的端口则在传输层继续分用。首部检验和 16 bit，只覆盖 IP 首部（含选项、填充），不覆盖 IP 数据，也不加入伪首部；TTL 等首部内容变化后须更新检验和。IPv4 没有以全 0 字段关闭首部校验的约定。〖4.2-004〗

链路 MTU 限制可承载的完整 IP 分组长度。IPv4 分组大于输出 MTU 且允许分片时，路由器可以拆成多个分片；每片均有自己的 IP 首

最小反例·MF 零不等于未分片

未分片数据报可有偏移 0、MF=0；一个最后分片也可有偏移 97、MF=0。两个状态共享 MF 数值，已足以排除“看到 MF 为 0 就断定没有分片”，必须同时读取片偏移。



MF 同为 0，偏移揭示不同状态

部。DF=1 禁止分片，无法通过时应丢弃并在允许条件下通知源端。重组在目的主机完成，避免中间路由器长期为每份报文保留重组状态。

标识字段 16 bit，用于关联同一原始数据报的各个分片，分片后各片保留其标识；它不是 TCP 式的有序交付字节号。重组还要结合源、目的地址和协议等信息，不能只凭一个 16 bit 标识合并任意分片。3 bit 标志由保留位（0）、DF、MF 组成，DF=1 禁止分片，MF=1 表示原始数据后面还有分片。片偏移以**原始 IP 数据区起点**为基准，单位为 8 B；除最后一片外，数据区长度必须为 8 B 整数倍。MF=0 既可能是未分片分组，也可能是最后一片，要结合偏移判断。

因此分片题应依次读总长度、IHL、DF，再计算每片的数据容量与 8 B 对齐量，最后写回每片的总长度、MF 和片偏移。IPv4 分片只是将 IP 数据切成多个 IP 分组，不会把片偏移变成 TCP 序号，也不会给每片自动增加一个新的 TCP 首部。

不变量·偏移坐标从原数据起

分片的偏移以原始 IP 数据起点为零，单位 8 B，不把任何分片首部累计进去。再次分片也沿用同一原坐标，因此原片的最后子片若后面仍有原数据，MF 仍应保持 1。

> **分片先守住三个长度边界**
>
> 原数据长度是原 IP 总长减首部；每片的总长不能超过出口 MTU；非末片的数据长度取不超过 MTU 减首部的最大 8 B 倍数。列出数据区间后，以原数据起点计算偏移，再写 MF。遇到再次分片，仍沿用原数据坐标与原片 “后面还有没有数据” 的状态。

4.7.1 例 4-2　为何 800 B 链路上的分片总长只有 796 B

例 4.7.1 (配套例题)

配套例题。若路由器向 MTU=800 B 的链路转发一个总长度为 1580 B 的 IP 数据报（首部长度为 20 B）时进行了分片，且每个分片尽可能大，则第 2 个分片的总长度字段和 MF 标志位的值分别是（　）。

A. 796，0　　B. 796，1　　C. 800，0　　D. 800，1

解析。原始数据区为 1560 B，每片至多容纳 780 B 数据，但非末片必须 8 B 对齐，因此取 $\lfloor 780/8 \rfloor \times 8 = 776$ B。三片数据依次为 776、776、8 B，总长度为 796、796、28 B，片偏移为 0、97、194，MF 依次为 1、1、0。第 2 片之后还有 8 B，故选 **B**。

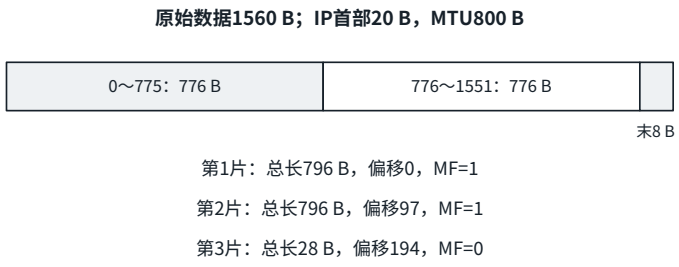


Figure 4.2: 偏移只累计原始数据，第二片从第 776 字节开始

把 800 直接填成总长度会使非末片数据长 780 B，不能用整数 8 B 偏移表达下片起点。重组时也不应把三个首部计入原始数据内容。再次分片时，偏移仍相对原始报文数据区，原分片若 MF=1，其最后子分片也仍为 MF=1。

4.8 子网掩码、CIDR 与可分配地址

错项排除·普通主机式有用途前提

普通多址子网常从地址总数减去网络和广播两个地址；主机路由/32、点到点/31 等用途有其他规则。先判断题设用途，再套主机数公式，不能把二的幂减二写成所有前缀通用定律。

CIDR 把 IPv4 地址写为 `a.b.c.d/p`，前 p 位是网络前缀，其余是该地址块内的偏移。掩码由连续 p 个 1 后接 $32-p$ 个 0 组成。给出主机地址 A 与掩码 M，网络地址为 $A\&M$，广播地址为网络地址加 $2^{32-p}-1$。

判断两个地址是否同网，应把两个地址分别与发送方所用的掩码按位与，再比较结果，不能只比较前三个十进制字节。子网划分可以缩小广播范围、组织路由，却不会凭空增加 IPv4 地址总数；普通子网越多，网络地址与广播地址等开销也可能越多。CIDR 改善分配与聚合，并不能彻底消除 32 位地址空间的限制。〖4.2-021〗〖4.2-024〗

4.8.1 例 4-3　非整字节前缀怎样求地址边界

例 4.8.1 (配套例题)

配套例题。主机 `168.16.84.24/20` 所在子网的最小可分配 IP 地址和最大可分配 IP 地址分别是（　）。

A. 168.16.80.1，168.16.84.254

B. 168.16.80.1，168.16.95.254

C. 168.16.84.1，168.16.84.254

D. 168.16.84.1，168.16.95.254

解析。`/20` 掩码为 255.255.240.0，第三字节以 16 为块长。84 落在 80～95 块内；网络为 168.16.80.0，广播为 168.16.95.255。排除二者，可分配范围为 168.16.80.1 至 168.16.95.254，选 **B**。84 只是主机地址中的第三个字节，不是网络边界。

定长划分从主机位统一借 s 位作子网号，得到 2^s 个等长子网；本书采用现代允许全 0、全 1 子网号的口径，不再无条件减 2。可变长划分 VLSM 要按需求从大到小分配，所分地址块必须在相应前缀边界对齐、彼此不重叠。需要 100 个普通主机地址，至少分 `/25` 的 128 地址块；若再需 50 个，分 `/26`，较大的块也不能从不对齐的地址开始。

4.8.2 例 4-4　“完整划成 5 个子网”限制了最深分支

例 4.8.2 (配套例题)

配套例题。若将 `101.200.16.0/20` 划分为 5 个子网，则可能的最小子网的可分配 IP 地址数是（　）。

A. 126　　B. 254　　C. 510　　D. 1022

解析。这里按整个原地址块被 5 个子网完整分割理解，可把划分看成二叉前缀树。每把一个叶块对半拆成两个子块，叶子数只增加 1。由 1 个块变成 5 个块共能拆 4 次；连续沿一个分支拆 4 次，最深前缀为 `/24`。可分配地址数为 $2^8-2=254$，选 **B**。

例如保留 `101.200.24.0/21`，把另一半继续拆出 `/22`、`/23` 和两个 `/24`，正好 5 块。若允许只从原块中零散取 5 个小块、其余地址未分配，便不能推出这一最小规模；本题“划分”为完整覆盖条件决定了前缀树模型。〖4.2-040〗也应先检查能否用指定总叶子数完整覆盖，而不能仅看两个候选块是否重叠。

特殊地址还需单独判断。`0.0.0.0` 可用于未取得地址时的本机源地址；`255.255.255.255` 为本地受限广播，路由器不转发，默认路由

不能改变这个限制；127/8 用于回环，可在主机内部作源或目的，不应作为外部链路的正常地址。定向广播是某子网主机位全 1 的地址，其跨路由器转发还受安全策略和配置限制，不能据此认为它一定被转发。〖4.2-018〗〖4.2-042〗

最小反例·更具体的出口会胜出

目的 10.1.2.7 同时落在 10/8 与 10.1.2/24 中，即使/8 记录的距离更小，转发仍选/24。先比较匹配前缀长度，才处理同一前缀候选的度量；表项先后顺序也不决定这个结果。

4.9 路由聚合与最长前缀匹配

路由聚合把连续、对齐且具有共同前缀的地址块合成一个更短的前缀，减少表项。若要求**精确聚合**，不能额外覆盖尚不属于该出口的地址；如果题目允许覆盖空隙并用更具体路由纠正，则需按该附加条件讨论。不能只找到任意共同前缀就忽略多覆盖的地址范围。

4.9.1 例 4-5　四个 /21 应缩短几位

例 4.9.1 (配套例题)

配套例题。某路由表中有转发接口相同的 4 条路由表项，其目的网络地址分别为 `35.230.32.0/21`、`35.230.40.0/21`、`35.230.48.0/21` 和 `35.230.56.0/21`，将该 4 条路由聚合后的目的网络地址为（　）。

A. 35.230.0.0/19　　B. 35.230.0.0/20

C. 35.230.32.0/19　　D. 35.230.32.0/20

解析。四个块覆盖第三字节 32～63，共 32 个 `/24`，合计 $4\times 2^{11}=2^{13}$ 个地址，前缀应为 $32-13=19$ 位。32 是 `/19` 对应的块边界，因此精确聚合为 35.230.32.0/19，选 **C**。只把 21 减 1 只能合并两个块；将网络起点写 0 又会改成另一块地址范围。

转发查表时，目的地址可能同时匹配多个前缀，应选**匹配位数最多**的条目。设表中有 `10.0.0.0/8→ 接口 1`、`10.1.0.0/16→ 接口 2`、`10.1.2.0/24→ 接口 3` 和默认 `/0→ 接口 4`，目的 10.1.2.7 走接口 3；10.1.9.7 走接口 2；11.1.2.7 仅匹配默认。先匹配前缀，再读出口；不同前缀长度的匹配项之间，不直接比较度量值大小。

默认路由 `/0` 能匹配所有普通目的，用于没有更具体条目时；它不改变广播、TTL 等协议限制。主机路由 `/32` 只匹配一个地址，比相应网络路由更具体。下一跳 IP 与本机输出接口是不同字段：前者指向邻居，后者确定从本设备哪个口发出。〖4.7-016〗

4.10 NAT：为什么地址变了，传输层校验也要变

网络地址转换 NAT 在边界处改写分组中的地址，并维护内部与外部地址的映射。常见 NAPT 同时利用端口区分多个内部端点，例如 `192.168.1.5:50000` 与 `192.168.1.6:50000` 可映射为同一公网 IP 的两个不同端口。回包到达时按映射表恢复内部目的地址和端口。

对出方向的分组，普通源 NAT 通常修改源 IP，NAPT 还可能修改源端口；目的 IP 与远端服务端口通常不变。IPv4 首部检验和需随地址改变更新；TCP/UDP 校验覆盖的伪首部也包含 IP 地址，因此其校验和可能必须更新。不能因为“路由器主要是网络层设备”就断言它绝不会检查或改写端口。IPv4 UDP 若明确未启用校验，其零字段语义另行处理。

NAT 保存映射状态，不等于给每条连接预留传输带宽；仅靠私有

地址也不会让内部服务器自动对外可见。外部主动发起访问通常需要静态映射、端口转发或其他穿越机制。私有地址主要有 10/8、172.16/12、192.168/16，不能把所有 172 开头地址都归成私有。

不变量·ARP 先确定当前邻居

源主机的第一帧只需交给本地下一跳，ARP 广播也只到当前广播域。即使 IP 最终目的在远端，当前帧目的 MAC 仍可为网关；普通二层交换机转发这帧时，不把源 MAC 换成自己。

4.11 ARP 与逐跳 MAC：最终目的和当前下一跳分开算

主机先用自己的子网掩码判断目的是否在本地。若本地可直接交付，下一跳为目的主机；否则下一跳通常是默认网关或更具体路由指定的邻居。再使用 ARP 查询**下一跳 IP 对应的 MAC**，封装当前以太网帧。不能先按最终目的 IP 向整个互联网广播 ARP。

ARP 请求通常以以太网广播发出，只在当前广播域传播，内含待查询 IP；拥有该 IP 的节点通常单播回复其 MAC。路由器不把普通 ARP 广播照搬到另一子网，代理 ARP 等特定机制需另给条件。ARP 缓存减少重复查询，但并非永久正确，也不是 DNS 那样把域名解析成 IP。

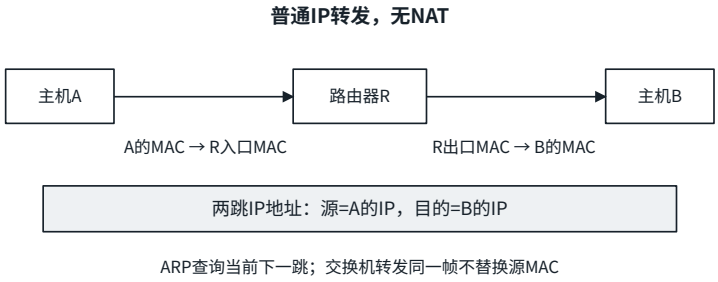


Figure 4.3: 经路由器时 IP 源/目的通常不变，帧的源/目的 MAC 按每跳重封装

在不经过 NAT 的普通转发中，图中 IP 源 A、目的 B 在各跳保持；第一帧目的为路由器入口 MAC，第二帧源为路由器出口 MAC。交换机只转发同一链路层帧时，不把源 MAC 改成交换机的 MAC。

4.11.1 例 4-6　相差几个第三字节，仍可能在同一子网

例 4.11.1 (配套例题)

〖4.2-043〗某以太网中，甲 IP 为 211.71.136.23，子网掩码 255.255.240.0，网关 211.71.136.1。若甲向乙 211.71.130.25 发送 IP 分组，则（　）。

A. 直接发给乙，帧目的 MAC 为网关 MAC

B. 直接发给乙，帧目的 MAC 为乙 MAC

C. 交网关转发，帧目的 MAC 为网关 MAC

D. 交网关转发，帧目的 MAC 为乙 MAC

解析。掩码是 `/20`，136 与 130 按位与 240 均得 128，两地址同属 211.71.128.0/20。应查询乙的 MAC 并直接交付，选 **B**。网关虽然已给出，但本次不需要它。题目给出某个参数，不等于必须使用它。

若同一物理广播域上的两台主机配置了不同掩码，它们对 “对方是否本地” 的判断可能不一致。接到 ARP 广播仅说明链路广播到达，不能证明双方会按同一 IP 子网路径发回数据；应分别从每个发送方的掩

码重算。这是〖4.2-045〗在网络配置异常条件下增加的判断边界。

错项排除·地址提议尚非地址生效

Offer 提供候选地址，初始选择阶段 Request 表达接受哪份提议，ACK 才确认租约。图中出现候选 IP 并不意味着它已可作客户端 IP 源；题目若问目的、源，还应按设问顺序填写。

4.12 DHCP：请求一个地址不等于已经拥有它

DHCP 自动提供 IP、掩码、默认网关、DNS 服务器和租期等配置。初始获取通常经历 Discover、Offer、Request、ACK 四类交互，承载于 UDP，客户端端口 68、服务器 67。客户端尚无可用地址，初始报文可用源 IP0.0.0.0 与广播目的；处于其他状态的续租请求则可能单播，不能把某一阶段的做法当成全部 DHCP 的固定规则。

Discover 寻找服务器，Offer 提出可用配置；客户端用 Request 表达选定的地址与服务器，收到 ACK 后才按配置使用。Request 在初始选择阶段采用广播，还能让未被选择的服务器知道该地址提议未被采用。跨子网获取配置可由 DHCP 中继帮助转送广播请求，普通路由器默认不会直接转发受限广播。

4.12.1 例 4-7　初始 DHCPREQUEST 的源、目的 IP

例 4.12.1 (配套例题)

配套例题。一台新接入网络的主机 H 通过 DHCP 服务器动态请求 IP 地址过程中，与 DHCP 服务器交换 DHCP 报文的部分过程如下图。封装 DHCPREQUEST 报文的 IP 数据报的目的 IP 地址和源 IP 地址分别是（　）。

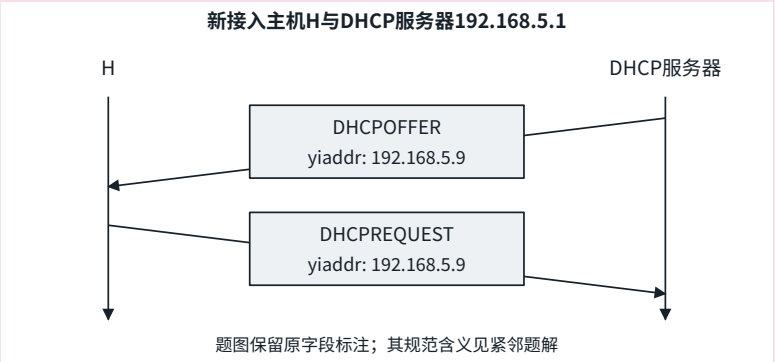


Figure 4.4: 原题的两个报文及字段标记；时间向下

A. 192.168.5.1，0.0.0.0

B. 192.168.5.1，192.168.5.9

C. 255.255.255.255，0.0.0.0

D. 255.255.255.255，192.168.5.9

解析。H 仅收到地址提议，尚未获得 192.168.5.9 的使用确认。初始选择阶段 Request 使用源 0.0.0.0、目的 255.255.255.255，按“目的、源”的设问顺序选 **C**。服务器的单播地址不是这一步的目的 IP 地址。

图中 Request 框沿用原题的 `yiaddr` 标注。按 DHCP 规范，客户端此阶段申请的地址实际由 Requested IP Address 选项携带，客户端发出的 `yiaddr` 为 0。图中的 192.168.5.9 应理解为待申请地址信息，不能据这个标注推出 H 已经能用它作 IP 源地址。Offer 中的 `yiaddr` 才是服务器提出的地址。

4.13 ICMP：报告差错不等于替原分组重传

错项排除·差错报告不是可靠重传

ICMP 把某次网络问题告知原源端，不负责替所有应用重发丢失分组。差错之间还有限制以防反馈放大；历史源点抑制已被废弃，不能把旧类型识别题的答案当成当前拥塞处理建议。

ICMP 封装在 IP 数据报中，IPv4 协议字段为 1。目的不可达、时间超过、参数问题等差错信息帮助源端诊断；回送请求/应答支持连通性探测。ICMP 不把 IP 变成可靠传输协议，不负责代替源端自动重发每份丢失数据。

ICMP 差错一般携带引发问题的 IP 首部和一部分数据，便于源端识别；返回目标是原分组的源端，并不向路径上的每个路由器广播。对 ICMP 差错报文本身通常不再产生 ICMP 差错；对非首片、广播/组播目的及某些特殊源地址等也有限制，防止差错相互放大。首部检验和损坏的 IP 分组通常直接丢弃；其中的源地址已不可靠，不能据以发送差错报告。

直接封装顺序为“链路帧—IP—ICMP”。说“ICMP 最终也由链路帧承载”可以，但不能据此跳过 IP 而把 ICMP 归为直接封装在以太网中的网络邻居协议。〖4.2-048〗

4.13.1 例 4-8　历史 ICMP 题要保留协议年代

例 4.13.1 (配套例题)

配套例题。若路由器 R 因为拥塞丢弃 IP 分组，则此时 R 可向发出该 IP 分组的源主机发送的 ICMP 报文类型是（　）。

A. 路由重定向　B. 目的不可达　C. 源点抑制　D. 超时

解析。依当年协议背景，源点抑制用于通知源端降低速率，选 **C**。它后来已被 RFC 6633 废弃，当前实现不应继续把发送源点抑制作为拥塞控制建议。本题用于辨认历史类型；现代拥塞处理应结合丢包、ECN 等适用机制讨论，不能把旧题答案直接当现行工程操作。

Ping 常用 ICMP Echo，Traceroute 借助逐步增大的 TTL 使沿途返回超时信息；具体探测可使用 UDP、ICMP 或 TCP 等变体。看到超时回复，说明探测分组到达某跳并触发限制，不等于所有数据路径都完全对称。

4.14 IPv6：基本首部固定，不代表没有扩展

IPv6 地址 128 bit，写成 8 组 16 位十六进制数。每组可省前导 0，一处连续的全 0 组可用 `::` 压缩，整串最多出现一次 `::`，否则无法唯一还原。`2001:0db8:0000:0000:0000:0000:0000:0001` 可写成 `2001:db8::1`；省略冒号两侧有效数字或多次使用 `::` 都会改变含义。

IPv6 基本首部固定 40 B，包含版本、流量类别、流标签、有效载荷长度、下一首部、跳数限制和源/目的地址。扩展首部在需要时另接，因此固定的是**基本首部**，不是所有扩展字段的总长。没有 IPv4 式首部检验和，不能由此认定它完全没有链路和端到端检错。

IPv6 路由器转发分组时不分片。分组过大时丢弃，并在适用条件下发 ICMPv6 Packet Too Big，源端据路径 MTU 调整；源端必要时用分片扩展首部处理。换一条任意大 MTU 链路转发不是替代既定路由规则的通用办法。IPv6 无广播地址，用组播等完成相应功能，邻居发现使用 ICMPv6，不能仍以 ARP 作为原生 IPv6 解析机制。

比较维度	IPv4	IPv6
地址长度	32 bit	128 bit
首部长度与长度字段	首部 20～60 B；总长度计首部和数据	基本首部 40 B；有效载荷长度不计这 40 B，计其后的扩展首部和数据
网络层首部检验和	有，只校验 IPv4 首部	基本首部没有该字段
转发时遇到过大分组	允许时可由路由器分片；DF=1 时不能分片	路由器不分片，通知源端调整
本地邻居与广播	ARP 解析下一跳；有受限/定向广播等地址	ICMPv6 邻居发现；无广播地址

表中比较的是两种 IP 机制。双栈、隧道属于过渡方式，NAT 属于地址转换，不能把这些机制理解成 “IPv6 自动把每个 IPv4 字段扩大四倍”。下题分别检查地址空间、基本首部和转发限制。

4.14.1 例 4-9　地址位数增加 96，不是地址数乘 96

例 4.14.1 (配套例题)

配套例题。下列关于 IPv4 和 IPv6 的叙述中，正确的是（　）。

I. IPv6 地址空间是 IPv4 地址空间的 96 倍

II. IPv4 首部和 IPv6 基本首部的长度均可变

III. IPv4 向 IPv6 过渡可以采用双协议栈和隧道技术

IV. IPv6 首部的 Hop Limit 字段等价于 IPv4 首部的 TTL 字段

A. 仅 I、II　　B. 仅 I、IV　　C. 仅 II、III　　D. 仅 III、IV

解析。地址空间比例为 $2^{128}/2^{32}=2^{96}$，I 错误；IPv6 基本首部固定，II 错误；双栈让节点同时支持两类协议，隧道把一类分组封装在另一类分组中跨越对应网络，III 正确；Hop Limit 与按跳递减的 TTL 作用相同，IV 正确，选 **D**。双栈和隧道也不意味着普通路由器可随意转换任意网络协议。

4.15 自治系统：域内最短与域间策略分开

自治系统 AS 是在统一管理和路由策略下的一组网络与路由器。域内路由协议 IGP 处理 AS 内部可达性，典型有 RIP、OSPF；域间路由协议处理 AS 之间信息，互联网主要使用 BGP。AS 不是一个 IP 子网，也不要求只有一台出口路由器。

一个分组可以先按本 AS 的域内路径到达出口，再按域间策略进入另一个 AS。IGP 的代价最短与 BGP 的政策选路标准不同，不能拿 RIP 跳数直接和 BGP 的 AS 路径长度混在一张 “最小值表” 里比较。

4.16 RIP：加 1 更新，16 表示不可达

RIP 采用距离向量，度量为跳数，最大可用距离 15，16 表示不可达；消息常通过 UDP 端口 520 传送。收到邻居表项，先把候选距离加 1 并把下一跳改为该邻居，再与本表比较。

若目的未登记，按候选加入；候选更优时替换；若原表下一跳就是该邻居，则即使距离变差，也应采用该邻居新的距离，以反映原路径变化；若不同邻居报告较差路径，通常不替换。具体等价路径保留规则可按题意处理。更新并不需要等所有邻居回复确认后才进行。〖4.4-012〗

错项排除·原下一跳变差也得更新

本机原路由经 B 到 N 为 3 跳，B 现在通告 5 跳，经 B 候选就变为 6。继续保留旧 3 会把已失效的信息当成更优路线；只有来自不同下一跳的更差候选，才可按通常规则忽略。

例如本机到 N 原为 3 跳、下一跳 B，B 新报 N 为 5，候选 6，应更新到 6 而不是坚持旧 3；若 C 报 2，候选 3，存在可替代的 3 跳路径。邻居报 16 时经它仍不可达，不保留 17 作有效距离。RIP 把无穷取小有助于限制计数时间，也限制可用网络规模；“跳数少” 不保证带宽更大或传播时延更短。

不变量·BGP 策略先于简单距离

AS_PATH 帮助抑制 AS 环并参与选路，真实决策还受本地优先级等属性约束。只有题目明确其余策略属性相同，才可按路径长度及到出口的域内代价进一步比较，不能固定背成 “AS 少就选”。

4.17 OSPF：区域怎样限制拓扑细节

OSPF 采用链路状态方法，基于 IP 直接承载，协议号 89，不使用 TCP 或 UDP 端口。Hello 发现并维持邻居关系；相邻路由器同步链路状态信息，形成数据库，再运行最短路径优先计算。Hello 与 Keepalive 都用于维持邻居或会话关系，但分属 OSPF 与 BGP，不能互换。〖4.4-015〗

OSPF 可把 AS 分成多个区域，区域间通信经骨干区域转发。区域内共享较完整的该区域拓扑，跨区主要使用汇总可达信息，降低每台路由器需要掌握的拓扑规模。区域边界路由器参与相邻区域与骨干的信息处理，不应简单说 “任何路由器只知道一个区域”。

区域划分减少洪泛和计算范围，但增加区域类型、边界通告等机制，不能因此称协议结构一定更简单。〖4.4-006〗中 “局部信息更少” 与 “整个协议更简单” 是两个判断。

4.18 BGP：AS_PATH 是路径向量，不是链路状态

BGP 在自治系统之间交换可达前缀和路径属性，使用 TCP 端口 179。AS_PATH 记录通告所经过的 AS 序列，帮助检测 AS 环路并执行策略；NEXT_HOP 给出通告路由的下一跳。BGP 不把全互联网每条物理链路的代价都洪泛给每个节点。

收到路径含本 AS 号的通告通常应拒绝，以免形成 AS 环；对其余候选还要执行本地策略，不能只按 AS_PATH 长度作唯一决策。对等连接成功也不等于对方通告的一切路径都应被接受。

RIP、OSPF、BGP 分别对应距离向量、链路状态、路径向量；本机邻居是谁、知道哪些信息、按何种规则选择，是比较的共同维度。BGP 虽然有 NEXT_HOP 属性，但其可达信息不能仅概括成 “到某网的下一跳”。〖4.4-019〗〖4.4-020〗

比较维度	RIP	OSPF	BGP
主要管理范围	AS 内部	AS 内部，可再划区域	AS 之间的可达性与策略
交换的核心信息	到目的网络的距离向量	本地链路状态，在规定范围内洪泛	可达前缀及路径属性，含 AS_PATH
接收者如何选路	邻居通告距离加本地一跳，比较候选	根据拓扑数据库计算最短路径树	根据路径属性与本地策略选择可接受路径
更新的主要特点	周期通告，并可触发更新；坏消息可能慢收敛	变化触发链路状态更新，还需刷新与老化	与对等体建立会话后按变化增量通告，不周期发送整张路由表
报文直接承载	UDP，端口 520	IP，协议号 89	TCP，端口 179

“交换了哪些信息” 和 “这些报文如何被传送” 是两个判断维度。BGP 使用 TCP 并没有把选路准则变成 TCP 窗口；OSPF 虽然直接由 IP 承载，但仍要维护邻居关系、管理通告的可靠性。路径算好以后，普通 IP 分组仍按转发表的最长前缀匹配转发，不为每个分组重新运行一次 RIP、Dijkstra 或 BGP 策略选择。

4.19 IP 组播：分支复制放在哪里

课程连接·成员管理与转发树分工

IGMP 像维护当前接收者集合，组播路由机制再按网络结构组织复制分支。知道本地有人加入，并不等于已经知道远端所有路径；TTL 只能限制错误环流寿命，不能替代合理的树结构。

组播把数据交给一个接收者组。源端发送一份，路由器在需要分叉的接口复制，使公共路径上的数据只传输一次。若改用多次单播，则要为每个接收者单独发送，公共链路可能重复承载相同内容。时延是否相同还取决于并发、排队和树结构，不能保证用多个单播替代后时延不变。〖4.5-001〗

IPv4 组播地址为 224.0.0.0/4，不用作普通单播接口地址。映射到以太网组播 MAC 时，只取 IP 低 23 位，放入 01:00:5E 后相应位置，因此多个 IP 组播地址会映射到同一 MAC。链路层收到该帧，不等于本机加入了对应的 IP 组播组，还需上层检查。

IGMP 用于在主机与相邻组播路由器之间管理本地成员关系，不能单独建立跨网络的组播路由树。组播路由协议组织无环转发树、选择正确分支，防止重复和环路；TTL 虽能最终限制环流寿命，却不能代替构造合理转发结构。〖4.5-002〗

4.20 移动 IP：位置改变后，固定地址怎样仍能被找到

移动 IPv4 保留移动节点的归属地址，使用当前访问网络的**转交地址**描述它现在的位置。归属代理维护两者的绑定；有外部代理时可由其提供转交地址和转送服务，也可采用节点自有转交地址。注册的目标是让归属代理知道新的可达位置，不是只让当前外部代理知道本机存在。

传统三角路由中，通信对端按归属地址发送；分组先到归属网络，由归属代理截获，再封装为隧道分组送到转交地址，解封装后交给移动节点。外层目的为转交地址，内层目的仍是归属地址，不能把这两个目的 IP 当成一次普通逐跳改写。

移动节点向外发送时，基础模型可直接经过被访网络路由器发往对端，回程却仍按归属地址经过归属代理。实际部署若存在源地址过滤等限制，可使用反向隧道；因此 “可直接发送” 要限定为该基础模型。〖4.6-001〗〖4.6-003〗分别考查注册与方向，要分两步判断，不能以 “移动后还能发” 为由推断回包也直接到新位置。

4.21 路由器内部：查表后为何仍可能排队

输入端口接收信号、处理链路帧并查转发表，交换结构把分组移向相应输出，输出端口排队并重新封装发送。路由处理器负责控制协议和表项维护，正常高速转发可由专用硬件完成。交换结构可基于内存、总线或互联网络，各自共享资源与并行程度不同。

即使输入查表很快，两个输入端口同时要求同一输出时，也不能都以满速把分组发到这条链路上；可能在输入、交换结构或输出端排队。输入队列若队首分组等待繁忙输出，后面本可去空闲输出的分组也可能被挡住，形成队首阻塞。输出排队则受该出口服务速率约束，缓存满时按规则丢弃。

逐包转发可按以下顺序检查：是否完整收到且链路检错通过；目的是否本机；TTL 等是否允许继续；最长前缀匹配得到哪个出口/下一跳；是否需要分片或报告过大；怎样解析下一跳链路地址并封装；出口什么时候空闲。题目给定的直通等特殊实现可调整开始转发的时刻，但不能省略这些逻辑条件。

把一次转发分成可追踪的状态

下面只表示普通 IPv4 路由转发的检查顺序，题目给定特殊实现时另加条件。

```
接收当前链路帧，检查后取出IP分组
若目的为本机：按协议字段上交
否则检查TTL；查最长匹配前缀，确定出口与下一跳
按出口MTU与DF判断转发、分片或报告差错
查询下一跳链路地址；在出口排队并重新封装
```

NAT 若存在，应按题设在相应位置执行地址/端口与检验和更新。路由选择负责形成表，以上查表没有为每份分组重跑全网最短路。

不变量·内外层各有自己的目的

移动节点的归属地址保持身份，转交地址描述当前位置。隧道外层把分组送到当前访问网络，内层仍保留原目的；将二者画成两个封装层，就不会误以为每一跳都把原目的 IP 改写。

4.21.1 例 4-10　等分子网后，主机余量与分片分别计算

例 4.21.1 (配套例题)

配套例题。某公司的网络如下图所示。IP 地址空间 192.168.1.0/24 被均分给销售部和技术部两个子网，并已分别为部分主机和路由器接口分配了 IP 地址。销售部子网的 MTU=1500 B，技术部子网的 MTU=800 B。

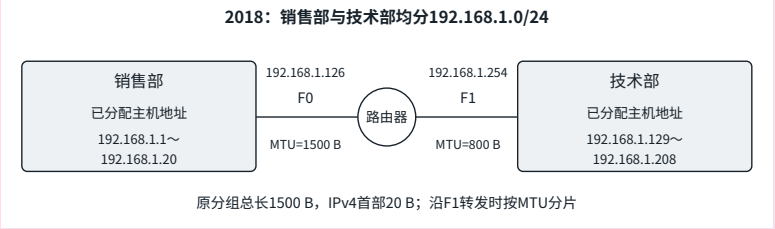


Figure 4.5: 销售部已分配 192.168.1.1～20，技术部已分配 192.168.1.129～208；F0 为.126，F1 为.254

（1）销售部子网的广播地址是什么？技术部子网的子网地址是什么？若每个主机仅分配一个 IP 地址，则技术部子网还可以连接多少台主机?

（2）主机 192.168.1.1 向主机 192.168.1.208 发送一个总长度为 1500 B、首部长度为 20 B 的 IP 分组。路由器通过 F1 转发时进行分片，且尽可能分为最大片。一个最大 IP 分片封装数据的字节数是多少？至少需要几个分片？每个分片的片偏移量是多少?

解析。“均分一个/24”先确定两个/25，每个块有 128 个地址，再利用已经分配的地址识别哪一块属于哪个部门。销售部.1～.20 在 192.168.1.0/25 内，广播地址为 **192.168.1.127**；技术部.129～.208 在 **192.168.1.128/25** 内。技术部可用地址有 $128-2=126$ 个，已分配主机数为 $208-129+1=80$，F1 的.254 还占 1 个，因此还可连接 $126-80-1=$ **45** 台主机。路由器接口不是额外的一台用户主机，但会占用同一子网的可用地址。

分片计算从原 IP 数据部分开始：$1500-20=1480$ B。F1 所在链路每片总长不能超过 800 B，扣首部后最多 780 B；非末片数据长度又必须是 8 B 的整数倍，故最大数据量为 $\lfloor 780/8 \rfloor \times 8 =$ **776** B。余下

$1480 - 776 = 704$ B，一片即可容纳，所以最少 2 片。

分片	数据长度/B	IP 总长度/B	片偏移（8 B 单位）与 MF
第一片	776	796	偏移 0，MF=1
第二片	704	724	偏移 97，MF=0

第二片偏移是 $776/8 = 97$，它累计的是原数据的位置，不加第一片首部。末片不要求数据长度继续凑满 776 B，所有片的数据长度相加仍为 1480 B。

课程连接·成员管理与转发树分工

IGMP 像维护当前接收者集合，组播路由机制再按网络结构组织复制分支。知道本地有人加入，并不等于已经知道远端所有路径；TTL 只能限制错误环流寿命，不能替代合理的树结构。

4.21.2 例 4-11　覆盖性聚合必须保留更具体的直连例外

例 4.21.2 (配套例题)

配套例题。Internet 的两个自治系统构成的网络如下图所示。AS1 由 R1 连接两个子网构成；AS2 由 R2、R3 互联并连接三个子网构成。各子网地址、R2 的接口名以及 R1、R3 的部分接口 IP 地址均在图中标出。

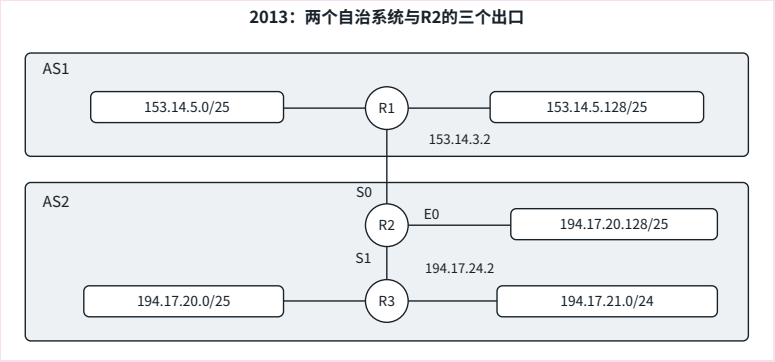


Figure 4.6: R2 经 S0 到 R1、经 S1 到 R3，E0 直连 194.17.20.128/25

（1）路由表结构为“目的网络、下一跳、接口”。利用路由聚合技术给出 R2 的路由表，要求包括到达图中所有子网的路由，且路由项尽可能少。

（2）若 R2 收到目的 IP 地址为 194.17.20.200 的 IP 分组，会通过哪个接口转发?

（3）R1 与 R2 之间利用哪个路由协议交换路由信息？该协议报文封装到哪个协议的数据单元中传输?

解析。解题入手点是先按出口分组，而不是把所有地址不加区别地取共同前缀。经 S0 到达的 153.14.5.0/25、153.14.5.128/25 恰好拼成 153.14.5.0/24，下一跳为 R1 的 153.14.3.2。经 S1 到达的 194.17.20.0/25 与 194.17.21.0/24 可用 194.17.20.0/23 覆盖，但这个/23 也包含 E0 直连的 194.17.20.128/25，必须保留该更具体条目，让最长前缀匹配处理例外。

目的网络	下一跳	接口
153.14.5.0/24	153.14.3.2	S0
194.17.20.0/23	194.17.24.2	S1
194.17.20.128/25	—（直连）	E0

这 3 条分别承担三个不同出口，已不能在保持全部转发结果的前提下继续合并。这里的第二条是“较宽覆盖加更具体例外”，不是声称

S1 后的两个原子网恰好无空隙地拼成一个/23。若删除 E0 例外，原本应直达的分组就会误发给 R3。

194.17.20.200 同时匹配 `194.17.20.0/23` 和 `194.17.20.128/25`；比较前缀长度 25 与 23，选择 **E0**，不依赖表项书写顺序。R1 与 R2 属于不同自治系统，因此交换域间路由使用 **BGP（BGP-4）**，BGP 报文由 **TCP** 承载。自治系统内部使用何种 IGP，不改变这条跨 AS 邻接的协议选择。

不变量·内外层各有自己的目的

移动节点的归属地址保持身份，转交地址描述当前位置。隧道外层把分组送到当前访问网络，内层仍保留原目的；将二者画成两个封装层，就不会误以为每一跳都把原目的 IP 改写。

4.21.3 例 4-12　RIP 逐轮传播与 BGP 出口选择是两条过程

例 4.21.3 (配套例题)

配套例题（改编）。　网络空间是继陆海空天之后的“第五疆域”，路由算法与协议是网络核心技术之一。现有互联网中 4 个自治系统的互连拓扑如下图。AS1 运行 RIP；AS3 内任意两台主机通信经过的路由器不超过 15 个，AS4 内可能超过 20 个。本题采用下图拓扑：**R13 与 R16 不直接相连**。

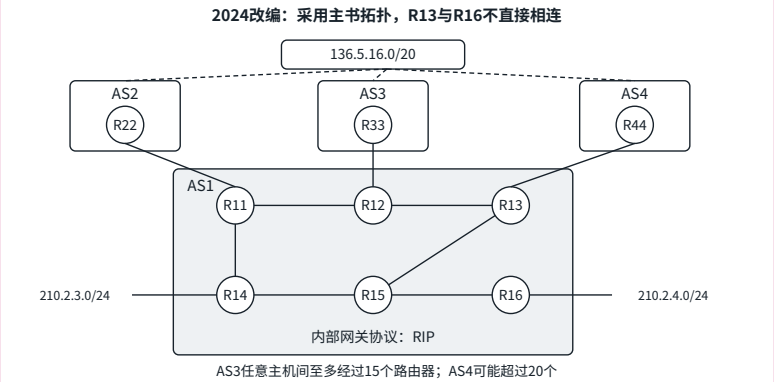


Figure 4.7: AS1 内仅有 R11—R12、R12—R13、R11—R14、R14—R15、R15—R16、R15—R13 六条路由器间链路

（1）若仅有 RIP、OSPF 可选，AS4 应选择哪个内部网关协议？

（2）AS3 中的某主机向本 AS 另一主机发送一个 IP 分组，为保证正常接收，初始 TTL 至少应为多少？

（3）AS1 的路由器同时启动，立即构建并交换初始距离向量，此后每隔 30 s 交换一次最新距离向量。从交换初始向量的时刻算起，R11～R16 全部获得到达 210.2.3.0/24 的正确路由至少需多久？全部获得到达 210.2.4.0/24 的正确路由至少需多久？

（4）R44 向 R13 通告 136.5.16.0/20 的路由，由哪类 BGP 会话完成、通过哪种 BGP 报文通告？R13 又通过哪类会话将该可达性信息通告给 R14、R15？

（5）R14、R15 均收到下表可达性信息。在无策略约束的情况下，更新后两者到 136.5.16.0/20 的下一跳各是谁？

目的网络	AS 路径	下一跳
136.5.16.0/20	AS2、AS8、AS19	R11
136.5.16.0/20	AS3、AS7、AS11、AS19	R12
136.5.16.0/20	AS4、AS10、AS19	R13

解析。第（1）问先检查协议的适用上限。RIP 最大有效跳数为 15，

16 即不可达，AS4 的规模可能超出这一限制，应选 **OSPF**。第（2）问问的是 IP 的 TTL 而非 RIP 度量：每经过一个路由器 TTL 减 1，减至 0 便被丢弃。最多经过 15 个路由器后仍须至少剩 1，故初始 TTL 至少为 **16**。

第（3）问把每次交换视作一轮：本轮只能把交换前已知的路由传给相邻路由器，不能让新收到的信息在同一轮连续穿越全网。又因为首次交换定义为 $t = 0$，直连路由在此刻已经传给一跳邻居，不能额外再计一个 30 s。

距首次交换的时间	已正确获知 210.2.3.0/24 的路由器	已正确获知 210.2.4.0/24 的路由器
0 s	R14、R11、R15	R16、R15
30 s	R11～R16 全部	R16、R15、R14、R13
60 s	R11～R16 全部	R11～R16 全部

210.2.3.0/24 直连 R14，首次传给 R11、R15，下一轮由它们传给 R12、R13、R16，所以需 **30 s**。210.2.4.0/24 直连 R16，首次仅传给 R15，30 s 时到 R14、R13，60 s 时才到 R11、R12，所以需 **60 s**。逐轮集合依赖题图中实际存在的边，不能擅自补上 R13—R16。

第（4）问按会话两端是否同属一个 AS 区分：R44 与 R13 分属 AS4、AS1，用 **eBGP** 会话，通过 **UPDATE** 报文通告；R13 向同属 AS1 的 R14、R15 传播可达性信息，用 **iBGP** 会话。BGP 会话不要求所有对端在物理上直接相连。

第（5）问按本题无策略约束的教材选路模型，先比较 AS_PATH：经 R11、R13 的路径各含 3 个 AS，经 R12 含 4 个，先排除 R12。在其余属性相同的候选中，再比较 AS 内到出口的距离。R14 到 R11 为 1 跳，到 R13 需经 R15 为 2 跳，选 **R11**；R15 到 R13 为 1 跳，到 R11 为 2 跳，选 **R13**。真实 BGP 还受本地优先级等属性影响，本题给定条件并不支持把 “AS 数少、出口近” 当成无条件覆盖所有策略的规则。

课程连接·成员管理与转发树分工

IGMP 像维护当前接收者集合，组播路由机制再按网络结构组织复制分支。知道本地有人加入，并不等于已经知道远端所有路径；TTL 只能限制错误环流寿命，不能替代合理的树结构。

4.21.4 例 4-13　卫星链路：瓶颈速率、窗口与 VLSM 各有约束

例 4.21.4 (配套例题)

配套例题。某公司工程部长期驻扎偏远山区，租用天通一号卫星通信链路连接工程部 R1 和总部 R2，网络如下图。S1、S2 为千兆以太网交换机；TR1、TR2 是卫星地面收发设备，实现全双工调制解调。卫星轨道高度 36000 km，电磁波传播速度 300000 km/s；卫星链路为 R1、R2 提供对称全双工信道，每方向数据传输速率 200 kb/s。

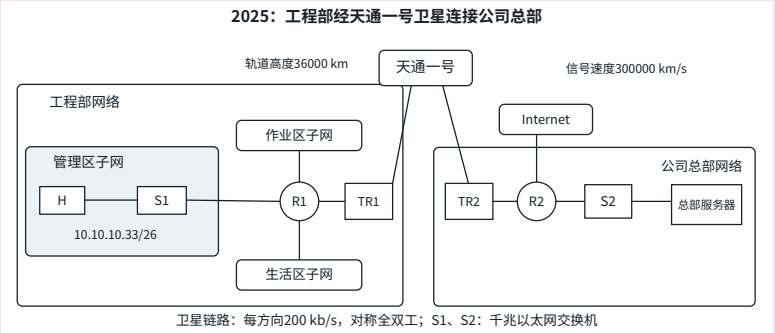


Figure 4.8: H 配置 10.10.10.33/26 并位于管理区；工程部还有作业区、生活区两个子网

（1）忽略卫星中继及 TR1、TR2 调制解调开销，卫星链路单向传播时延是多少？H 向总部服务器传输数据可达到的最大吞吐量是多少？忽略各层首部开销与以太网内传播时延，上传 4000 B 工程进度报告文件至少需要多久？

（2）用 GBN 为卫星链路设计单向可靠的数据链路层协议 SLP，支持 R1 向 R2 发送数据。SLP 数据帧长 1500 B，忽略 ACK 帧长度；要求单向信道利用率不低于 80%，发送窗口至少为多少？帧序号字段至少需要几位？

（3）总部分配 10.10.10.0/24 给工程部，需划给三个子网：生活区可分配地址不少于 120 个，作业区、管理区分别不少于 60 个，H 的地址配置正确。作业区、管理区、生活区的子网地址分别是什么？请用 CIDR 表示。

辨析·分类与 CIDR

分类编址按地址前缀判断类别；CIDR 按明确前缀长度解释，不能混用默认掩码。

解析。单向路径要经过“地面 → 卫星 → 地面”两段。按本题采用的几何模型，每段链路的长度取卫星高度，单向传播时延 $T_p = 2 \times 36000/300000 = \mathbf{0.24\ s}$。路径吞吐量受最慢链路限制，千兆以太网不能抬高 200 kb/s 的卫星瓶颈，因此 H 单方向最大吞吐量为 **200 kb/s**；全双工表示反方向另有同样容量，不能在一次上传中相加成 400 kb/s。

4000 B 经卫星链路发送需 $4000 \times 8/200000 = 0.16$ s。首部忽略时，最后一比特从卫星链路发送端到接收端还要传播 0.24 s，故教材模型给出的最短上传时间为 $0.16 + 0.24 = \mathbf{0.40\ s}$。这个 400 ms 还额外忽略了局域网的发送开销；题干给出的忽略项并不包含千兆链路上的发送与分帧，若要严格计入每段链路上的发送、分帧及存储转发，还需题目进一步指定相应条件。例如 4000 B 在一条 1 Gb/s 链路上仅串行发送也需 32 μs。因此 400 ms 适合作为本题理想下界，不能视为所有实际以太网转发方式下的精确完成时间。

SLP 每帧发送时延 $T_d = 1500 \times 8/200000 = 60$ ms；ACK 长度忽略，从开始发送首帧到收到其确认需 $60 + 2 \times 240 = 540$ ms。设窗口为 W，利用率 $U = \min(1, 60W/540)$；要求 $U \geq 0.8$，得到 $W \geq 7.2$，向上取整为 **8 帧**。GBN 接收窗口为 1，需 $2^k \geq W + 1 = 9$，所以序号字段最少 **4 bit**。3 bit 虽然有 8 个序号，却只能支持最大 7 帧的 GBN 发送窗口；其利用率 $7/9 \approx 77.78\%$，达不到要求。

最后按可用主机数决定块大小。生活区需 $2^7 - 2 = 126$ 个可用地址，至少占/25；另两区各需 $2^6 - 2 = 62$ 个，至少占/26。三块恰好用完 $128 + 64 + 64 = 256$ 个地址。H 的 10.10.10.33/26 锁定管理区为 10.10.10.0/26；生活区的/25 必须按 128 地址边界对齐，且不能与管理区重叠，只能取 10.10.10.128/25，留下 10.10.10.64/26 给作业区。

子网	CIDR 地址	可用地址范围	可用数量
作业区	**10.10.10.64/26**	10.10.10.65～10.10.10.126	62
管理区	**10.10.10.0/26**	10.10.10.1～10.10.10.62	62
生活区	**10.10.10.128/25**	10.10.10.129～10.10.10.254	126

4.22 分类地址、特殊地址与逐级划分

历史分类编址从地址前缀判断网络号长度：A 类首位 0、默认前缀 8 位；B 类首两位 10、默认前缀 16 位；C 类首三位 110、默认前缀 24 位。首字节分别位于 1～126、128～191、192～223 的普通单播类别，0 和 127 另有用途。D 类前四位 1110 即 224.0.0.0/4 为组播；E 类为保留类别。CIDR

按显式前缀长度解释地址，不能再由首字节机械决定掩码。

普通广播子网中，主机部分全 0 表示该网络，全 1 表示定向广播，主机号占 h 位时通常可分配 $2^h - 2$ 个地址。路由器接口也占用其中的地址；若题目另给点对点特殊编址，应按其规则计算。受限广播 255.255.255.255 只用于本地范围；0.0.0.0 可在主机尚未获地址时作源地址；127.0.0.0/8 用于环回，不作为链路上普通主机的可路由地址。

私有 IPv4 地址段为 10.0.0.0/8、172.16.0.0/12、192.168.0.0/16。它们在不同私网中可以重复使用，访问公网通常结合 NAT、代理或其他出口机制。NAT 按映射改写地址，NAPT 还按端口区分多个内部会话；公网端不能只凭一个共享公网地址就唯一确定内网进程。NAT 表项、端口和回程处理须保持同一连接方向，涉及 TCP/UDP 伪首部时也要更新校验和。

方法·先需求后对齐

把主机与网关需求合计，再选择足够大的 2 次幂地址块，并检查边界对齐。

4.22.1 用一个地址块同时满足不同主机需求

现有 128.14.32.128/27 共 32 个地址。网吧需要 12 台主机，再加网关 1 个，普通子网至少需要 14 个可用位置，可分配 128.14.32.128/28：网络.128、广播.143，主机.129～.142。家庭 5 台主机加网关 1 个，正好使用 128.14.32.144/29 的 6 个可用地址.145～.150，广播.151。点对点的主机和路由器采用普通`/30`模型，分配 128.14.32.152/30，可用.153、.154，广播.155。剩余.156～.159 组成另一个`/30`。

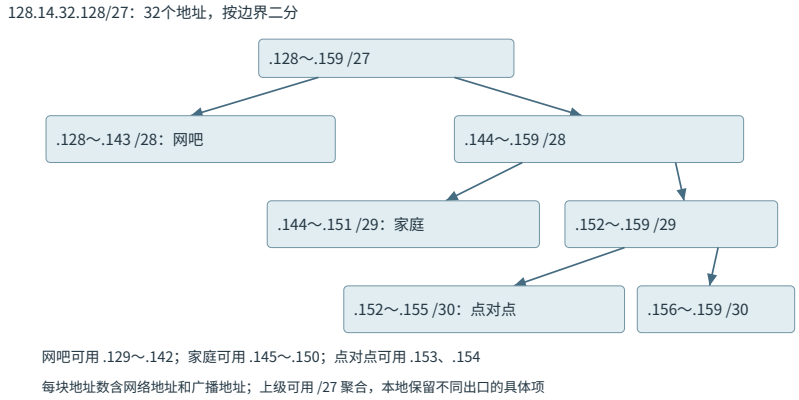


Figure 4.9: 同一/27 逐级二分为/28、/29 与两个/30，块边界与地址范围对应

这些子块都按其大小边界对齐，且互不重叠。上级路由器可以用 128.14.32.128/27 概括这批地址；本地路由器仍须保留指向不同出口的更具体子网项。概括地址包括尚未分配的.156/30，转发时要结合更具体路由、默认路由及丢弃策略避免形成环路。最长前缀匹配匹配的是前缀长度，不是表项顺序或数字大小。

4.23 OSPF 的数据库同步与五种分组

LSDB 是链路状态数据库，LSA 是其中的一份链路状态通告，LSA 头包含用来辨认通告及其新旧程度的信息。OSPF 分组承载这些信息，不能把 “LSA” 与 “LSAck 分组” 混为同一个缩写。

类型值	分组	一次同步中的作用
1	Hello 问候	发现和维持邻居，检查建立关系所需的参数
2	DD 数据库描述	发送 LSDB 摘要，即相应 LSA 的头信息
3	LSR 链路状态请求	对照摘要，请求缺少或更新的 LSA
4	LSU 链路状态更新	发送所需 LSA 的具体内容，也可洪泛变化
5	LSAck 链路状态确认	确认已收到哪些 LSA，支持可靠洪泛

同步顺序可理解为 “认识邻居—交换目录—索取缺项—传送正文—确认收到”。这是一条教学依赖链，不要求每次稳定运行都重新同步完整数据库；收到重复 LSU 时仍可能需要确认，但应避免无限重复洪泛。Hello 间隔和失效时间由网络类型与配置决定；课件示例每 10 s 问候、40 s 超时，是该示例的参数。

变化的链路信息在规定范围内洪泛，使相关路由器更新数据库，再独立运行 Dijkstra 计算最短路径树。区域限制拓扑细节和洪泛范围；区域间、外部路由的通告类型和传播范围按 OSPF 规则处理，不能把 “每个区域有自己的详细数据库” 理解为跨区完全不交换可达信息。

条件·转发表还需递归解析

BGP 的 NEXT_HOP 未必是本地邻居，要通过 IGP 确定实际出口。

4.24 RIP 坏消息与 BGP 会话的区别

RIP 直连网络距离按本章教材计 1，每跨过一个路由器再加 1；周期更新通常 30 s，课件失效判断示例为 180 s。触发更新在发现变化时尽快通告，水平分割和毒性逆转用于减少特定回路，但距离向量仍须警惕计数到无穷。若 A 到网络 N 的旧路径经 B，而 B 又把从 A 学到的路径报回 A，双方可能逐次把距离加大；不能因每次都选择收到的最小值，就断定网络中绝无环路。

BGP 通过 TCP 建立会话。不同 AS 之间的会话为 eBGP，同一 AS 内传播 BGP 信息的会话为 iBGP。基本完整网状 iBGP 用于避免同一 AS 内继续转发 iBGP 学习路由所形成的问题，实际规模化部署还可用路由反射器等机制。iBGP 邻居不必物理直连，AS_PATH 也不是内部逐台路由器的名单。

BGP 基本报文有 OPEN、UPDATE、KEEPALIVE、NOTIFICATION。OPEN 在 TCP 连接成功后交换会话参数；UPDATE 发布或撤销路由；KEEPALIVE 维持会话；NOTIFICATION 报告错误并结束会话。变化通告与保活是不同任务，不能把 KEEPALIVE 理解为周期重发全部路由。

选路先执行题目给定的策略。例如课件简化次序依次比较本地偏好、AS 路径长度、到出口的域内代价、BGP 标识符；真实 BGP 还有其他属性与规则。经 iBGP 得到的 NEXT_HOP 未必等于本机实际转发表中的下一跳，仍须借助 IGP 找到通往该 BGP 下一跳的本地出口。

4.25 IPv6 字段、地址与自动配置

IPv6 基本首部 40 B：版本 4 bit、流量类别 8 bit、流标签 20 bit、有效载荷长度 16 bit、下一首部 8 bit、跳数限制 8 bit、源与目的地址各 128 bit。有效载荷长度计基本首部之后的扩展首部及上层内容；下一首部可指扩展首部，也可指 TCP、UDP 等上层协议。流量类别和流标签为分类处理提供信息，端到端带宽、时延保证仍需网络资源和相应机制配合。

IPv6 可进行无状态地址自动配置，也支持 DHCPv6 等管理方式。接口标识符的生成可以采用多种方案，不能一概由 MAC 地址直接拼接。未指定地址为`::`，环回为`::1`，链路本地单播属于 `fe80::/10`，组播属于 `ff00::/8`。任播给多个接口配置同一地址，数据按路由规则到达其中一个，表示“一组中的一个”，并非每个接收者都获得一份。

压缩 `2001:0db8:85a3:0000:0000:8a2e:0370:7334` 可写为 `2001:db8:85a3::8a2e:370:7334`。每组只可去前导 0，不能删掉 `370` 末尾的 0；`::`出现一次，恢复时补到 8 组。双栈让设备同时运行 IPv4 和 IPv6，隧道将一类 IP 分组封装到另一类 IP 分组的数据区中，内外首部的端点含义分别读取。

辨析·自动配置有多种方式

IPv6 既支持无状态自动配置，也支持 DHCPv6，接口标识符不必来自 MAC。

4.26 主动回忆自测

以下为自拟题，先写当前观察的层与接口，再列必要条件。

1. `192.168.10.131/26` 所在网络、广播和普通可分配地址范围分别是什么？
2. 目的 10.1.2.3 同时匹配`/8`、`/16`、`/24`，距离分别为 1、8、20，应选哪条？
3. IPv4 数据区 1600 B、首部 20 B，经 MTU620 B 链路分片，非末片最大数据区和第二片偏移是多少？
4. 主机加入本地组播组后，IGMP 是否已经算好全网的无环转发树？
5. 路由与转发有什么区别？SDN 逻辑集中是否要求只有一台物理控制器？
6. 向异地目的主机发包时，源主机先 ARP 最终目的 IP 还是下一跳 IP？NAT 改写源 IP 后哪些校验可能受影响？
7. 初次 DHCP 获取地址的 Request 阶段，能否把 Offer 提出的地址立即用作 IP 源地址？
8. 比较 IPv4 与 IPv6 的首部校验、广播和路由器分片行为；IPv6 地址空间是 IPv4 的多少倍？
9. RIP、OSPF、BGP 分别交换什么信息，由什么直接承载？
10. 移动 IPv4 隧道的内外层目的地址分别代表什么？为什么已查到出口后仍可能排队？

4.26.1 核对答案

1. 网络 192.168.10.128，广播 192.168.10.191，可分配.129～.190。 **2.** 选匹配最长的`/24`；同前缀候选如何选优是另一层判断。 **3.** 每个非末片数据 600 B，第二片偏移 $600/8 = 75$；偏移不累计各片首部。

4. 没有，IGMP 管理本地成员，跨网转发树由相应组播路由机制组织。 **5.** 路由计算路径和表；转发查出口。逻辑集中可由多台控制服务器实现。 **6.** ARP 下一跳 IP；更新 IPv4 首部校验，以及启用的 TCP/UDP 伪首部校验。

7. 不能，初始选择阶段通常仍用源 0.0.0.0、广播目的，请求后收到 ACK 才确认使用。 **8.** IPv4 有首部校验且允许路由器分片；IPv6 无首部校验、广播和路由器分片。地址空间之比 2^{96}。 **9.** RIP 交换距离向量，经 UDP；OSPF 交换链路状态，直接经 IP；BGP 交换可达前缀和路径属性，经 TCP。

10. 内层目的为归属地址，外层为转交地址。出口竞争、交换结构或队首阻塞可引起排队。