408 自学讲义

计算机组成原理

例题就近解析，自测题在章末给出答案。

A4 单栏 · 2026 年 10 月

目录

阅读约定 **iii**

1 计算机系统与程序执行的层次 **1**

1.1 从程序看计算机的功能部件 1
1.2 存储程序怎样变成一次次指令执行 2
1.3 性能计算：先确定谁的时间在改变 3

2 数据表示、位级运算与浮点数 **5**

2.1 位串与数值之间还差一个解释规则 5
2.2 定点编码：范围先于运算规则 5
2.3 截断、扩展与 C 类型转换 6
2.4 加法器怎样同时支持加与减 7
2.5 CF 与 OF 分别判断什么 7
2.6 乘除运算必须保留的中间量 8
2.7 IEEE 754：字段既规定精度，也规定特殊情况 10
2.8 浮点加减：对阶丢位以后还要判断舍入 11

3 存储层次、地址与 Cache **13**

3.1 为什么一个程序同时使用几层存储器 13
3.2 SRAM、DRAM 与 Flash 保存信息的方式 13
3.3 地址引脚不总等于地址位数 13
3.4 单体多字和多体交叉怎样提高带宽 14
3.5 主存芯片怎样连到 CPU 15
3.6 磁盘与 SSD 的一次访问花在哪些时间上 16
3.7 Cache 命中率怎样变成时间 17
3.8 地址拆分决定块能放在哪里 17
3.9 LRU 更新的是访问次序，不只是装入次序 18
3.10 写命中与写缺失是两个独立问题 19
3.11 虚拟存储器怎样让程序看到地址空间 19
3.12 页表与 TLB：地址偏移为何原样保留 19
3.13 段式与段页式地址为什么需要界限检查 21
3.14 跨页数组访问：页、Cache块与遍历次序分别计算 21

4 指令系统与 C 程序的机器级表示 24
4.1 指令字段怎样决定可表示的操作和地址 . . . 24
4.2 从形式地址到有效地址 . . . 24
4.3 大端、小端和对齐解决不同问题 . . . 25
4.4 RISC 与 CISC：设计倾向不代替具体实现 . . . 26
4.5 编译、汇编、链接怎样确定程序中的地址 . . . 27
4.6 分支和循环怎样改变 PC . . . 27
4.7 过程调用为什么要保存返回位置 . . . 28

5 CPU、数据通路、控制器与异常中断 30
5.1 寄存器的名字说明它暂存什么 . . . 30
5.2 指令周期、机器周期与时钟周期 . . . 31
5.3 一条指令怎样变为微操作 . . . 31
5.4 控制信号由组合逻辑还是微程序产生 . . . 33
5.5 异常、中断与返回位置 . . . 34

6 流水线与并行处理的基本模型 36
6.1 延迟和完成间隔是两个量 . . . 36
6.2 阶段寄存器保存的不只是一份数据 . . . 36
6.3 冒险先按冲突对象分类 . . . 37
6.4 超标量与动态流水线允许哪些重叠 . . . 39
6.5 一条指令处理多个数据，还是多个指令流 . . . 39
6.6 硬件线程、多核与共享内存 . . . 40

7 总线：一次事务怎样占用时间 41
7.1 位宽、频率、传送率分别给出什么 . . . 41
7.2 一次总线事务从地址到应答 . . . 42

8 I/O接口、程序中断与 DMA 45
8.1 端口是接口中可访问的位置 . . . 45
8.2 查询方式：等待和搬运都由 CPU 安排 . . . 45
8.3 中断方式：先请求，再响应，再运行服务程序 . . . 46
8.4 DMA：数据不经过 CPU 寄存器逐次搬运 . . . 48

题目索引 50

方法索引 52

阅读约定

例题中的【年份】表示 408 真题；〖节号-题号〗表示王道书相应节的习题编号。改动原题条件时标为“改编”；补充题另标“原创”。先根据题目条件辨认模型，再阅读连续的计算或执行过程。

本讲义默认下标、指针、位数和计量单位在初次使用处定义。同一个字母在不同主题中可能表示不同的量，以当前定义为准。并发过程、地址转换和通信时序中的结论都依赖给定假设；题目改变条件时，应重新检查解法成立的前提。

正文末尾附题目索引与方法索引，可从目录或书签跳转；索引右侧为正文页码。

第1章　计算机系统与程序执行的层次

1.1 从程序看计算机的功能部件

计算机系统由硬件和软件共同构成。硬件提供保存信息、执行运算、控制步骤和输入输出的物理装置，软件用程序和数据规定装置怎样完成任务。只看处理器芯片，不能判断一个应用是否能运行；还要看指令集、操作系统、库及文件格式等条件。

计算机的五个基本功能部件是运算器、控制器、存储器、输入设备和输出设备。这个分类按**功能**划分，不是按芯片外壳划分。CPU 通常包含运算器、控制器和寄存器，还可能集成若干级 Cache；一个存储控制器也可能集成在处理器芯片内。

部件	在执行 c=a+b 时做什么
运算器	对取来的两个数进行加法，形成结果及有关标志
控制器	解释指令，在合适时刻发出选择、读写和运算等控制信号
存储器	保存指令、a、b、c 及执行所需的其他信息
输入、输出设备	将系统外部的信息送入系统，或把系统内的结果送出

中央处理器 CPU 的数据通路包括寄存器、运算部件及其连接，控制器决定数据在通路上何时、向哪里流动。第5章将把一次加法展开为寄存器传送；这里先把“处理数据”和“控制步骤”分清。

主存储器能由 CPU 直接按地址访问，程序执行时所需的指令和数据通常要进入主存。磁盘、SSD 等外存提供较大且非易失的存储空间，不能把“文件保存在磁盘”解释成 CPU 每执行一条指令都直接向磁盘取一次。

ISA 规定什么，微体系结构决定什么

指令集体系结构 ISA 是软件可见的机器接口，规定机器指令的功能和编码、软件可见的寄存器、数据类型、寻址方式以及相关的存储访问规则。微体系结构是在该接口约束下怎样组织和实现机器，例如采用几级流水线、怎样转发数据、Cache 怎样实现、加法器采用何种进位结构。

同一个整数加法的机器指令，可以由不同硬件通路实现。只要软件可见的效果符合 ISA，程序不必知道内部用了串行进位还是先行进位。不过，机器码能执行还涉及运行环境；“同一 ISA”不自动保证不同操作系统的可执行文件可直接互用。硬件与软件能实现相同逻辑功能，也不表示两者的时间、成本和可修改性相同。

1.2 存储程序怎样变成一次次指令执行

存储程序的基本思想是：执行前把程序指令和数据存入存储器，运行时自动取出指令、解释并执行。指令和数据都可以用二进制编码，机器根据当前操作和访问位置解释其含义。同一串位并没有脱离上下文的“指令身份”或“数据身份”。

冯·诺依曼型计算机按指令控制执行过程，常称控制流驱动。遇到转移、调用或异常中断时，下一步不再简单地取顺序地址上的指令，但仍由确定的控制机制改变执行位置。“存储程序”也不要求指令执行期间永远不能修改程序所在的存储内容。

程序计数器 PC 保存指令执行所需的地址信息。最小的顺序执行过程可以写成：

1. 根据 PC 访问指令所在存储单元，取得指令。
2. 解释操作码和有关字段，取得操作数。
3. 执行运算、访存或控制转移，保存结果。
4. 按顺序地址或转移目标更新执行位置，继续取指。

这里的顺序地址增量取决于指令长度和地址单位。按字节编址、指令长4 B时，顺序地址通常增加4；不能把所有机器的 PC 更新都写成“加1”。流水线中取指、译码、执行还可能重叠，程序员看到的指令语义与内部时序应分开。

从 C 源文件到 CPU 能执行的内容

在常见的静态编译流程中，预处理展开头文件和宏等指令；编译把高级语言转换为汇编形式；汇编把汇编指令编码成可重定位目标文件；链接合并目标文件与所需库，处理符号引用和重定位，形成可执行文件。装入程序再根据可执行文件的组织建立进程的地址空间，准备执行入口。

汇编语句 `add` 是便于人阅读的符号，CPU 取到的是其机器编码。宏、伪指令还可能展开为零条、一条或多条机器指令。一条 C 语句也可能展开为多条指令；反过来，编译优化可能把多条 C 语句合并或删除。

例 1-1　硬件直接执行哪一种程序

【2015】 计算机硬件能够直接执行的是（　）。

I. 机器语言程序　II. 汇编语言程序　III. 硬件描述语言程序

A. 仅 I　B. 仅 I、II　C. 仅 I、III　D. I、II、III

解析。 普通指令执行硬件按 ISA 识别机器编码，因此 I 成立。汇编语言必须经过汇编，硬件描述语言用于描述和设计硬件，不能作为普通机器指令直接送入 CPU 执行。答案为 **A**。题目问的是执行接口，而不是哪种语言更接近硬件。

解释执行是另一种程序执行方式：解释器读取源程序或中间表示，并在运行时实施相应操作。实际解释器本身仍由机器指令运行。现代语言实现也可能结合解释、预编译和即时编译，不能用“高级语言都逐行解释”概括。

1.3 性能计算：先确定谁的时间在改变

响应时间是从提出任务到得到结果经历的时间；吞吐量是单位时间内完成的任务量。增加处理器可以让多个独立任务同时进行，因而可能提高系统吞吐量；一个不能并行的单线程任务却不因此自动缩短执行时间。

程序的总运行时间还可能包含 I/O 等待、系统调度等。CPU 时间是 CPU 为该程序工作所花的时间。本节的基本性能式只计算指定口径的 CPU 时间：

$$T_{\text{CPU}} = \frac{N \times \overline{\text{CPI}}}{f} = N \times \overline{\text{CPI}} \times T_{\text{clk}}.$$

N 是实际执行的指令条数，不能用程序文件中的静态指令条数代替；f 是主频，单位 Hz；$T_{\text{clk}} = 1/f$ 是时钟周期；平均 CPI 是每条指令平均占用的时钟周期数。若第 i 类指令执行 n_i 条、平均 CPI 为 c_i，则

$$\overline{\text{CPI}} = \frac{\sum_i n_i c_i}{\sum_i n_i}.$$

不能把不同类指令的 CPI 不加权地平均。CPI 还受 Cache 缺失、流水线停顿等影响，并非仅由指令操作码决定。流水线稳态下 CPI 可以接近1；多发射处理器的平均 CPI 也可以小于1，它不表示一条指令的全部处理延迟小于一个时钟周期。

例 1-2　主频相同，怎样由指令组成求时间

【2022】 某计算机主频为1 GHz，程序 P 运行过程中共执行10000条指令，其中80%的指令执行平均需1个时钟周期，20%的指令执行平均需10个时钟周期。程序 P 的平均 CPI 和 CPU 执行时间分别是（　）。

A. 2.8，28 μs　B. 28，28 μs　C. 2.8，28 ms　D. 28，28 ms

解析。 条件给的是动态指令比例，先求加权平均：$0.8 \times 1 + 0.2 \times 10 = 2.8$。总周期数为 $10000 \times 2.8 = 28000$；1 GHz 对应每周期1 ns，因此 CPU 时间为28000 ns，即28 μs。答案为 **A**。百分比必须乘各类周期数，GHz 与 μs 的换算不能略去。

例 1-3　CPU 加快后，I/O 时间怎样处理

【2012】 假定基准程序 A 在某计算机上的运行时间为100 s，其中90 s为 CPU 时间，其余为 I/O 时间。若 CPU 速度提高50%，I/O 速度不变，则运行基准程序 A 所耗费的时间是（　）。

A. 55 s　B. 60 s　C. 65 s　D. 70 s

解析。 “速度提高50%”是原速度的1.5倍，因此原来的90 s变为 $90/1.5 = 60$ s，而非减少 45 s。I/O 仍占10 s，总时间为70 s，选 **D**。

一般地，原运行时间中比例 p 的部分加快为原速度的 s 倍，其余不变，且两部分时间可以这样相加时，加速比为

$$S = \frac{1}{(1-p) + p/s}.$$

该式的上限是 $1/(1-p)$，但前提是加速部分划分和时间模型成立。若 I/O 与计算本来重叠，或并行化新增了通信与同步开销，应先画出实际时间关系，不能直接把各部分都相加。

比较性能时，为什么不能只看主频或 MIPS

两台机器的时间之比同时包含指令条数、平均 CPI 和主频。相同源程序在不同 ISA、不同编译器下可能有不同的动态指令条数。即使平均 CPI 相等，也不能仅凭主频断言谁完成同一任务更快。

MIPS 是每秒执行的百万条指令，$\text{MIPS} = f/(\overline{\text{CPI}} \times 10^6)$；IPC 是每周期平均完成的指令数，在统计区间一致时与平均 CPI 互为倒数。MFLOPS 等指标统计浮点运算次数，与机器指令条数不是同一量。跨机器比较应优先比较同一任务的实际时间，再看指标如何解释差异。

机器字长主要反映 CPU 一次处理整数数据的基本位宽。它关系到整数表示范围和相关运算能力，但不能单独推出主存容量、总线宽度或某程序的速度。“64位机器”也不表示所有数据类型都占64位。

自测

1. 【2014】程序 P 在机器 M 上的执行时间是20 s。编译优化后，P 执行的指令数减少到原来的70%，而 CPI 增加到原来的1.2倍，则 P 在 M 上的执行时间是（ ）。A. 8.4 s　B. 11.7 s　C. 14 s　D. 16.8 s。
2. 原创补充：两个任务都由同一单核 CPU 各执行2 s。换成两核后，每个任务仍占用一个核执行2 s，且可同时开始。两个任务的总完成时间和单个任务的响应时间分别怎样变化?

答案。1. D。主频不变，时间变为 $20 \times 0.7 \times 1.2 = 16.8$ s。2. 两个任务全部完成的时间从4 s降为2 s；无排队时单个任务本身的执行时间仍为2 s。该小例用于区分吞吐量改善与单任务加速。

第2章　数据表示、位级运算与浮点数

2.1 位串与数值之间还差一个解释规则

位是取0或1的二进制位，字节 B 在本讲义中为8位，bit 写作 b。同一位串可以解释成无符号整数、补码整数、浮点数或字符编码。计算前必须同时确定**位宽、编码和小数点位置**，不能看见最高位为1就断言“这个数是负数”。

r 进制采用位置权，$(a_k\cdots a_0.a_{-1}\cdots)_r$ 的值是 $\sum_i a_i r^i$，其中 $0\le a_i<r$。二进制与八进制、十六进制转换时，从小数点向两侧分组：每3位一组对应一位八进制，每4位一组对应一位十六进制；整数端左侧补0，小数端右侧补0。

例 2-1　整数与小数分别换基数

〖2.1-001〗 若十进制数为137.5，则其八进制数为（　）。

A. 89.8　B. 211.4　C. 211.5　D. 1011111.101

解析。 $137=2\times8^2+1\times8+1$，小数部分 $0.5\times8=4$，因此为 $(211.4)_8$，选 **B**。八进制数字只能是0至7，A 本身就不是合法八进制数。分组也可验证：$137.5=(10001001.1)_2=(010\ 001\ 001.100)_2$。

十进制整数转二进制可反复除2取余、倒序排列；小数则反复乘2取整数、顺序排列。有限十进制小数未必能写成有限二进制小数，例如0.1的二进制表示无限循环。保存有限位时会发生近似，这正是后面浮点舍入出现的原因之一。

2.2 定点编码：范围先于运算规则

真值是按通常数学符号写出的数值；机器数是采用约定编码保存的位串。定点表示是约定小数点位置固定，不表示存储器真的另存了一个小数点。

对 n 位整数，常用编码如下。

编码	最高位和数值含义	表示范围
无符号	所有位均有正权	0 至 2^n-1
原码	最高位为符号，其余为绝对值	$-(2^{n-1}-1)$ 至 $2^{n-1}-1$，两个零
反码	正数同原码，负数的数值位取反	与原码相同，两个零
补码	最高位权为 -2^{n-1}，其余为正权	-2^{n-1} 至 $2^{n-1}-1$，一个零

8位补码 `1111 1101` 的值为 $-128+64+32+16+8+4+1=-3$。也可先把它作为无符号数253，再因最高位为1减去256，得到−3。后一方法适合十六进制机器数：对 n 位补码，若无符号解释为 u，则真值是 u 或 $u-2^n$。

求一个负整数的补码时，可在给定位宽下把其绝对值逐位取反再加1；位宽不能省。8位中 -128 编码为 `1000 0000`，它的数学相反数128不能用8位补码表示。“取反加1”仍得到同一位串，反映的是模256运算，而不是已经得到可表示的正128。

原码中的 `1000 0000` 表示−0，补码中则表示−128。反码的−0是 `1111 1111`。对于常见的偏置 2^{n-1} 的整数移码，有 $E = x + 2^{n-1}$，与对应补码相比只需翻转最高位；IEEE 754 阶码的偏置通常为 $2^{k-1}-1$，不可套用“翻转最高位”这一特殊关系。

若采用一位符号、$n-1$ 位小数的补码定点小数，最高位权为−1，其余权从 2^{-1} 至 $2^{-(n-1)}$，范围为 $[-1, 1-2^{-(n-1)}]$。同样的位串改变小数点位置，真值就按2的幂缩放。

2.3 截断、扩展与 C 类型转换

位宽变小时，硬件截取低位；能否保留原数值，要检查被丢掉的位。位宽增大时，无符号数在高位补0，有符号补码数复制符号位。原码、反码各有自己的扩展规则，不能用补码规则覆盖所有编码。

8位补码−3扩为16位是 `1111 1111 1111 1101`，无符号253扩为16位则是 `0000 0000 1111 1101`。扩展后低8位相同，真值不同。**扩展方式首先取决于源数怎样解释，而不是目标类型名字中有没有 unsigned**。

例 2-2　无符号短整数扩展

【2012】 假定编译器规定 int 型和 short 型长度分别为32位和16位，执行下列 C 语言语句：

```
unsigned short x = 65530;
unsigned int y = x;
```

得到 y 的机器数为（　）。

A. 0000 7FFAH　B. 0000 FFFAH　C. FFFF 7FFAH　D. FFFF FFFAH

解析。 $65530 = 65536 - 6 =$ `FFFAH`，源类型是无符号16位数，扩展补0，得到 `0000 FFFAH`，选 **B**。最高位为1在这里是普通数值位，不是负号。

例 2-3　负的 short 转成 unsigned int

【2025】 在32位计算机上执行下列 C 语言代码段后，ui 的值是（　）。

```
short si = -32767;
unsigned int ui = si;
```

A. $2^{15}-1$　B. $2^{15}+1$　C. $2^{32}-2^{15}-1$　D. $2^{32}-2^{15}+1$

解析。 按题目的16位 short、32位 unsigned int 模型，−32767的16位补码为 `8001H`。数值转换为32位无符号整数后，得到与−32767模 2^{32} 同余的数，即 $2^{32}-32767 = 2^{32}-2^{15}+1$，机器数为 `FFFF 8001H`，选 **D**。把 `8001H` 直接补0会把负的源值误当成无符号32769。

C 中的 usual arithmetic conversions 也会改变比较方式。若32位 `int i=-1` 与32位 `unsigned u=1` 比较，常见模型下 i 转为无符号 $2^{32}-1$，所以 `i<u` 为假。需要先处理整数提升和通常算术转换，再决定比较哪种值。

本讲义中“截断取低位”的位级推演按题设机器模型进行。C 语言本身不保证有符号溢出按补码绕回：有符号加法溢出属于未定义行为；按本讲义采用的 C11/C17 口径，超范围转换到有

符号类型还涉及实现规定。考题若明确给机器位宽和截断模型，可据模型计算；编写可移植 C 程序时不能把这些题设当成语言的普遍保证。

移位先问逻辑还是算术

逻辑右移高位补0，算术右移复制符号位；左移均在低位补0，但如何解释结果及是否溢出仍取决于编码。8位补码−3算术右移1位得到−2，相当于向负无穷方向取整；整数除法−3/2通常向零截断得到−1，两者不能无条件互换。左移使被丢弃的高位无法恢复，也不因“低位补0”就保证数值恰好乘2。

2.4 加法器怎样同时支持加与减

一位全加器接收 A_i, B_i, C_i，产生和位 S_i 与向高位的进位 C_{i+1}：

$$S_i = A_i \oplus B_i \oplus C_i, \qquad C_{i+1} = A_iB_i + (A_i \oplus B_i)C_i.$$

定义进位生成 $G_i = A_iB_i$、进位传递 $P_i = A_i \oplus B_i$，即可逐层展开进位表达式。串行进位需等低位进位逐级传播；先行进位用更复杂的组合逻辑并行形成若干进位，缩短关键路径。更快的进位结构没有改变加法的数值规则。

加减运算器用控制位 Sub 将第二输入按位与 Sub 异或，同时令最低进位 $C_0 = \text{Sub}$。Sub=0 时执行 $A + B$；Sub=1时执行 $A + \overline{B} + 1$，即模 2^n 的减法。算术逻辑部件 ALU 还通过选择控制实现与、或、异或等逻辑操作；移位器是否属于图中 ALU 的内部，要依具体数据通路图判断。

例 2-4　减法器的两路输入不直接送负数符号

〖2.2-018〗 某计算机字长为8位，CPU 中有一个8位加法器。已知无符号数 $x = 69, y = 38$，若在该加法器中计算 $x - y$，则加法器的两个输入端信息和输入的低位进位信息分别为（　）。

A. 0100 0101、0010 0110、0
B. 0100 0101、1101 1001、1
C. 0100 0101、1101 1010、0
D. 0100 0101、1101 1010、1

解析。 $69 = 0100\ 0101$，$38 = 0010\ 0110$。第二路取反为 `1101 1001`，另由最低进位补上1，所以选 **B**。若第二路已取反加1又令最低进位为1，就重复加了1。运算实际为 $69+217+1 = 287$，低8位31、最高进位1，符合 $69 - 38 = 31$。

2.5 CF 与 OF 分别判断什么

同一次加法器运算可以同时按有符号和无符号两种规则解释，因此产生不同用途的标志。ZF 表示结果低 n 位是否全0，SF 等于结果最高位；SF=1并不自动表示数学真值为负，还要确认按有符号解释且未发生有符号溢出。

对于加法，CF 反映最高位向外进位；对于本讲义采用的“CF=1表示借位”约定，减法的 CF 为最高进位的反值。可统一写为 $\text{CF} = C_n \oplus \text{Sub}$。某些 ISA 用“无借位”作为减法进位标志，遇到题设必须改用其约定。

OF 判断有符号结果是否越出补码范围：加法时同号相加而结果异号会溢出；减法时两操作数异号且结果符号与被减数不同会溢出。也可用符号位的进位和出位异或：$\mathrm{OF}=C_{n-1}\oplus C_n$。它不要求把符号位当成独立的符号去做原码运算。

例 2-5　十六进制补码相减

【2018】 假定有符号整数采用补码表示，若 int 型变量 x 和 y 的机器数分别是 FFFF FFDFH 和 0000 0041H，则 x、y 的值及 x−y 的机器数分别是（　）。

A. x=−65，y=41，x−y 的机器数溢出
B. x=−33，y=65，x−y 的机器数为 FFFF FF9DH
C. x=−33，y=65，x−y 的机器数为 FFFF FF9EH
D. x=−65，y=41，x−y 的机器数为 FFFF FF96H

解析。 `FFFFFFDFH` 距 2^{32} 差33，故 x=−33；`41H` 是十进制65。数学结果为−98，在32位补码范围内，机器数为 $2^{32}-98=$ `FFFFFF9EH`，选 **C**。十六进制的41不能按十进制41读。

例 2-6　有符号减法为何仍会产生借位

【2023】 已知 x、y 为 int 类型，当 x=100、y=200时，执行“x减y”指令得到的溢出标志 OF 和借位标志 CF 分别为0、1。那么当 x=10、y=−20时，执行该指令得到的 OF 和 CF 分别是（　）。

A. OF=0，CF=0　B. OF=0，CF=1　C. OF=1，CF=0　D. OF=1，CF=1

解析。 有符号真值为 $10-(-20)=30$，可表示，OF=0。若按无符号解释输入位串，−20对应 $2^{32}-20$，10小于它，减法需要借位，CF=1，选 **B**。题目已经用100−200说明了借位标志约定，不能把两个标志都按有符号真值判断。

条件转移利用这些标志完成比较。先计算 $a-b$：无符号 $a<b$ 对应 CF=1，无符号 $a>b$ 对应 CF=0且ZF=0；带符号 $a<b$ 对应 SF $\neq$ OF，带符号 $a>b$ 对应ZF=0且SF=OF。用 SF 单独判断带符号大小，会在溢出时失败。

2.6　乘除运算必须保留的中间量

无符号乘法：为什么需要部分积和双倍位宽

两个 n 位无符号数的精确乘积最多需要 $2n$ 位。以王道书 §2.2中的13乘11为例：$13=1101_2$，$11=1011_2$。乘数从低位到高位为1、1、0、1，部分积依次是13、26、0、104，总和143，即 `1000 1111`。

顺序乘法器可以每轮检查乘数最低位，决定是否把被乘数加到部分积高半部，再将“进位—部分积—乘数”组合右移。部分积开始为0，循环 n 次后得到 $2n$ 位积。相应的等价算法也可让被乘数左移、乘数右移，把选中的部分积加到双倍宽累加器；两种寄存器布局的逐轮数值不同，不应把一种布局的移位规则抄到另一种。

对13×11，用双倍宽累加器的轨迹如下：

本轮乘数低位	本轮被乘数	累加器更新后	乘数右移后
1	13	13	5
1	26	39	2
0	52	39	1
1	104	143	0

带符号乘法不能把负数的补码直接当成同宽无符号数求完整积。Booth 法在乘数末端附一位0，考察相邻两位 q_iq_{i-1}：01时加被乘数，10时减被乘数，00或11不加减，再对组合寄存器算术右移。符号扩展和足够宽的中间寄存器是条件，最小负数的取负尤其需要保护位。

以4位补码的−3×5说明Booth法（原创机制示例）。乘数寄存器Q为4位，附加位q_{-1}为1位，A采用5位补码以保留保护位，被乘数M=−3也扩成5位。初态A=00000、Q=0101、$q_{-1}=0$。每轮先看Q_0q_{-1}，对A加减M，再把A、Q、q_{-1}连接成10位整体算术右移；A的最低位移入Q最高位，Q最低位移入q_{-1}。

轮次	判断位	移位前操作及A真值	移位后的A	移位后的Q	q_{-1}
1	10	A−M=3	00001	1010	1
2	01	A+M=−2	11111	0101	0
3	10	A−M=2	00001	0010	1
4	01	A+M=−2	11111	0001	0

四轮后AQ为9位11111 0001，去掉冗余符号保护位即8位1111 0001，真值为−15。移位时必须复制A的符号位，并在寄存器边界传位；把A、Q分别右移会丢掉跨界位，得到错误乘积。

阵列乘法器把部分积生成和压缩求和铺成组合电路，可能在一个足够长的时钟周期内完成；顺序乘法器复用 ALU 和移位器，通常跨多个周期。“一个周期”不能脱离所用电路和时钟周期长度讨论。常数乘法可以在保持规定语义的前提下化为移位与加减，例如 $13x=(x\ll 3)+(x\ll 2)+x$。

除法：商来自每一步余数比较

以无符号7÷3为例，按被除数的有效位 111 从高到低处理，初始余数 R=0。每读入一位，先令 $R\leftarrow 2R+b$，若 R⩾3则减3并在商中记1，否则记0。

读入位	比较前余数	本位商	本步余数
1	1	0	1
1	3	1	0
1	1	0	1

商为 010 即2，余数1，满足 $7=2\times 3+1$ 且 $0\le R<3$。硬件通常固定处理整个位宽，在前面补零位，不会因此改变结果。恢复余数法先试减，负了再加回；不恢复余数法根据余数符号决定下一轮加还是减，用不同轨迹完成同一任务。

不恢复余数法也可用同一7÷3观察。令余数R为4位有符号寄存器、Q为3位，除数D=3，初态R=0、Q=111。每轮先把R、Q连接左移一位，Q最高位移入R最低位；若上一轮R非负，本轮减D，若上一轮R为负则加D；运算后R非负就在Q最低位置1，否则置0。

轮次	左移后R真值	加减操作	操作后R	记商后的Q
1	1	R−D	−2	110
2	−3	R+D	0	101
3	1	R−D	−2	010

最后R仍负，补做R←R+D，得到余数1，Q=010为商2。第二轮没有先把−2恢复成1再试减，而把恢复效果合并进下一轮加法，这正是不恢复余数法的含义；最终余数校正不能漏掉。硬件布局或商编码约定不同会改变表中轨迹，执行题应坚持同一套规则。

有符号除法还要确定商、余数符号和舍入方向。按 C 向零截断模型，−7÷3的商为−2、余数为−1，仍满足被除数=商×除数+余数。除数0需要异常处理；$-2^{n-1}/(-1)$ 的商超出 n 位补码范围。某种除法器可能检测被除数绝对值小于除数后提前输出商0，另一种固定轮数除法器仍运行完整迭代。只有题干电路给出提前退出逻辑时，才能比较哪组数据用时最短。

2.7 IEEE 754：字段既规定精度，也规定特殊情况

IEEE 754 binary32 即通常的单精度格式，由1位符号 s、8位阶码 E、23位尾数字段 F 构成；binary64分别为1、11、52位。这里 F 的整数值要除以 2^{23} 或 2^{52} 才是小数尾数部分。

IEEE 754 binary32：32 位

s：1位	E：8位	F：23位

E=1…254：隐含 1，指数 E−127

E=0：隐含 0，指数 −126；F=0 时为带符号零

E=255：F=0 为 ±∞；F≠0 为 NaN

负号只由 s 决定，不把整个位串取补码

图 2.1: 单精度字段及三类指数编码

对于 binary32：

$$x=\begin{cases}(-1)^s(1+F/2^{23})2^{E-127}, & 1\le E\le 254;\\ (-1)^s(F/2^{23})2^{-126}, & E=0;\\ (-1)^s\infty, & E=255,F=0;\\ \mathrm{NaN}, & E=255,F\neq 0.\end{cases}$$

规格化数有隐含的前导1，有效精度24位。非规格化数前导为0，用同一最小指数−126逐渐接近0；当 F=0时是带符号零。非规格化数不能再用指数 E−127配隐含1计算。

最小正规格化数为 2^{-126}，最小正非规格化数为 2^{-149}，最大有限正数为 $(2-2^{-23})2^{127}$。这些是数值范围；“能连续精确表示的整数”是另一问题。binary32能精确表示 $[-2^{24},2^{24}]$ 内所有整数，更大的某些整数仍能精确表示，但相邻可表示数的间隔可能大于1。

例 2-7　负小数怎样组成单精度机器数

【2022】 −0.4375的 IEEE 754 单精度浮点数表示为（　）。

A. BEE0 0000H　B. BF60 0000H　C. BF70 0000H　D. C0E0 0000H

解析。 $0.4375 = 0.0111_2 = 1.11_2 \times 2^{-2}$。s=1，E=−2+127=125=01111101，F为 110 后补20个0。连接为 1|01111101|11000000000000000000000，十六进制为 BEE00000H，选 **A**。负数只改变符号位，不对浮点数全部位取补码。

例 2-8　同为负浮点数时怎样比较

【2014】 float 型数据常用 IEEE 754 单精度浮点格式表示。假设两个 float 型变量 x 和 y 分别存放在32位寄存器 f1 和 f2 中，若 (f1)=CC90 0000H、(f2)=B0C0 0000H，则 x 和 y 之间的关系为（　）。

A. x<y且符号相同　B. x<y且符号不同　C. x>y且符号相同　D. x>y且符号不同

解析。 两个最高位都为1，均为负。x的阶码为153，实际指数26；y的阶码为97，实际指数−30。两者均为有限规格化数，x的绝对值远大于y，因此 x<y，选 **A**。此处不必把尾数展开为完整十进制数。对负数，绝对值更大的反而更小。

int 转 float 可能丢低位，32位 int 转 binary64 则可精确表示，因为 binary64 有53位有效精度。float 转 double 在通常 IEEE 格式下能精确保留原有限数值，但不能恢复 float 形成时已经丢掉的信息。浮点转整数按语言规则截断，且须检查范围；NaN 与任何数（包括自身）的相等比较都为假，不能把 x/x==1 用在 x=0或无穷等情形。

2.8 浮点加减：对阶丢位以后还要判断舍入

两个浮点数只有指数相同，才能直接把有效数相加。通常先把较小指数的有效数右移，使指数与较大者一致；这叫对阶。大阶向小阶对齐会要求更多高位和更大的寄存器，不符合固定精度运算的通常实现。

对阶之后进行尾数运算，再规格化和舍入。加法可能得到 $10.xxx_2$，须右移1位、阶码加1；异号相加发生抵消，可能得到 $0.00\cdots1xxx_2$，须左移、阶码减少。舍入使尾数加1时还可能再次进位，必须再检查规格化和阶码范围。若得到精确0，其处理也不能继续无止境左移寻找前导1。

用一个仅保留4位有效数的教学格式说明舍入。$x = 1.000_2 \times 2^0$，$y = 1.000_2 \times 2^{-4}$，精确和为 1.0001_2，恰好位于保留为 1.000 和 1.001 的中点。采用“舍入到最近，正中取偶数”，保留最低位为0的 1.000。若 x 改为 1.001，精确和为 1.0011，则正中取偶数进为 1.010。偶数指保留有效数的最低位为0，不是判断整个真值是奇整数还是偶整数。

实际实现常保留保护位、舍入位和粘滞位。粘滞位把更低位是否出现过1汇总起来，因此 1000… 与 1000…1 的舍入结论可能不同，不能只保留移出的第一位。

例 2-9　哪些步骤可能造成指数越界

【2015】 下列有关浮点数加减运算的叙述中，正确的是（　）。

I. 对阶操作不会引起阶码上溢或下溢
II. 右规和尾数舍入都可能引起阶码上溢
III. 左规时可能引起阶码下溢
IV. 尾数溢出时，结果不一定溢出

A. 仅 II、III　B. 仅 I、II、IV　C. 仅 I、III、IV　D. I、II、III、IV

解析。 对阶把较小阶提高到较大阶，最终阶码仍是原有合法阶码之一；右移尾数可能损失精度，但不使该阶码越界，I正确。右规和舍入后的再右规会使指数加1，可能越过上界，II正确。抵消后的左规要减小指数，可能进入非规格化区或触及题设的下溢界，III正确。尾数暂时形成 `10.xxx` 还可以右规，只要指数容纳得下，结果仍可表示，IV正确。选 **D**。尾数的暂时进位与最终浮点范围溢出是不同层次。

采用 IEEE 754 的渐进下溢时，指数过小并不立即把所有结果变成0，还可能形成非规格化数。题目若采用“阶码、尾数均为补码”的教学格式，就应按其位宽、小数点位置、双符号位和舍入方法计算，不能把该格式的尾数补码接到 IEEE 字段中。

浮点加法不满足数学实数的结合律。例如 binary32中，$a=2^{25}, b=-2^{25}, c=1$：$(a+b)+c=1$，而 $a+(b+c)$ 中 b+c可能先舍入回b，结果为0。发生差异的原因是中间舍入，不是加法指令随意改变数学规则。

自测

1. 原创补充：8位机器计算 `7FH+01H`，按本章标志约定求低8位结果、CF、OF、SF、ZF。
2. 原创补充：binary32位串 `0000 0001H` 与 `0080 0000H` 各表示什么正数？两者是否都具有隐含前导1？
3. 〖2.3-024〗 已知32位 int 变量 i=12345，float 变量 $f=1.2345\times 2^3$。下列结果为假的是：A. `i==(int)(double)i`；B. `f==(float)(double)f`；C. `i==(int)(float)i`；D. `f==(float)(int)f`。

答案。 1. 结果 `80H`，CF=0、OF=1、SF=1、ZF=0；127+1越出补码范围，但未越出8位无符号范围。2. 分别为 2^{-149} 与 2^{-126}，前者非规格化、隐含0，后者规格化、隐含1。3. D。12345能被 binary32精确表示；float到double再回来也保留原float值，但 f 截断为整数会丢小数部分。

第3章　存储层次、地址与 Cache

3.1　为什么一个程序同时使用几层存储器

寄存器、Cache、主存和外存的速度、容量及单位成本不同。寄存器紧贴运算部件、容量小；Cache 保存近期可能使用的主存块；主存容纳正在运行的程序和数据；外存提供较大且通常非易失的空间。层次化存储利用程序访问的局部性，使大量访问落在较快的层中，同时保留较大容量。

随机存取指访问时间基本不随单元位置改变，不等于“随机挑一个位置”。顺序存取要按顺序经过前面的内容；直接存取先定位一个区域，再在区域内访问，例如磁盘。相联存储器按内容匹配，TLB 的相联查找就是常见用途。

存取时间是完成一次读或写所需的时间；存取周期是连续两次访问之间允许的最短间隔。DRAM 读后需要恢复等操作，存取周期可能大于单纯读出延迟。算连续访问的总时间时，不能只把一次存取时间乘次数。

容量要写成“单元数×每单元位数”，再与地址单位连接。2^{20} 个8位单元为1 MiB；本讲义在芯片容量、地址空间、Cache中使用二进制单位，主频和传输率中的 M、G 按十进制。题源沿用 KB、MB 时，根据地址幂次说明实际口径。

3.2　SRAM、DRAM 与 Flash 保存信息的方式

SRAM 用稳定电路状态保存位，只要供电就不需周期刷新，通常速度快、集成密度相对低，适合 Cache。DRAM 用电容电荷表示位，电荷会泄漏，需要刷新；读出还伴随感知、放大和恢复。它的高密度使其适合主存。

“动态”说的是保存机制，不是程序是否经常改写数据；“随机”说的是访问方式，不是是否需要刷新。SRAM、DRAM 都是易失性存储器，掉电后不能保持原信息。

Flash 是非易失性半导体存储器。读、编程和擦除的粒度与代价不同，通常不能对任意旧位直接像 SRAM 那样覆盖写入；例如 NAND Flash 常按页读写、按块擦除。SSD 控制器借助映射、垃圾回收和磨损均衡，把复杂的物理操作组织成主机看到的逻辑块访问。掉电保持不等于写入无限次、写延迟与读延迟相同。

3.3　地址引脚不总等于地址位数

SRAM 的 $2^k \times w$ 表示有 2^k 个可选单元，每次选中输出 w 位，通常需 k 根地址线和 w 根数据线，另有片选和读写等控制线。DRAM 常将行地址、列地址分时送入同一组地址引脚，由行、列选通信号分别锁存，因此逻辑地址位数不能直接作为地址引脚数。

例 3-1　DRAM 的复用地址怎样计数

【2014】 某容量为256 MB的存储器由若干 $4\text{M}\times 8$ 位的 DRAM 芯片构成，该 DRAM 芯片的地址引脚和数据引脚总数是（　）。

A. 19　B. 22　C. 30　D. 36

解析。 $4\text{M}=2^{22}$，芯片内部需要22位单元地址。按题目采用的行列各11位、地址复用模型，需11根地址引脚；数据宽8位，需要8根数据引脚，共19根，选 **A**。题目给出的整机256 MB并不改变单片引脚数。若问组成整机需要多少片，则另算 $256/4=64$ 片。

实际 DRAM 还可能含多个 Bank，地址、命令及引脚结构要按题目给出的组织判断。刷新按行进行，不是每保存一个位就分别发一次刷新。集中刷新把若干刷新操作连在一起，期间可能形成较长不能正常访问的区间；分散刷新把一次正常存取和一次刷新组合到扩大的存取周期内，不形成集中刷新的长间隙，但会降低正常访存速率。异步刷新在保持时间内把各行刷新均匀分散，定期插入短的刷新周期，其间仍可进行正常访问。若有 R 行、保持时间为 T_r，把每行一次刷新均匀分布时，平均间隔为 T_r/R；还须检查每次刷新占用多久。

MAR 容量由地址空间决定

MAR 需容纳可由该机器给出的主存地址。它与 MDR 的位数没有“必须相等”的关系。MDR 反映某次数据传送的位宽，MAR 反映地址编码位宽。

例 3-2　已安装容量不是全部可编址空间

【2011】 某计算机存储器按字节编址，主存地址空间大小为64 MB，现用 $4\text{M}\times 8$ 位的 RAM 芯片组成32 MB的主存储器，则存储器地址寄存器 MAR 的位数至少是（　）。

A. 22位　B. 23位　C. 25位　D. 26位

解析。 题目问覆盖64 MB地址空间需要多少位，而非识别当前安装的32 MB。$64\text{MB}=2^{26}\text{B}$，每个字节一个地址，所以 MAR 至少26位，选 **D**。芯片地址位数22、已安装容量地址位数25都不能回答这一问题。

3.4　单体多字和多体交叉怎样提高带宽

单体多字存储器扩宽一次读写的数据量，一个存储单元包含多个机器字。顺序使用相邻字时，一次访问可以提供多个字；若频繁跳转，取来的其他字未必有用。它主要改善带宽，不能仅因“一次取多个字”便称为解决地址空间不足的方案。

多体存储器则包含能相对独立工作的存储模块。高位交叉（顺序编址）用地址高位选模块，各模块保存连续的一段地址；低位交叉用低位选模块，连续字地址轮流落到不同模块。对 m 个模块且按字编址的常规模型：

$$\text{模块号}=\text{字地址}\bmod m,\qquad \text{模块内地址}=\left\lfloor\frac{\text{字地址}}{m}\right\rfloor.$$

若给的是字节地址，每字 w B，且各模块每次存取一字，通常应先以 $\lfloor A/w\rfloor$ 得字地址，再分模块；最低的字节偏移不参与模块编号。多体交叉与单体多字可以结合，但两者不是同一种机制。

设单模块存取周期为 T，连续启动相邻模块的间隔为 r，模块数 m。连续顺序访问不冲突的条件是 $mr \geq T$。若第一字在 T 后到达，后续每隔 r 得到一个字，读 n 个字的时间为 $T + (n-1)r$。第一字延迟仍为 T，提高的是连续吞吐率。

例 3-3　同一模块不等于立即发生冲突

【2015】某计算机使用4体交叉编址存储器，假定在存储器总线上出现的主存地址（十进制）序列为8005、8006、8007、8008、8001、8002、8003、8004、8000，则可能发生访存冲突的地址对是（　）。

A. 8004和8008　B. 8002和8007　C. 8001和8008　D. 8000和8004

解析。先求地址模4：1、2、3、0、1、2、3、0、0。最后两次8004、8000连续访问模块0，模块可能尚未结束前次存取，所以选 **D**。8008与8004也在模块0，却隔了四个访问位置，不能只凭同体就忽略时间间隔。这里沿题目的低位交叉约定解释“可能冲突”，具体是否冲突仍由模块周期与请求间隔决定。

3.5　主存芯片怎样连到 CPU

位扩展把若干芯片并联在同一地址上，各提供数据的一部分；字扩展让若干组芯片承担不同地址范围，用片选区分。组成 $M \times W$ 的存储器，单片容量 $m \times w$，且能整倍扩展时，位方向需要 W/w 片，字方向需要 M/m 组，总片数为两者乘积。

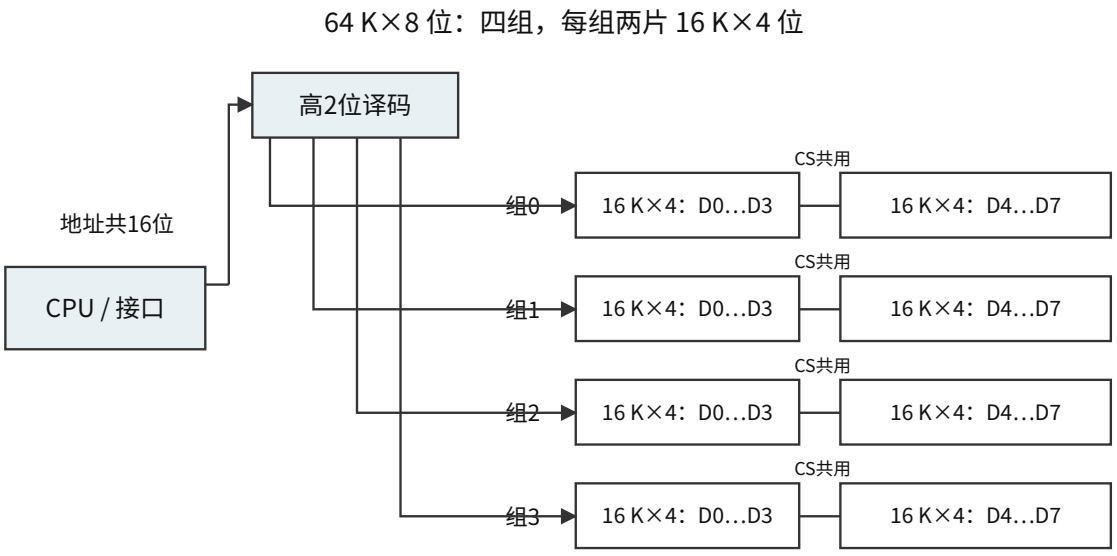


图 3.1: 两片并联扩位，四组译码扩字；同组选中信号相同

图中每片 16K × 4 位，同行两片并成 16K × 8 位，四组组成 64K × 8 位。低14位送给所有芯片选择片内单元，高2位经2–4译码器选一组。位扩展增加数据宽度，字扩展增加可选单元数，两者所用连线不同。

例 3-4　ROM 与 RAM 分区要分别计算

【2009】某计算机主存容量为64 KB，其中 ROM 区为4 KB，其余为 RAM 区，按字节编址。现要用 $2\text{K}\times 8$ 位的 ROM 芯片和 $4\text{K}\times 4$ 位的 RAM 芯片来设计该存储器，则需要上述规格的 ROM 芯片数和 RAM 芯片数分别是（　）。

A. 1、15　B. 2、15　C. 1、30　D. 2、30

解析。ROM单片2 KB且已有8位宽，需 $4/2=2$ 片。RAM总量60 KB；单片虽有4 K单元，每单元只有4位，要两片并成 $4\text{K}\times 8$ 位的一组，再用 $60/4=15$ 组，共30片，选 **D**。只算60/4会漏掉位扩展。

确定地址范围时，先确定编址单位，再拼接片选地址和片内地址。首地址等于片选编码后补全0，末地址等于片选编码后补全1。例如按字编址，32 K×16位芯片的片内字地址为15位；若高3位片选为111，则字地址范围为 `38000H` 至 `3FFFFH`。若改按字节编址，每个字占2 B，片内字节范围需16位，范围随之改变，不能沿用同一答案。

地址线的名字也要从题干读。通常本书令 A0为最低位；有的题明确写 A0为最高位，此时4 K片内地址使用最后12根低位地址线，片选应取其上方的线。下标数字不是高低位的可靠替代品。

3.6　磁盘与 SSD 的一次访问花在哪些时间上

磁盘由盘面、磁道和扇区组织信息。同一半径处各盘面的磁道组成柱面；选择盘面由磁头完成，寻道把磁头移动到相应磁道。旋转等待使目标扇区转到磁头下方，随后才传输数据。磁盘地址的典型几何字段是柱面号、磁头号、扇区号，而不是把“磁头号”和“盘面号”重复算成两个独立定位维度。

$$T_{\text{access}} = T_{\text{seek}} + T_{\text{rotation}} + T_{\text{transfer}}.$$

只有题设要求时再计控制器或排队开销。转速为 r 转/分时，一圈为60/r秒；随机到达且目标角位置均匀时，平均旋转等待为半圈。传输一个扇区的时间只占一圈的相应部分，不能把等待半圈再次计入传输。

例 3-5　7200转每分不是7200转每秒

【2015】若磁盘转速为7200转/分，平均寻道时间为8 ms，每个磁道包含1000个扇区，则访问一个扇区的平均存取时间大约是（　）。

A. 8.1 ms　B. 12.2 ms　C. 16.3 ms　D. 20.5 ms

解析。一圈 $60/7200\ \text{s}\approx 8.333\ \text{ms}$，平均旋转等待约4.167 ms；一扇区传输约 $8.333/1000=0.008333\ \text{ms}$。总时间约12.175 ms，选 **B**。把一整圈当成平均等待，会得到另一数量级的选项。

SSD 没有机械寻道和旋转等待，但仍有接口传输、闪存访问、控制器与写放大等开销。不能套磁盘半圈公式。RAID把多个盘组织起来：条带化提升并行访问能力，镜像提供冗余，奇偶校验可支持某些盘故障后的恢复。RAID0没有数据冗余；采用冗余也不等于代替备份，误删仍可能被同步写到冗余盘。

3.7 Cache 命中率怎样变成时间

时间局部性指近期访问过的信息可能很快再访问，例如循环累加器；空间局部性指相邻位置可能很快被访问，例如顺序扫描数组。Cache按块调入，因此顺序数组中一次缺失可能为随后几个元素准备数据。

命中率 $h = N_{\text{hit}}/(N_{\text{hit}} + N_{\text{miss}})$。平均访问时间必须先确定失败访问的口径。若先查 Cache 花 t_c，未命中后再用 t_m 完成取块，则

$$\text{AMAT} = t_c + (1 - h)t_m.$$

若题目给出的“未命中访问时间”已经包含查 Cache 的时间，记为 t_{miss}，则写为 $ht_c + (1 - h)t_{\text{miss}}$。两式是同一事件分解，不能在第二式中再额外加一次 t_c。多级 Cache 则应区别局部缺失率与相对 CPU 总访问的全局缺失率。

例 3-6　读后写的数组访问怎样计缺失率

【2016】 有如下 C 语言程序段：

```
for (k = 0; k < 1000; k++)
    a[k] = a[k] + 32;
```

若数组 a 和变量 k 均为 int 型，int 型数据占4 B，数据 Cache 采用直接映射方式，数据区大小为1 KB、块大小为16 B，该程序段执行前 Cache 为空，则该程序段执行过程中访问数组 a 的 Cache 缺失率约为（　）。

A. 1.25%　B. 2.5%　C. 12.5%　D. 25%

解析。 每块容纳4个 int。按顺序扫描，每块第一次读缺失，其余3次读命中；第一次读已把块取入，随后对应的写也命中。每4个元素共8次数组访问、1次缺失，因此约为12.5%，选 **C**。若数组首地址未按块对齐，块数可能多1，不影响本题“约为”的结论。不能把循环1000轮误当作只访问数组1000次。

一次缺失损失要不要反复付启动代价

若每次取8 B需发送地址1周期、准备8周期、传输1周期，64 B块包含8次独立访问，总计 $8(1 + 8 + 1) = 80$ 周期。若支持突发，只发一次首地址，等待首数据8周期后连续传8次，则共 $1 + 8 + 8 = 17$ 周期。这正是是否支持突发会改变算法的地方，详见第7章，不能只看总线同为64位就给同一个时间。

3.8 地址拆分决定块能放在哪里

先由数据容量 C 和块大小 B 求行数 $L = C/B$。若每组 r 行，则组数 $G = L/r$。按字节编址且 B、G为2的幂时，块内偏移为 $b = \log_2 B$ 位，组号为 $g = \log_2 G$ 位，剩下高位为标记。Cache总容量若已经包含标记，不能再把它当作 C。

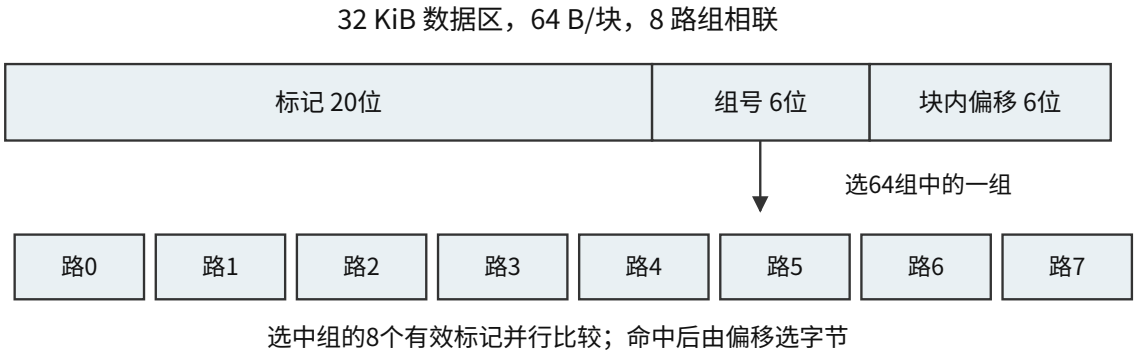


图 3.2: 先去块内偏移，再用块号确定组和标记

常规低位选组的规则为：主存块号 $q=\lfloor A/B\rfloor$，组号 $q \bmod G$，标记 $\lfloor q/G\rfloor$。直接映射是 r=1，全相联是 G=1；r 路组相联中的“路数”是每组行数，不是组数。

访问时用组号选一组，并行比较该组各行的有效标记。组号已经用于选组，不需要再保存到每行标记中；块内偏移只负责从已找到的块中选字节。

例 3-7　8路组相联需要几个比较器

【2022】 若计算机主存地址为32位，按字节编址，某 Cache 的数据区容量为32 KB，主存块大小为64 B，采用8路组相联映射方式，该 Cache 中比较器的个数和位数分别为（　）。

A. 8，20　B. 8，23　C. 64，20　D. 64，23

解析。 行数 $2^{15}/2^{6}=2^{9}$，组数 $2^{9}/8=2^{6}$。偏移6位、组号6位，标记 $32-6-6=20$ 位。一次只在选中的一组内比较8个标记，因此8个20位比较器，选 **A**。64组不表示同一次访问需要比较64组。

3.9 LRU 更新的是访问次序，不只是装入次序

当目标组有空行时先用空行；满了才按替换算法决定牺牲哪一行。直接映射每个块只有一个位置，不需要在多行间选择。FIFO记录装入次序，命中一般不改变队列；LRU记录最近访问次序，命中也要更新；随机替换不跟踪精确最近次序。

下面以两路的一个组解释 LRU 状态，顺序从最近使用到最久未使用。开始为空，访问 A 后为[A]，访问 B后为[B,A]，再次访问 A后为[A,B]。此时访问 C，应淘汰 B，变为[C,A]。若按 FIFO，则第三次访问 A不改变装入队列，访问 C会淘汰 A。这组状态足以说明两算法的分歧。

执行替换题的表格应至少记录本次地址、块号、组号、命中与否，以及该组更新后的状态。替换仅发生在对应组内，不能从其他组挑一个“全 Cache 最久未用”的块。若题干另用高位或特殊函数选组，先照它的映射分组，LRU本身不负责决定组号。

3.10 写命中与写缺失是两个独立问题

写命中时，直写同时更新 Cache 和下一层；回写只改 Cache 并置修改位，替换脏块时才写回。直写常配写缓冲，以减少等待，但缓冲满时仍可能阻塞。回写中的主存暂时旧于 Cache 是允许的受控状态，不能凭“二者立即不同”就断定设计错误。

写缺失时，写分配先调入块再更新 Cache，非写分配直接写下一层而不把该块装入 Cache。回写常配写分配、直写常配非写分配，这是常用组合，不是逻辑上仅有的两种组合。

例 3-8　Cache 总容量还包括哪些位

【2015】 假定主存地址为32位，按字节编址，主存和 Cache 之间采用直接映射方式，主存块大小为4个字，每字32位，采用回写方式，则能存放4 K字数据的 Cache 的总容量的位数至少是（ ）。

A. 146 K　B. 147 K　C. 148 K　D. 158 K

解析。 一块 $4 \times 4 = 16$ B，块内偏移4位。4 K字数据共16 KB，Cache有 $4096/4 = 1024 = 2^{10}$ 行，行号10位，标记18位。每行数据128位，还需有效位1和修改位1，共 $128 + 18 + 1 + 1 = 148$ 位；总计 $1024 \times 148 = 148$ K位，选 **C**。直接映射无需 LRU 替换位。本题“至少”按这些必要字段计算，不额外猜测 ECC 等未给出的实现。

多个 CPU 各有 Cache 时，一个核的写入还涉及其他副本怎样失效或更新；DMA 与 Cache 也可能有一致性处理。单核回写正确不等于多核副本会自动一致。协议细节超出本章基本模型，此处保留“需要一致性机制”的边界，不把全写法当作解决任意多副本问题的证明。

3.11 虚拟存储器怎样让程序看到地址空间

虚拟存储器把进程使用的虚拟地址映射到物理地址，允许部分内容暂存外存，也支持隔离与保护。它不是“用硬盘代替所有内存”：CPU最终仍需要可访问的物理存储，缺页时还要调入并等待。

操作系统建立、维护页表等映射信息，决定分配、换入换出及保护；运行时 MMU 根据这些信息实施地址转换并检查权限。把“映射由 OS 管理”与“每次访存都调用 OS 软件转换”混为一谈，会误判硬件路径。正常的 TLB 命中不需要逐次陷入内核。

3.12 页表与 TLB：地址偏移为何原样保留

页式系统把虚拟地址分为虚页号 VPN 和页内偏移 d；页表查得物理页框号 PPN 后，物理地址为 PPN $\times P + d$，P是页大小。因为页和页框大小相同，页内位置不变。虚拟地址位数和物理地址位数可以不同，改变的是页号部分。

TLB 是页表项的高速缓存。TLB未命中表示缓存里没有本次所需的映射，不表示页面一定不在主存；随后可以查页表并填入TLB。页表存在位为0才可能触发所采用模型中的缺页异常。权限不允许则是保护异常，即使页面已经在内存也不能访问。

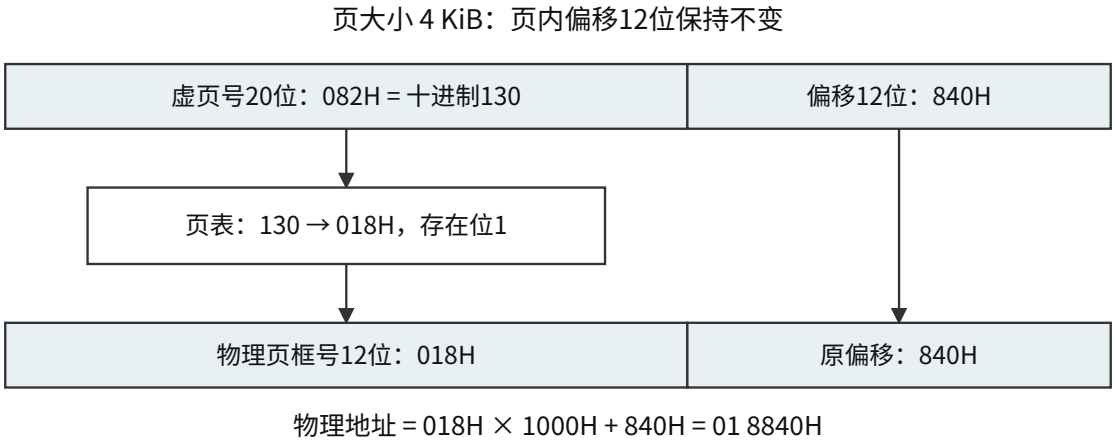


图 3.3: 虚拟地址先查映射，再用页框号与原偏移形成物理地址

例 3-9　页号的十六进制不能直接当表中十进制

【2022】 某计算机主存地址为24位，采用分页虚拟存储管理方式，虚拟地址空间大小为4 GB，页大小为4 KB，按字节编址。某进程的页表部分内容如下。

虚页号	实页号（页框号）	存在位
82	024H	0
…	…	…
129	180H	1
130	018H	1

当 CPU 访问虚拟地址0008 2840H时，虚—实地址转换的结果是（　）。

A. 得到主存地址02 4840H　B. 得到主存地址18 0840H
C. 得到主存地址01 8840H　D. 检测到缺页异常

解析。 页大小 2^{12} B，低12位是偏移 `840H`，虚页号 `82H` 等于十进制130，并非表中第一行的十进制82。查到页框 `018H` 且存在位1，物理地址为 `018H×1000H+840H=018840H`，选 **C**。计算前逐列辨明进制，可避免把本题误判为缺页。

例 3-10　TLB 标记不包含页内偏移

【2024】 某计算机按字节编址，采用页式虚拟存储管理方式，虚拟地址为32位，主存地址为30位，页大小为1 KB。若 TLB 共有32个表项，采用4路组相联映射方式，则 TLB 表项中标记字段的位数至少是（　）。

A. 17　B. 18　C. 19　D. 20

解析。 偏移10位，VPN为22位。TLB共有8组，选组用VPN的3位，标记为 $22-3=19$ 位，选 **C**。物理地址30位决定页框号位数，不决定用来匹配虚页的标记位数；也不能将Cache的块偏移位数搬来。

计算含 TLB 的平均时间时，应画出题设路径。例如串行访问、TLB命中率 h、TLB耗时 t_T、单级页表和主存访问各耗时 t_M，不计缺页时为 $h(t_T+t_M)+(1-h)(t_T+2t_M)$。多级页表、

页表项缓存、TLB与Cache并行查找都会改变路径。缺页还包括外存和操作系统处理，通常远大于一次普通主存访问。

3.13 段式与段页式地址为什么需要界限检查

段式系统按代码、数据等逻辑单位划分不等长段。逻辑地址含段号和段内偏移，段表记录段基址、段长及权限。若段长表示可用字节数 L，必须先验证 $0 \le d < L$，再计算物理地址 base $+ d$；当 d=L时已经越界，不能把末地址写成base+L。

段页式先按段号找到该段页表，再用段内页号查页框，最后拼接页内偏移。段表基址、页表基址和最终数据地址不是同一个量。若段本身有界限，页号合法仍不保证最后一页的所有偏移均合法。

例如某段基址10000 B、段长3000 B，偏移2999合法、物理地址12999 B；偏移3000非法。若段页式采用1 KB页，同一段逻辑长度仍为3000 B，最后一个页号2中的偏移952对应段内3000，应被界限检查拒绝，不能因页框还有空间就允许访问。

3.14 跨页数组访问：页、Cache块与遍历次序分别计算

例 3-11　交换内外层循环，命中率一定降低吗

【2023】改编（两个赋值式统一为常量10） 已知计算机M字长为32位，按字节编址，采用请求调页策略的虚拟存储管理方式，虚拟地址32位，页面大小为4 KB；数据Cache采用4路组相联映射方式，数据区大小为8 KB，主存块大小为32 B。现有C语言程序段如下：

```
int a[24][64];
/* ... */
for (i = 0; i < 24; i++)
    for (j = 0; j < 64; j++) a[i][j] = 10;
```

已知二维数组a按行优先存放，在虚拟地址空间中分配的起始地址为0042 2000H，`sizeof(int)=4`。假定在M上执行上述程序段之前数组a不在主存，且在该程序执行过程中不会发生页面置换。请回答下列问题。

（1）数组分布在几个页面中？对于数组a的访问，会发生几次缺页异常？页故障地址各是什么？

（2）不考虑变量i和j，该程序段的数据访问是否具有时间局部性？为什么？

（3）计算机M的虚拟地址（A31～A0）中哪几位用作块内地址？哪几位用作Cache组号？a[1][0]的虚拟地址是多少？其所在主存块对应的Cache组号是多少？

（4）数组a占用多少主存块？假设上述程序段执行过程中数组a的访问不会和其他数据发生Cache访问冲突，则数组a的Cache命中率是多少？若将循环中i和j的次序按如下方式调换，则数组a的Cache命中率又是多少？

```
for (j = 0; j < 64; j++)
    for (i = 0; i < 24; i++) a[i][j] = 10;
```

解析。 先把数组元素下标化为字节地址，再分别按页和Cache块划分。按行优先，每行64个int，共256 B，因此

$$\mathrm{addr}(a[i][j]) = \texttt{00422000H} + (64i + j) \times 4.$$

本题参考解按写分配模型处理首次写缺失：写一个尚不在Cache中的块时先调入该块。后续命中率均采用这一约定；若明确改为非写分配，结论须重算。数组初始不在主存，不能预先把数组块当作有效命中。

（1）数组大小为 $24 \times 64 \times 4 = 6144$ B，即6 KiB。起始地址低12位为0，恰在4 KiB页边界；前16行占第一页4096 B，后8行占第二页2048 B，所以共2页。

第一次执行a[0][0]时缺页，故障地址为0042 2000H；第一次执行a[16][0]时进入下一页，故障地址为0042 3000H。无页面置换，每页首次调入后保留，共2次缺页。6 KiB除以4 KiB后向上取整在这里成立，是因为首地址页对齐；若数组从页中部开始，必须把首地址页内偏移也计入。

（2）以数组元素为数据对象，各元素只被写一次，没有重复访问同一元素，因此没有时间局部性。按行连续访问相邻元素，具有空间局部性。一个Cache块中的相邻元素后来命中，正是按块调入利用空间局部性的结果，不应据此把同一元素“又访问了一次”。

（3）块为 2^5 B，块内地址为A4～A0。Cache行数 $8192/32 = 256$，4路共有64组，组号6位，对应A10～A5。虽然映射最终作用于物理块，但这些位都在低12位页内偏移内，地址转换不改变它们，因此可以直接从虚拟地址取出本题组号。

a[1][0]在起点之后256 B，即0042 2100H。低11位中的组号为 `(2100H>>5) mod 64=8`，二进制001000。不要把“第1行”当成只跨过一个int。

（4）每块32 B可容纳8个int，起点块对齐，总块数 $6144/32 = 192$。按行访问时，每块第一次写缺失，随后7次写命中，共1536次写、192次缺失，命中率为

$$\frac{1536 - 192}{1536} = \frac{7}{8} = 87.5\%.$$

交换循环后，每个j先跨24行访问，同一列相邻两次地址相差256 B，即相差8个块，组号也按模64增加8。固定j时，24个块轮流落在8个组中，每组恰好3块，**4路容得下这3块**。因此不能仅凭“按列走”就断言块被赶走。

例如j=0时，行号0、8、16的块都映射到组0，分别占据该组3路；第4路仍空。j=1至7仍访问这24个已装入块，均命中。j=8首次使用下一批24块，其组号在原来基础上加1，与前批分属不同组；以后同理。全数组192块能按映射同时保留，仍只有192次首次缺失，命中率仍为87.5%。

这个结论同时用了数组大小、起始对齐、组数、路数和无其他数据冲突。不能只依据“数组6 KiB小于Cache8 KiB”就结束证明，因为组相联中总容量装得下，也可能在少数组内发生冲突。

关键变式（原创）。 若仅把Cache改成4 KiB、2路，保留64组和32 B块，则每个相关组仍轮流访问3块，却只有2路。按列遍历、LRU替换时，三块循环会互相淘汰，下一列也难以复用，数组写访问全部缺失；按行遍历仍能在同块的8次访问中命中7次。改变解法的条件是每组可容纳的块数，不是“换循环必然降低命中率”这一口号。

自测

1. 原创补充：32位字节地址、Cache数据区4 KB、块16 B、2路组相联，求偏移、组号、标记位数。假定另需有效位和修改位，先不计替换位，每行多少位?
2. 原创补充：两路某组按LRU访问A、B、A、C、B，初始空，列每次命中情况与最近到最久次序。
3. 【2024】下列事件中，不是在 MMU 地址转换过程中检测的是（ ）。A. 访问越权　B. Cache缺失　C. 页面缺失　D. TLB缺失。

答案。1. 4、7、21位；每行 $128+21+1+1=151$ 位。2. 缺失[A]、缺失[B,A]、命中[A,B]、缺失[C,A]、缺失[B,C]。3. B。MMU负责地址转换和相关保护；Cache缺失属于Cache查找结果，不能与TLB缺失等同。

第4章　指令系统与 C 程序的机器级表示

4.1 指令字段怎样决定可表示的操作和地址

一条机器指令包含操作码以及完成该操作所需的其他字段。操作码规定做什么，地址字段可能给出立即数、寄存器编号、形式地址、位移或寻址方式，不能把所有字段都当成主存绝对地址。指令字长是指令编码的位数，机器字长是整数运算的基本位宽，两者不必相等。

按显式操作数地址字段数，可以有零地址、一地址、二地址、三地址指令。零地址指令未必不操作数据，栈式机器的加法可隐含从栈顶取两个数；一地址指令可隐含累加器；二地址形式常让一个地址同时承担源和目的，但具体语义仍要由题目给出。不能只根据“两个字段”推出固定访存次数，字段还可能指定寄存器或立即数。

数据传送指令移动或复制值；算术逻辑指令形成新值和可能的标志；转移指令改变后继执行地址；调用在转移前保留返回位置，返回根据保存的位置继续；输入输出及系统控制指令还可能有权限限制。通常的赋值和算术指令不会把源操作数“取走后清空”。

固定长度操作码用 k 位可区分至多 2^k 种编码。扩展操作码把部分短编码保留为扩展前缀，用更长的操作码表示操作数较少的指令。已作为短指令使用的编码不能同时作为长指令前缀，否则译码会歧义。

例 4-1　扩展操作码应逐层扣除哪些前缀

【2022】 设计某指令系统时，假设采用16位定长指令字格式，操作码使用扩展编码方式，地址码为6位，包含零地址、一地址和二地址3种格式的指令。若二地址指令有12条，一地址指令有254条，则零地址指令的条数最多为（　）。

A. 0　B. 2　C. 64　D. 128

解析。 二地址格式需要12位地址，短操作码为4位，共16种前缀，用掉12种，剩4种可扩展。每个前缀再接6位，共提供 $4\times64=256$ 种一地址操作码；用掉254种，剩2种再各扩展6位，得到 $2\times64=128$ 条零地址指令，选 **D**。

不能从 2^{16} 中只减“12+254”，因为每条二地址指令还对应 2^{12} 种操作数字段组合，每条一地址指令对应 2^6 种组合。逐层保留前缀的算法直接反映译码过程，也方便处理其他字段长度。

4.2 从形式地址到有效地址

以下记指令地址字段为 A，寄存器 R 的内容为 (R)，内存地址 x 的内容为 M[x]，有效地址 EA 是最终操作数所在的主存地址。立即数不需要另求操作数主存地址；寄存器寻址的操作数也在寄存器，不应为凑公式虚构一次主存访问。

寻址方式	操作数或有效地址	核对条件
立即	操作数在指令中	字段的符号扩展规则
直接	EA=A，操作数=M[A]	A的编码范围

寻址方式	操作数或有效地址	核对条件
一次间接	EA=M[A]	先取地址，再取操作数
寄存器直接	操作数=(R)	字段是寄存器编号
寄存器间接	EA=(R)	寄存器保存的是地址
基址	EA=(BR)+位移	位移位宽及符号
变址	EA=A+(IX)	元素下标是否已乘元素宽度
相对	目标=PC基准+位移	PC指当前还是后继地址

间接寻址得到的中间地址位宽可能大于指令地址字段，从而扩大可寻址范围，代价是增加寻址访存。基址可用于程序重定位，变址适合数组遍历；二者都可表现为寄存器加位移，但所赋予寄存器的用途不同，具体机器也可能用同一种编码机制实现。

例 4-2　相对转移用哪个 PC

【2009】 某机器字长为16位，主存按字节编址，转移指令采用相对寻址，由两个字节组成，第一个字节为操作码字段，第二个字节为相对位移量字段。假定取指令时，每取一个字节 PC 自动加1。若某转移指令所在主存地址为2000H，相对位移量字段的内容为06H，则该转移指令成功转移后的目标地址是（　）。

A. 2006H　B. 2007H　C. 2008H　D. 2009H

解析。 指令从2000H开始，占2 B，取完后 PC=2002H。相对位移为+6，目标为2008H，选**C**。若位移字段改为 FAH且按8位补码解释，则位移为−6，目标为1FFCH；不能把 FAH当作正250。PC基准必须根据本题更新时机确定。

数组寻址还需区分元素下标和字节偏移。按字节编址、int为4 B时，`a[i]` 地址为base+4i。某 ISA 若有“比例变址”，可由硬件将索引乘4；没有时由移位或其他指令形成4i。这不意味着数组元素之间多留了3个空洞，四个字节共同存一个元素。

访存次数要从执行路径数

若指令为一个字、无Cache、无预取，直接寻址的读操作数指令通常至少取指一次、取操作数一次；一次主存间接寻址再多读一次地址。若还写回主存，需另计一次写。若指令跨两个存储字、发生缺页或含两个主存操作数，次数会改变。“寄存器间接”中的“间接”不会额外读一次主存地址，因为地址已经在寄存器中。

4.3 大端、小端和对齐解决不同问题

多字节数据的大端方式把最高有效字节放在最低地址，小端方式把最低有效字节放在最低地址。它只改变一个多字节对象内部的字节排列，不反转每个字节的位，也不改变数组元素顺序。

32位值 `12345678H` 从低地址到高地址，大端为12、34、56、78，小端为78、56、34、12。讨论“高位字节”指数字意义上的高位，讨论“高地址”指位置，两个维度应明确分开。

对齐是对象起始地址满足指定倍数。常用自然对齐模型中，2 B对象起于2的倍数，4 B对象起于4的倍数。结构体编译器可能在成员间和末尾加入填充，使成员地址和相邻数组元素都满足对齐规则。具体要求属于 ABI/编译器约定，题目已给“按边界对齐”时再按给定类型大小执行。

例 4-3　先确定结构布局，再看低字节

【2012】 某计算机存储器按字节编址，采用小端方式存放数据。假定编译器规定 int 型和 short 型长度分别为32位和16位，并且数据按边界对齐存储。某 C 语言程序段如下：

```
struct {
    int a;
    char b;
    short c;
} record;
record.a = 273;
```

若 record 变量的首地址为0xC008，则地址0xC008中的内容及 record.c 的地址分别为（ ）。

A. 0x00，0xC00D　B. 0x00，0xC00E
C. 0x11，0xC00D　D. 0x11，0xC00E

解析。 a占偏移0至3，b占偏移4。下一地址偏移5不是2的倍数，须填充1 B，c占偏移6、7，故c地址为C00EH。273 = 00000111H，小端最低地址保存低字节11H，选 **D**。填充来自对齐，低字节11来自字节序，两步不能互相代替。

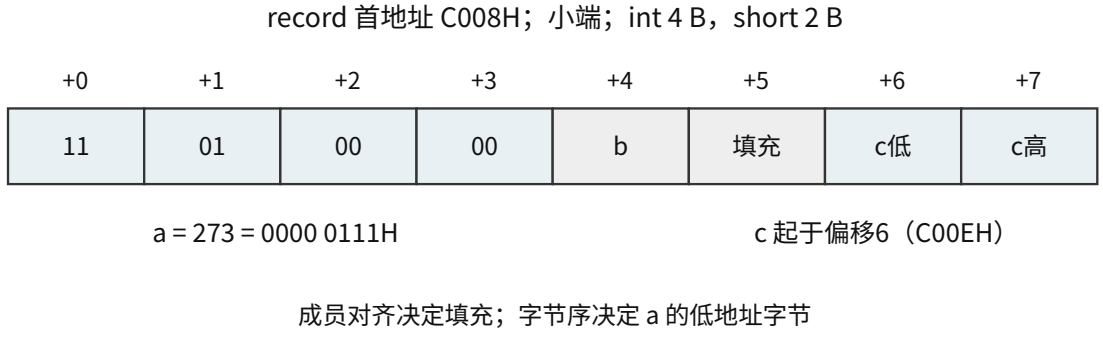


图 4.1: 结构体成员、填充与低地址字节分别标明

二维数组按行优先存放时，a[i][j] 的元素偏移为 $i \times$ 列数 $+ j$，字节偏移还要乘元素字节数。对补码负的 short，先求完整16位编码，再按字节序拆开。例如−6为 FFFAH，小端低地址是FA、下一字节是FF，不是把真值“−6”拆成十进制字符。

4.4 RISC 与 CISC：设计倾向不代替具体实现

RISC通常采用较规整的指令格式、较少的寻址方式和Load/Store风格：算术逻辑操作主要在寄存器间进行，访存由装入和存储指令承担。这有利于规整译码和流水处理。CISC往往支持更丰富的指令形式与寻址方式，单条指令可以表达较复杂操作。

“RISC”不等于所有指令永远一个周期完成；Cache缺失和乘除等都可能增加时间。CISC也能采用流水线和内部微操作等技术。硬布线和微程序是实现控制器的方式，不能仅由缩写绝对断言某台具体处理器的全部内部实现。

例 4-4　RISC 设计能否支持流水线

【2025】 下列关于 RISC 的叙述中，错误的是（　）。

A. 多采用硬连线方式实现控制器
B. 通常采用 Load/Store 型指令设计风格
C. 难以采用流水线数据通路实现微架构
D. 多采用寄存器传递过程调用时的参数

解析。 格式规整、操作较简单，通常有利于流水线实现，所以 C 错。A、B、D描述常见设计倾向，不应将“多采用”改读成“只能采用”。答案为 **C**。

4.5 编译、汇编、链接怎样确定程序中的地址

第1章已给出工具链顺序，这里进一步说明为什么目标文件未必能直接运行。编译和汇编时，一个模块可能引用另一个模块的函数或全局变量，汇编器尚不知道它的最终地址，只能留下符号与重定位信息。链接器合并相应节，解析符号，再按选定地址修改相关引用。

可执行文件包含机器代码，也含装入所需的组织信息；并非文件的每一个字节都被 CPU 当作指令。目标文件还可能含符号表、调试信息和重定位记录。高级语言的变量名在运行时未必仍对应一个固定主存地址，优化后它可能在寄存器中、被折叠成常量，或已经消失。

例 4-5　工具链顺序

【2022】 将高级语言源程序转换为可执行目标文件的主要过程是（　）。

A. 预处理→编译→汇编→链接
B. 预处理→汇编→编译→链接
C. 预处理→编译→链接→汇编
D. 预处理→汇编→链接→编译

解析。 先处理源文件中的预处理指令，再将高级语言翻译成汇编表示，继而编码为目标文件，最后解析跨模块引用，选 **A**。这是题目采用的典型静态编译流程；动态链接将部分工作留到装入或运行时，不改变汇编编码必须在普通机器执行之前完成这一点。

4.6 分支和循环怎样改变 PC

机器执行选择结构时，先形成条件，再决定是否改变后继地址。条件可由比较指令设置标志，也可由分支指令直接比较寄存器。翻译 C 条件时，必须保留 signed/unsigned 的区别，不能因为两者都使用减法硬件就使用同一个转移条件。

下列教学指令约定整数均为32位、R1存x、R2存y，`bge` 按有符号数比较，标签代表指令地址；假定本例的差值可用32位有符号数表示：

```
    bge R1, R2, ELSE     // x>=y 时跳过 then
    sub R3, R2, R1      // then: z=y-x
    jump END
ELSE:
    sub R3, R1, R2      // else: z=x-y
END:
```

这里为实现 `if(x<y) z=y-x; else z=x-y;`，分支条件采用原条件的否定，使满足原条件时顺序落入 then。转移目标是代码位置，不是把标签的字符存进 PC。

循环先确定入口测试、循环体、更新和回边。对以下机器级教学轨迹，R0为数组基址，R1为元素下标，R2为和，R3为元素个数，int占4 B：

```
    R1 <- 0; R2 <- 0
TEST:
    if R1 >= R3 jump EXIT
    R4 <- R1 << 2
    R5 <- M[R0 + R4]
    R2 <- R2 + R5
    R1 <- R1 + 1
    jump TEST
EXIT:
```

R3=0时直接退出，不读 `a[0]`；R3=3时读取偏移0、4、8而非0、1、2。这两个边界足以检查循环上下界和地址单位。若变换为指针遍历，每轮指针加4，终止地址为base+4R3；不能把终止地址当成最后一个有效元素地址。

逆向读代码时，先标各寄存器初值和更新式，再识别分支条件。循环回边指令的执行次数与循环体次数可能不同：入口先测的 n 次循环，测试通常执行 n+1次。算动态指令数和 Cache 访问次数时，这个差别不能省。

4.7 过程调用为什么要保存返回位置

调用至少要解决四件事：把参数交给被调过程，记录返回位置，给局部变量和临时值安排空间，将返回值交回调用者。ISA提供调用、返回或寄存器转移等基础机制，ABI进一步规定参数寄存器、返回值位置、栈对齐，以及哪些寄存器由哪一方保存。

返回地址可以放到栈，也可以先放到链接寄存器。若采用链接寄存器，叶子函数可能不访存保存返回地址；会再次调用其他函数的过程通常需要在覆盖链接寄存器前保存它。不能把“返回地址一定写主存”当成所有指令系统的共同特征。

以下采用一个明确的栈模型说明调用：栈向低地址增长，每槽4 B，SP指向当前栈顶；push先SP减4再写，pop先读再SP加4；调用压入后继指令地址，返回弹出该地址送PC。调用前SP=1000H，返回地址为2004H，则调用后SP=0FFCH、M[0FFCH]=2004H。

若被调过程又保存旧帧指针 FP、再分配8 B局部区，SP依次变0FF8H和0FF0H。此时局部变量不能覆盖0FFCH的返回地址。退出时先撤销局部区，恢复旧FP，再取返回地址；SP最终回到1000H。图中的地址单位为字节。

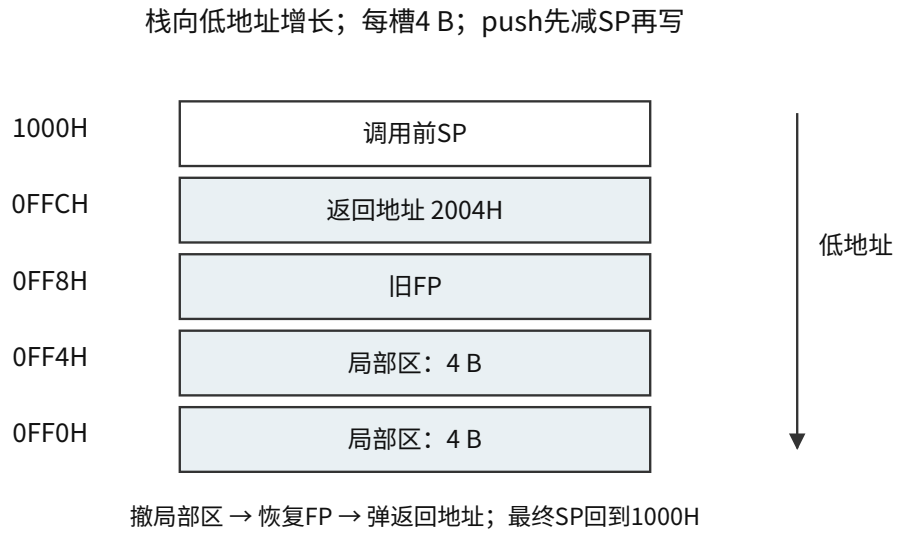


图 4.2: 调用、建立栈帧和返回时，SP逐步移动

嵌套调用靠每次独立保存的返回位置区分“回到哪里”；递归的各层也各有参数、局部变量和返回地址。局部变量同名不表示它们共用同一槽。调用者保存寄存器需在调用前保留自己还要使用的值；被调用者保存寄存器则在被调过程修改前保存、返回前恢复。

机器题给出具体调用约定时，按它追踪，而不是凭熟悉的 x86、MIPS 或 RISC-V 经验补条件。特别要检查栈生长方向、SP指向、入栈前后调整顺序和返回地址基准。它们会同时影响地址计算与最终返回位置。

自测

1. 【2025】某32位计算机按字节编址，采用小端方式存放数据，编译器按边界对齐方式为下列 C 语言结构型数组 employee 分配空间：`struct record { int id; char name[10]; int salary; } employee[200];`。若 employee 首地址为0000 A0B0H，employee[1].id的机器数为1234 5678H，则其中56H所在单元地址是（ ）。A. 0000 A0C3H　B. 0000 A0C4H　C. 0000 A0C5H　D. 0000 A0C6H。
2. 原创补充：沿用本章栈模型，初始SP=1000H，连续push两个4 B值后，再pop一个值，SP是多少？返回地址保存在链接寄存器时，是否每次调用都必然产生一次主存写？

答案。 1. C。id占0至3，name占4至13，填充14、15，salary占16至19，结构大小20 B。employee[1].id始于A0C4H，小端的56H在其后1 B，即A0C5H。2. SP=0FFCH。否，是否写主存还取决于调用模型及是否需要溢出保存。

第5章　CPU、数据通路、控制器与异常中断

5.1 寄存器的名字说明它暂存什么

CPU 的基本任务是取指、解释指令并控制操作执行，同时处理规定的异常和中断。运算部件完成算术逻辑处理，寄存器保存当前操作需要的状态，控制器安排数据通路中的动作。每个部件的作用要放到一次实际传送中理解。

寄存器	保存内容及用途
PC	与后继取指位置有关的地址；更新规则由执行时序决定
IR	当前正在译码或执行的指令编码
MAR	本次主存访问的地址
MDR	与主存交换的指令或数据
通用寄存器组	指令能按编号访问的操作数、地址或临时结果
PSW/标志寄存器	运算标志及体系结构规定的处理器状态

“寄存器在 CPU 内”不等于“它属于通用寄存器组”。PC、IR与通用寄存器的用途不同；MAR、MDR在题目的抽象模型中标明访存接口，不表示所有现代芯片都按同样名字放置独立物理寄存器。

MAR 位数由可寻址单元数决定，MDR 位数由该数据通路一次访存交换的位宽决定。若数据总线32位、按字节编址且有26位地址，MDR可以为32位而MAR为26位，两者无须相等。MDR刚完成取指时存指令，刚完成数据读时存操作数，不能给它永久指定一种内容。

例 5-1　哪些元件负责运算，哪些元件保存状态

【2023】 数据通路由组合逻辑元件（操作元件）和时序逻辑元件（状态元件）组成。以下给出的元件中，属于操作元件的是（　）。

I. 算术逻辑部件（ALU）　II. 程序计数器（PC）
III. 通用寄存器组（GPRs）　IV. 多路选择器（MUX）

A. 仅 I、II　B. 仅 I、IV　C. 仅 II、III　D. 仅 I、II、IV

解析。 ALU按当前输入产生运算输出，MUX按选择信号把某路输入送往输出，二者是组合逻辑。PC和通用寄存器组保存跨时钟的状态，属于状态元件，选 **B**。寄存器组含有组合读出或选择电路，不改变“它承担保存状态功能”的分类。

5.2 指令周期、机器周期与时钟周期

时钟周期是同步CPU状态推进的基本时间单位。指令周期是从一条指令开始执行到完成所需的整个过程。机器周期是某些实现中为取指、访存等基本操作划分的较大时间单位，不同机器的划分不同，不应当成跨体系结构固定的常数。

指令周期可能含取指、间址、执行、中断等阶段；不是每条指令都经过所有阶段。寄存器指令无需为操作数访问主存，间接寻址可能增加取有效地址的阶段，外部中断也只有在满足响应条件时才进入响应过程。

单周期CPU把一条指令的全部操作安排在一个时钟周期内，所以时钟必须容纳最慢指令的数据通路；简单指令也使用同样长的周期。多周期CPU把指令拆成若干步，周期由各步关键路径决定，不同指令使用不同步数。流水线让多条指令的不同阶段重叠，减少连续指令的平均完成间隔，但未必缩短一条指令自身的延迟。

若题目给“每次访存2周期”，应把它安排到取指和操作数读写等实际位置；不能先背“某类指令固定3个机器周期”，再无视具体数据通路的资源限制。

5.3 一条指令怎样变为微操作

微操作是数据通路能完成的基本动作，例如PC送MAR、两寄存器值相加、结果写回。控制信号选择输出源、选择ALU功能、允许某个寄存器写入或发出存储器读写请求。微操作是动作，微命令是发出该动作的控制命令，两者不是同一个对象。

下例采用单条CPU内部总线。一次总线传送只允许一个驱动源，可将同一值送入多个目的寄存器。ALU的一输入来自暂存器Y，另一输入来自总线，结果先存Z，再由Z上总线写回。这里先按图确认资源，再写时序，不另补未画出的专用路径。

例 5-2　从单总线图确定控制信号与取指时序

【2022】 某CPU中部分数据通路如下图所示，其中，GPRs为通用寄存器组；FR为标志寄存器，用于存放ALU产生的标志信息；带箭头虚线表示控制信号，如控制信号Read、Write分别表示主存读、主存写，MDRin表示内部总线上数据写入MDR，MDRout表示MDR的内容送内部总线。

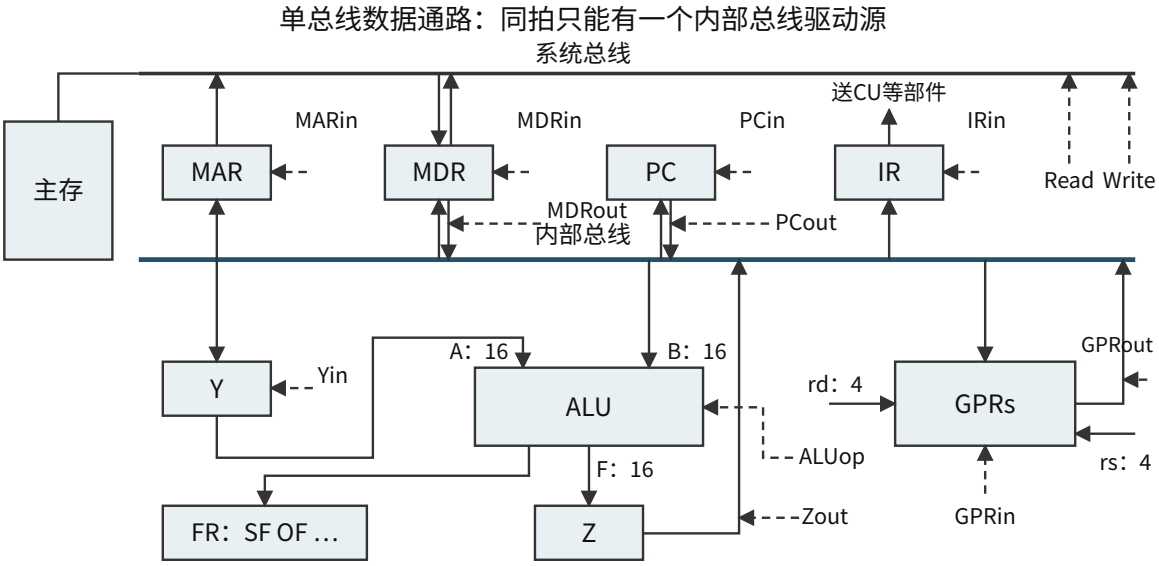


图 5.1: 单条内部总线连接Y、ALU与Z；rs、rd为4位寄存器编号

（1）设ALU的输入端A、B及输出端F的最高位分别为A15、B15及F15，FR中的符号标志和溢出标志分别为SF和OF，则SF的逻辑表达式是什么？A加B、A减B时OF的逻辑表达式分别是什么？要求逻辑表达式的输入变量为A15、B15及F15。

（2）为什么要设置暂存器Y和Z?

（3）若GPRs的输入端rs、rd分别为所读、写的通用寄存器的编号，则GPRs中最多有多少个通用寄存器？rs和rd来自图中的哪个寄存器？已知GPRs内部有一个地址译码器和一个多路选择器，rd应连接地址译码器还是多路选择器?

（4）取指令阶段（不考虑PC增量操作）的控制信号序列是什么？若从发出主存读命令到主存读出数据并传送到MDR共需5个时钟周期，则取指令阶段至少需要几个时钟周期?

（5）图中控制信号由什么部件产生？图中哪些寄存器的输出信号会连到该部件的输入端?

解析。（1）SF直接记录结果最高位，所以 SF $= F_{15}$。OF判断有符号运算是否越界。为简写，以下令 $a = A_{15}, b = B_{15}, f = F_{15}$，乘号表示逻辑与、加号表示逻辑或、上横线表示逻辑非：

$$\mathrm{OF}_{\mathrm{add}} = ab\overline{f} + \overline{a}\,\overline{b}f, \qquad \mathrm{OF}_{\mathrm{sub}} = a\overline{b}\,\overline{f} + \overline{a}bf.$$

加法只在两输入同号、结果异号时溢出；减法只在两输入异号、结果符号不同于A时溢出。例如16位32767加1得到8000H，a=b=0、f=1，代入加法表达式得OF=1；−32768减1得到7FFFH，a=1、b=0、f=0，代入减法表达式也得1。SF保存编码位，并非有符号数学结果正确性的保证。

（2）同一时刻内部总线只能提供一个值，而ALU要同时接收两个输入。先把第一个输入存Y，总线随后送第二个输入到B端，Y提供A端。ALU产生结果时总线还在送第二输入，若直接把结果也送回同一总线会争用；先用Z保存，下拍再由Z输出。Y解决输入的先后取得，Z解决结果输出的时机，不是两个名字不同的通用寄存器。

（3）rs和rd均为4位编号，最多 $2^4=16$ 个通用寄存器。它们来自指令寄存器IR中的对应字段。rd决定本拍把结果写入哪一个寄存器，接写地址译码器；rs决定从哪个寄存器读出，控制读出多路选择器。4位编号能选16个寄存器，不表示每个寄存器只有4位。

（4）先用PC提供指令地址，访问主存，最后将读出的指令送IR：

控制步骤	有效控制信号	数据变化与所需时间
地址准备	PCout、MARin	PC经内部总线写MAR，1周期
主存读	Read	主存按MAR地址读出，送MDR，共5周期
装入指令	MDRout、IRin	MDR经内部总线写IR，1周期

因此至少 $1+5+1=7$ 个时钟周期。5周期已包含主存读出并送MDR，不能再加一次“写MDR”的额外周期。图中MDRin专指从内部总线写MDR，不能把它机械加到这个外部主存读入路径上。题目明确不考虑PC增量，也不能为了更新PC擅自多加一步。

（5）控制信号由控制器中的控制部件CU产生。IR输出指令的操作信息，FR输出SF、OF等状态，二者共同为控制决策提供输入。通用寄存器保存的是程序数据，PC提供执行位置，不能因它们都在CPU内就把所有寄存器一概列为本图CU判断输入。

例 5-3　间接操作数经过哪些部件

【2019】 某指令功能为 $\mathrm{R}[r2]\leftarrow\mathrm{R}[r1]+\mathrm{M}[\mathrm{R}[r0]]$，其两个源操作数分别采用寄存器、寄存器间接寻址方式。对于下列给定部件，该指令在取数及执行过程中需要用到的是（　）。

I. 通用寄存器组（GPRs）　II. 算术逻辑单元（ALU）
III. 存储器（Memory）　IV. 指令译码器（ID）

A. 仅 I、II　B. 仅 I、II、III　C. 仅 II、III、IV　D. 仅 I、III、IV

解析。 r1值和r0中的地址来自寄存器组；按r0值访问存储器得到第二个操作数；ALU做加法并写回r2，所以I、II、III必需，选 **B**。题目已限定“取数及执行”，指令译码是前面确定操作的工作，不能把整个指令周期使用过的所有部件都加进来。

读写数据通路题时，先写指令的寄存器传送语义，再用图上的实际路径连接源和目的，最后安排周期。总线冲突、写入条件和内存延迟通常比“背一张步骤表”更能决定答案。未画出的旁路不能为省周期自行补上。

5.4 控制信号由组合逻辑还是微程序产生

硬布线控制器根据操作码、当前节拍和状态条件，经译码与逻辑电路产生控制信号。它不必逐条读取控制存储器中的微指令，常有较短控制延迟；新增复杂指令可能需要修改更多逻辑。

微程序控制器把一条机器指令的控制过程组织为微指令序列，保存在控制存储器中。微指令的控制字段产生本拍的微命令，后继地址及条件字段决定下一条微指令。控制存储器通常是CPU内部的专门存储，不是用户主存；微程序计数器或微地址寄存器也不是机器程序的PC。

微指令的直接控制方式为各控制线分配位，便于同拍并行但字宽较大。字段直接编码把互斥微命令分组，每字段经译码选一个命令，需要保留“不发该组命令”的编码。字段间接编码还借助其他字段共同解释。水平型倾向于显式并行多个微命令，垂直型以较短编码表示操作，常需更多微指令完成同一控制任务；不能笼统说后者并行性更高。

例 5-4　互斥类为什么还要一个空操作编码

【2012】 某计算机的控制器采用微程序控制方式，微指令中的操作控制字段采用字段直接编码法，共有33个微命令，构成5个互斥类，分别包含7、3、12、5和6个微命令，则操作控制字段至少有（　）。

A. 5位　B. 6位　C. 15位　D. 33位

解析。 每组除发某一命令外，还须能不发命令。各组位数为 $\lceil \log_2(7+1) \rceil = 3$、2、4、3、3，总计15位，选 **C**。例如若某组有4条命令，2位只有4种编码，没有“本拍不用该组”的位置，通常要3位。

例 5-5　控制存储器地址字段怎样估位宽

【2014】 某计算机采用微程序控制器，共有32条指令，公共的取指令微程序包含2条微指令，各指令对应的微程序平均由4条微指令组成，采用断定法（下地址字段法）确定下条微指令地址，则微指令中下地址字段的位数至少是（　）。

A. 5　B. 6　C. 8　D. 9

解析。 公共取指微程序只存一份，控制存储器至少需 $32 \times 4 + 2 = 130$ 个微指令位置，地址至少 $\lceil \log_2 130 \rceil = 8$ 位，选 **C**。32种机器指令只需要5位编码，不表示微指令的存储地址也只需5位；两者编码的对象不同。

取指不依赖“上一条指令的操作码”来决定读取下一条指令，但它仍需控制信号来选择PC、发存储器读和写IR。流水线图有时把固定发生的控制动作省去，不代表取指、译码电路无需任何控制。题目说“数据通路不包含控制部件”时，是按功能划分数据处理通路与信号生成部分；这也不意味着数据通路能脱离控制运行。

5.5 异常、中断与返回位置

本讲义按408常用语境区分：异常与当前执行的指令有关，在执行过程中检测，例如缺页、非法指令、算术异常；外部中断来自指令执行之外的事件，例如设备完成、定时器请求，通常在指令边界接受响应。广义“中断机制”有时统称两者，遇到题目需先辨其用词范围。

故障 fault 通常可在修复后重新执行，例如缺页后调入页面；陷阱 trap 作为有意通知或调试事件，常从后继位置继续；终止 abort 表示严重情况，通常不能可靠恢复。不同ISA的异常分类和保存PC细则不同，此处不把每一种算术异常固定归入同一类别。

响应异常或中断时，硬件需保存足够的返回信息、切换到规定状态并找到处理程序入口。通用寄存器现场往往由入口汇编和软件继续保存。中断服务例程是软件；“中断隐指令”则是对硬件自动响应动作的教材称呼，不是程序员在代码中插入的一条普通指令。

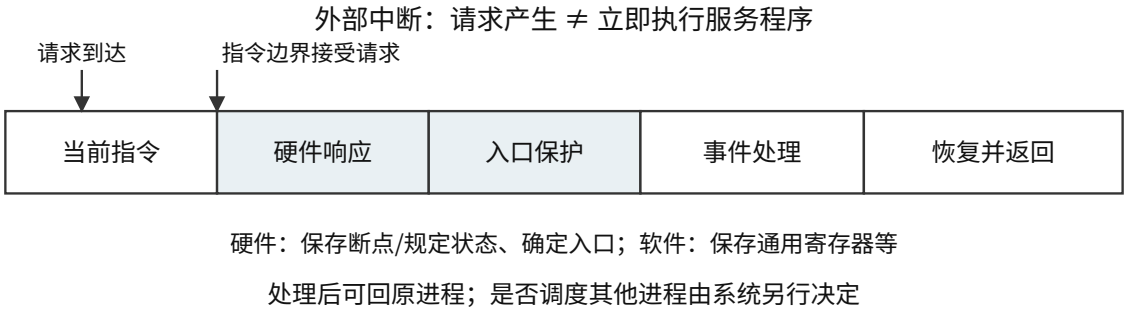


图 5.2: 外部请求先等待响应边界，再由硬件入口转入软件处理

例 5-6　缺页后为什么重试当前指令

【2021】 异常事件在当前指令执行过程中进行检测，中断请求则在当前指令执行后进行检测。下列事件中，相应处理程序执行后，必须回到当前指令重新执行的是（ ）。

A. 系统调用　B. 页缺失　C. DMA传送结束　D. 打印机缺纸

解析。 页缺失意味着当前指令需要访问的页面尚未就绪，指令的原定访问还未完成。处理程序调入页面后，应重新执行这条指令，选 **B**。系统调用已经发出了服务请求，不能不加区分地重做调用指令；DMA完成和打印机事件来自外设，不要求重做某条已完成的普通指令。

外部中断的返回地址通常是下一条尚未执行指令的位置，不能写成“刚执行完的那一条”。发生故障时可能保存当前指令起点，发生陷阱时可能保存后继位置。给出流水线或变长指令的题目，还要看体系结构怎样保证可恢复状态，不能单凭此时取指PC的数值推断精确断点。

处理器进入内核态不必切换到另一个进程。一次设备中断可能处理后返回原进程；调度器也可能决定切换执行主体。模式切换与进程上下文切换相关但不等价。第8章进一步讨论设备请求、屏蔽和中断嵌套。

自测

1. 【2009】相对于微程序控制器，硬布线控制器的特点是（ ）。A. 指令执行速度慢，指令功能的修改和扩展容易；B. 指令执行速度慢，指令功能的修改和扩展难；C. 指令执行速度快，指令功能的修改和扩展容易；D. 指令执行速度快，指令功能的修改和扩展难。
2. 原创补充：沿用本章单总线图，能否在一拍同时执行 `R1→Y、R2→MAR`？能否同时执行 `R1→Y、R1→MAR`？

答案。 1. D，比较的是教材所述常见控制实现的控制开销与修改难度。2. 前者不能，两源争用总线；后者可以，同一来源同时送两个写入端，只要各目的具备独立写使能。

第6章　流水线与并行处理的基本模型

6.1 延迟和完成间隔是两个量

把一条指令分为 k 段，每段使用自己的部件或使用时段，让多条指令的不同阶段重叠执行，称为指令流水线。流水线没有让同一条指令的先后依赖消失：必须先取得地址，才能读取相应数据。它主要提高连续指令的吞吐率。

理想 k 段流水线，每段耗时一个时钟周期 τ，无停顿且一次每周期启动一条指令，完成 n 条指令需

$$T_{\text{pipe}} = (k + n - 1)\tau.$$

前 k 个周期使第一条指令通过全线，此后每周期再完成一条。不是每条都额外支付一次填充时间。吞吐率为 n/T_{pipe}，n足够大时趋近 $1/\tau$；单条延迟约为 $k\tau$。加入停顿 s 周期后，总时间变为 $(k + n - 1 + s)\tau$，前提是按本模型每个停顿周期使最终完成时间增加一周期。

若非流水方案每条确实依次完成这 k 段、每段也用同样的 τ，则非流水时间为 $nk\tau$，加速比为 $nk/(k + n - 1)$。若原方案时钟不同、可以不等长执行或另有资源复用，要重新计算基线，不能直接把流水级数当加速比。

例 6-1　最慢的一段决定时钟下限

【2009】 某计算机的指令流水线由四个功能段组成，指令流经各功能段的时间（忽略各功能段之间的缓存时间）分别为90 ns、80 ns、70 ns和60 ns，则该计算机的 CPU 时钟周期至少是（　）。

A. 90 ns　B. 80 ns　C. 70 ns　D. 60 ns

解析。 相邻阶段寄存器在同一节拍推进，必须留足最慢段90 ns，选 **A**。若实际阶段寄存器开销为 t_r，则通常需至少 $\max_i(t_i) + t_r$，题目已说忽略这项。

在本题时间下，理想完成10条指令需 $(4 + 10 - 1) \times 90 = 1170$ ns。若非流水方案每条直接耗时 $90 + 80 + 70 + 60 = 300$ ns，10条为3000 ns，加速比约2.56；若基线规定每段都占90 ns，又得到另一基线时间。比较时必须明确分母采用哪种机器。

6.2 阶段寄存器保存的不只是一份数据

五段教学流水线常写为 IF取指、ID译码/寄存器读、EX执行或地址计算、MEM访存、WB写回。算术指令也可能经过MEM这一拍但不访问数据存储器；存储指令通常不在WB写通用寄存器。阶段名描述某种通路设计，不是每条指令都在每段做同一种事。

阶段之间的寄存器保存下一段所需的操作数、立即数、目的寄存器编号、指令地址及控制信息。若只传数据不传目的编号，结果就可能写到错误寄存器；若指令阻塞时仍让其写使能继续流动，也可能重复写入或错误访存。

时钟推进状态，控制信号决定状态写入是否允许及组合部件选择什么功能。阶段寄存器常需写使能、保持和清空控制，因此“控制仅作用于组合部件、时钟仅作用于寄存器”的割裂描述不能当作普遍规则。气泡是在某阶段放入不产生有效状态改变的操作，冻结是让原状态保留，两者效果不同。

6.3 冒险先按冲突对象分类

结构冒险来自同拍争用不足的硬件资源。例如取指和数据读取同时需要单端口统一存储器；可通过停顿、增加端口或分离指令与数据存储来处理。寄存器组同拍读写是否冲突，取决于端口数及前后半拍的时序约定。

数据冒险来自指令间数据依赖与执行时序的矛盾。写后读 RAW：后指令读前指令产生的新值；读后写 WAR：后指令过早写破坏前指令尚未读取的旧值；写后写 WAW：两次写的完成顺序颠倒，使最终值错误。在固定五段、顺序发射、ID读寄存器且WB顺序写回的简单流水线中，通常需要处理RAW，而WAR、WAW被既定次序排除。变为乱序执行或不同延迟写回后，这个结论不再普遍成立。

控制冒险来自后继指令地址未确定，常见于条件分支、跳转、异常和中断处理。无条件转移仍需在某个时刻获得目标地址，因而也可能造成前端控制冒险。不能因为“不判断条件”便断言“不会停顿”。

转发能省去等待写回，但不能送来尚未产生的数据

转发把已经形成的结果从阶段寄存器等位置直接送到后续指令使用点，不必等写回寄存器组。例如ALU结果在EX结束时产生，后继指令下一拍进入EX，可以从EX/MEM处取得它。

load的数据通常到MEM结束才产生。紧随其后的指令若下一拍EX就需要该值，即使有转发也来不及，必须插入一个等待周期。转发路径是否通往存储数据端、分支比较端，也要看图，不能看见“支持转发”就推断所有相关都已解决。

例 6-2　装入后立即使用需要一个气泡

〖5.6-013〗 下列指令序列中，指令I1和I3、I2和I3之间发生数据相关。假定采用“取指、译码/取数、执行、访存、写回”五段流水线方式，那么在采用转发技术时，需要在指令I3之前加入（ ）条空操作指令才能使这段程序不发生数据冒险。

```
I1: add  r1, r0, 1    // R[r1] <- R[r0] + 1
I2: load r3, 12(r2)   // R[r3] <- M[R[r2] + 12]
I3: add  r5, r3, r1   // R[r5] <- R[r3] + R[r1]
```

A. 3　B. 2　C. 0　D. 1

解析。 I1在第3拍EX末形成r1结果，到I3需要时已经可用；I2到第5拍MEM末才有r3数据，而无停顿的I3本应在第5拍EX使用它，时间相撞。把I3的EX推迟到第6拍即可，因此选 **D**。

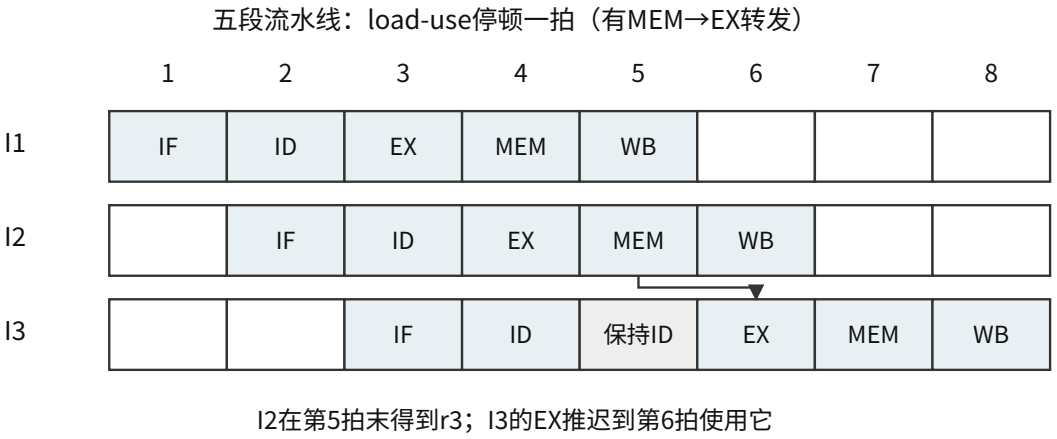


图 6.1: load到MEM末才有数据；空泡把使用时刻推迟到下一拍

指令	1	2	3	4	5	6	7	8
I1	IF	ID	EX	MEM	WB			
I2		IF	ID	EX	MEM	WB		
I3			IF	ID	保持ID	EX	MEM	WB

采用寄存器组同拍先写后读的时序，I1第5拍WB写回的r1可在该拍被保持在ID的I3读到；若实现不同，须另有WB到ID的旁路。第5拍EX放入气泡，I3在ID保持，下一拍接到装入结果。这里把r3的使用点设为EX，使用题目所指的常见五段转发模型；若某图要求在ID比较，所需等待和转发路径还可能不同。

例 6-3　同一段序列里同时有数据与控制等待

【2023】 在采用“取指、译码/取数、执行、访存、写回”5段流水线的 RISC 处理器中，执行如下指令序列，其中s0、s1、s2、s3和t2表示寄存器编号。

```
I1: add  s2, s1, s0  // R[s2] <- R[s1] + R[s0]
I2: load s3, 0(s2)   // R[s3] <- M[R[s2] + 0]
I3: beq  t2, s3, L1  // if R[t2] = R[s3] jump to L1
I4: addi t2, t2, 20  // R[t2] <- R[t2] + 20
I5: L1: ...
```

若采用转发（旁路）技术处理数据冒险，采用硬件阻塞方式处理控制冒险，则在指令I1～I4的执行过程中，发生流水线阻塞的指令有（　）。

A. 仅 I3　B. 仅 I2、I4　C. 仅 I3、I4　D. I2、I3、I4

解析。 I1的ALU结果可以及时转发给I2计算地址，所以I2不因这项RAW等待。I2是load，I3马上使用s3，仍有load-use等待。I3的分支结果未确定时，硬件阻塞后继I4，形成控制等待。因此为I3、I4，选 **C**。一条序列不能只找第一组相关就结束；每个使用值的位置和后继PC都要检查。

三种处理办法各改变什么

硬件阻塞保留相关指令及其前方必要状态，在前级暂停、后级放气泡，让生产者先前进。编译调度把不依赖该结果、且移动后不改变程序语义的指令填进等待间隔；无法填满才用NOP。不能把有副作用或可能越界访存的指令随意移过分支。

分支预测先选择一条路径继续取指，正确时减少等待，错误时清除错误路径上尚不能提交的结果并从正确位置重新取指。若每条指令发生预测错误的概率为p、每次平均损失d周期，且其他开销已包含在基本CPI中，可用 $\mathrm{CPI} = \mathrm{CPI}_0 + pd$；不能把“分支比例”直接当“所有指令的预测失败比例”。

旁路主要解决值的及时可用，不直接决定分支目标地址；某些设计把数据转发给分支比较器，缩短因数据相关而产生的分支等待，但不等于所有控制冒险都由旁路消除。题目需按具体控制路径判断。

6.4 超标量与动态流水线允许哪些重叠

超标量CPU每周期可发射多条指令，需要相应的译码、调度、执行和写回资源。是否真能每周期发满，取决于数据依赖、分支、功能部件和访存带宽。最大发射宽度w只给出理想吞吐上限，不能用w直接作为任意程序的加速比。

超流水把阶段划得更细，试图缩短时钟周期。阶段寄存器开销和冒险损失会限制收益。超长指令字 VLIW 把若干可并行操作交给编译器打包，硬件和指令格式仍需支持相应并行执行，并非“只改编译器，硬件没有要求”。

动态调度可让后面的就绪指令先执行，减少因前面一条长延迟指令而造成的闲置。寄存器重命名为不同逻辑写入分配不同物理位置，可去除WAR、WAW这类假相关，但不能消除真实RAW：消费者必须等对应生产者的值。按序提交进一步使软件看到的状态符合程序顺序，并帮助实现精确异常。

例如前指令还要读取旧r1，后指令将写新r1时，为新值分配另一物理寄存器，可避免覆盖旧值；若后指令确实需要前指令算出的r1，则改名字也不能凭空产生结果。区分“名字相同”和“值确有依赖”比背三组字母更有用。

6.5 一条指令处理多个数据，还是多个指令流

Flynn分类按指令流和数据流区分：SISD为单指令流单数据流；SIMD为单指令流多数据流；MISD为多指令流单数据流；MIMD为多指令流多数据流。分类描述执行组织，不是按机器装了几个屏幕、几块内存来判断。

向量处理器用一条向量指令对一组数据元素重复执行同类操作，可采用向量流水和多个通道，属于常见SIMD组织。它有启动代价，长向量能更好摊薄；向量长度不等于同时存在同样多套完整处理器。SIMD也不能自然处理每个元素都要求完全不同控制流程的任务，分支发散可能降低有效利用率。

MIMD允许不同处理单元执行不同指令流。共享物理地址空间的多处理器属于MIMD的一种，分布式存储系统也可属于MIMD。SMP中的“对称”是各处理器在系统功能等方面地位对等，不表示每个时刻执行同一条指令。

6.6 硬件线程、多核与共享内存

硬件多线程让一个核保存多套线程体系结构状态，以便在一个线程等待时运行另一线程。细粒度多线程可按周期交替线程；粗粒度多线程常在较长延迟事件时切换；同时多线程 SMT 允许同周期从不同线程发射操作，利用已有执行资源。它们都不要求芯片必须有多个核。

多核是在一个处理器芯片内集成多个执行核心。各核可以独立推进指令流，通常还共享某些Cache、互连或内存控制资源。增加核数不保证单线程加速，也不保证功耗必然高于任意单核设计；工艺、频率、负载和资源共享均影响结果。

共享内存多处理器让各处理器使用同一物理地址空间，但各核寄存器、部分Cache仍可私有。共享地址只保证可以指向同一对象，不保证多个读改写操作自动原子。并发程序还需要同步，Cache一致性与存储顺序也要分别满足相应规则。操作系统的进程同步讲义会沿用这一边界。

例 6-4　硬件多线程不等于多核

【2022】 下列关于并行处理技术的叙述中，不正确的是（　）。

A. 多核处理器属于 MIMD 结构
B. 向量处理器属于 SIMD 结构
C. 硬件多线程技术只可用于多核处理器
D. SMP中所有处理器共享单一物理地址空间

解析。 单核也能保存多套线程状态并共享执行部件，所以 C 错，选 **C**。A、B从指令流和数据流分类，D说的是共享物理地址空间；都没有断言所有资源完全相同或所有访问自动同步。

自测

1. 原创补充：理想5段流水线周期2 ns，完成20条指令，中间有3个导致整体延长的停顿周期，求总时间与实际吞吐率。
2. 原创补充：若一条指令的结果要到MEM末才形成，而消费者在下一拍EX开始使用，有MEM→EX转发，是否仍需等到生产者WB结束？若消费者EX与生产者MEM是同一拍呢？

答案。 1. $(5+20-1+3)\times 2=54$ ns，吞吐率 $20/54\approx 0.370$ 条/ns。2. 前者不需要，可在下一拍使用MEM末的结果；后者来不及，需要推迟消费者。关键是结果形成时刻与使用时刻，而不是“二者有相关”这句判断本身。

第7章　总线：一次事务怎样占用时间

7.1 位宽、频率、传送率分别给出什么

总线是部件之间传送信息的公共通路。按信息用途可区分地址、数据和控制：地址说明访问哪个单元或端口，数据线承载被交换的值，控制线说明操作类型、有效时刻及应答等。命令字虽然在语义上“控制设备”，CPU写命令字时仍可能在**数据线**上传送；不能只按信息的中文名称给它分配导线。

数据线上可以传指令、操作数、状态字、命令字和中断类型号。它们如何解释取决于传送双方和操作类型。MAR保存待访问地址，MDR暂存交换的值；主存并不是通过“某个数据看起来像地址”来判断总线作用，而是由相应线路与控制时序确定。

总线位宽通常指并行数据线根数。串行传送逐位使用通道，并行传送同一时刻通过多条线传若干位；多个串行通道并用不能因此直接称为单条传统并行总线。系统可用桥接部件连接不同速度和协议的通路，靠近CPU的部件通常要求更高带宽，不能由“有多条总线”推出所有总线共用同一时钟。

若有效数据宽度为 W 位，每秒实际发生 R 次数据传送，理想单方向峰值带宽为 $R \times W/8$ B/s。R与时钟频率不一定相同：每周期一次为R=f，每周期两次为R=2f；若已给MT/s，则已经是每秒传送次数，不能再乘“每周期次数”。

总线周期是一轮规定总线操作所占的时间，可能有多个时钟周期。带宽为每次传送的有效数据量除以这次所用时间；控制、地址、等待、校验和空闲开销会使有效数据率低于只算数据节拍的峰值。

例 7-1　一个总线周期占两个时钟周期

【2009】 假设某系统总线在一个总线周期中并行传输4 B信息，一个总线周期占用2个时钟周期，总线时钟频率为10 MHz，则总线带宽是（　）。

A. 10 MB/s　B. 20 MB/s　C. 40 MB/s　D. 80 MB/s

解析。 时钟周期100 ns，一次总线传送需200 ns，传4 B，因此带宽 $4/(200 \times 10^{-9}) = 20 \times 10^{6}$ B/s，选 **B**。直接用4 B×10 MHz忽略了每次传送占两拍。

例 7-2　已经给出 MT/s 就不再乘4

【2025】 某处理器总线采用同步、并行传输方式，每个总线时钟周期传送4次数据（quadpumped技术）。若该总线的工作频率为1333 MHz（实际单位是MT/s，表示每秒传送1333 M次），总线宽度为64位，则总线带宽约为（　）。

A. 10.66 GB/s　B. 42.66 GB/s　C. 85.31 GB/s　D. 341.25 GB/s

解析。括号给出了1333这个数的实际意义：它已经是数据传送率。每次64位=8 B，故 $1333\times10^{6}\times8\approx10.66$ GB/s，选 **A**。若1333真的表示时钟MHz，才会再乘4。本题必须服从括号的单位限定，不能同时把同一数当两种量。

多通道带宽只有在各通道能够并行传送且工作分配允许时才相加。全双工总线要区分单方向带宽和两个方向合计带宽；校验位若不属于有效载荷，不应加入有效数据量的分子。带宽题第一步宜写出“每次有效几字节、每秒几次”，再统一单位。

7.2 一次总线事务从地址到应答

总线主设备发起事务，从设备按地址被选中并完成操作。CPU常是主设备，DMA控制器也可在取得使用权后成为主设备。主从指本次事务中的角色，不等于某个设备永久只能发送或只能接收。

一次读事务可以分为：主设备发地址和读命令；从设备译码并准备数据；从设备在数据线上给出有效数据；主设备采样，双方结束本轮操作。写事务则由主设备给出要写的数据。地址、数据若复用同一组线路，就需不同时间片分别传送，不能同时算作两份独立并行位宽。

同步定时：固定采样时刻，必要时插等待

同步总线用共同的时钟约定信号有效和采样时刻。最短周期需容纳信号传播、译码、设备准备及建立时间等路径。若从设备来不及，可按协议插入等待状态；“同步”不等于所有事务长度永远相同，也不表示每个设备可随意提供互不协调的时钟。

突发传送只先给一个首地址，再连续交换多个相邻数据，摊薄地址和启动开销。非突发则可能为每个数据重复地址及准备过程。因此“读一块多长时间”应先数数据拍数，再判断地址、等待代价付几遍。

例 7-3　不支持突发，就要反复准备每个数据

【2023】某存储器总线宽度为64位，总线时钟频率为1 GHz，在总线上传输一个数据或地址需要一个时钟周期，不支持突发传送方式。若通过该总线连接CPU和主存，主存每次准备一个64位数据需要6 ns，主存块大小为32 B，则读取一个主存块所需的时间是（　）。

A. 8 ns　B. 11 ns　C. 26 ns　D. 32 ns

解析。一拍1 ns，每个64位数据为8 B，一块需要4个数据。每个数据独立付地址1 ns、准备6 ns、传数据1 ns，共8 ns，总计 $4\times8=32$ ns，选 **D**。11 ns对应只付一次地址和准备、再连传4次，是突发模型，题目已排除。

例 7-4　峰值带宽与整次事务的有效速率

【2024】某存储器总线的时钟频率为420 MHz，总线宽度为64位，每个时钟周期传送2次数据；其总线事务支持突发传送方式，最多传送8次数据，第1个时钟周期传送地址和读/写命令，从第4个至第7个时钟周期连续传送8次数据。该总线的总线带宽（最大数据传输率）为（　）。

A. 3.84 GB/s　B. 6.72 GB/s　C. 30.72 GB/s　D. 53.76 GB/s

解析。 问的是数据节拍的最大传送率，每周期2次、每次8 B，峰值 $420\times10^{6}\times2\times8=6.72$ GB/s，选 **B**。

若另问这次8次数据的事务有效速率，才把地址和等待计入分母：数据64 B、事务7周期，$64/(7/(420\times10^{6}))=3.84$ GB/s。A是另一口径的结果，不能用它回答本题已经说明的峰值带宽。第4至第7拍共4拍，每拍2次，正好8次，不是8拍。

异步定时：用握手确认进度

异步总线不用统一周期来强制双方同拍完成，而用请求和应答等信号交换进度。速度较慢的设备晚些应答，主设备相应等待。异步不是没有顺序约束，也不是随时改变信号而不告知对方。

全互锁的四阶段握手可以写为：主设备置请求；从设备准备好后置应答；主设备看到应答后撤请求；从设备看到请求撤销后撤应答。各阶段都等待对方作出相应反应，因而不依赖预设的固定延迟来猜测对方已结束。

异步全互锁：请求和应答的撤销也要相互确认

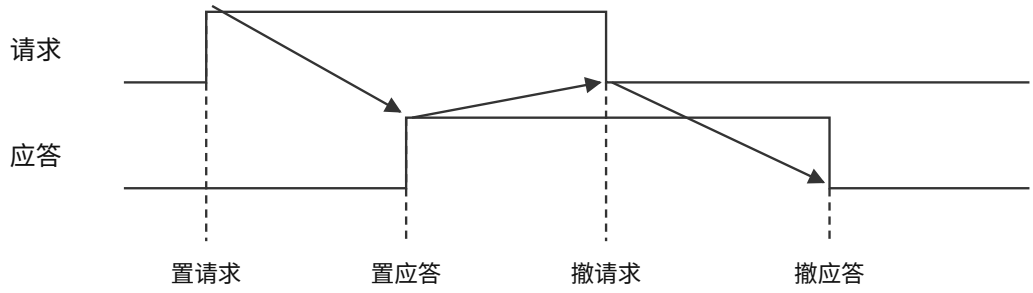


图 7.1: 全互锁握手的撤销顺序也由对方信号确认

非互锁方式中，主设备发出请求后按预定时间撤回，不等应答；从设备发出应答后也按时撤回，不等请求撤回。半互锁方式中，主设备等待应答出现才撤请求，而从设备仍可按时撤应答。全互锁方式中，从设备还必须等请求撤回才撤应答。给出时序图时，以图中的建立、撤销条件识别，不单凭信号名称猜测。全互锁通常多了等待环节，不能把最可靠直接推成最快。

半同步通信将时钟节拍与等待/应答结合：正常按时钟推进，慢设备可请求延长，握手状态在规定边沿采样。这里的“半同步”不等于一半数据串行、一半数据并行，两个分类维度不同。

如何读总线时序图

先标出地址何时稳定、读写命令何时有效、数据何时有效和何时被接收，最后数从事务开始到完成的时间。若图中低电平有效，应以标出的有效电平判断，不可把所有上升沿都当成开始。不同信号能否同拍出现由协议规定；“地址/数据复用”和“独立地址数据线”会改变能否重叠的操作。

串行异步字符传送还常带起始位、校验位和停止位。若每字符7个数据位、1个校验位、1个起始位和1个停止位，则每字符实际发送10位，480字符/s需要4800 bit/s，而有效字符数据只有3360 bit/s。不要把物理线路传送率与有效数据率混为一谈。

自测

1. 〖6.2-010〗某存储器总线采用同步通信，时钟频率50 MHz，突发传8个字，每字4 B。1周期接收地址、3周期等待、8周期传8个字。数据传输速率为（ ）。A. 114.3 MB/s　B. 126 MB/s　C. 133.3 MB/s　D. 144.3 MB/s。
2. 〖6.2-010〗变式（改变事务组织）：将第1题改为每个字都独立付1周期地址、3周期等待、1周期数据，读同样8字需要多少时间，有效速率多少？

答案。1. C。共12周期，每周期20 ns，32 B/240 ns≈133.3 MB/s。2. 共40周期=800 ns，32 B/800 ns=40 MB/s。两题块长相同，改变的是启动代价的重复次数。

第8章　I/O接口、程序中断与 DMA

8.1 端口是接口中可访问的位置

CPU通常通过I/O接口访问外部设备。接口把系统总线上的读写操作转换为设备所需的信号，并提供数据缓冲、状态记录、命令控制、地址识别及必要的中断或DMA连接。设备本体和接口不是同一对象：磁盘驱动器是设备，网络控制器、打印机适配器等承担接口功能。

CPU能访问的接口寄存器或相应位置称为I/O端口。数据端口交换数据，状态端口报告就绪、忙或错误，控制端口接收启动、复位等命令。读状态与写控制可能共用同一个端口地址，由读写方向区分；不能据地址相同就断言两个功能必须互相覆盖。

统一编址（存储器映射I/O）把端口放进主存地址空间，用访存指令访问；独立编址为I/O设单独地址空间，通常使用专门I/O指令。同一个数值地址在独立编址下可分别表示内存位置和端口，在统一编址下则要避免地址译码冲突。端口地址不是设备内部磁盘扇区地址。

例 8-1　命令字走哪组线

【2012】 下列选项中，在I/O总线的数据线上传输的信息包括（　）。

I. I/O接口中的命令字　II. I/O接口中的状态字　III. 中断类型号

A. 仅 I、II　B. 仅 I、III　C. 仅 II、III　D. I、II、III

解析。 三者都是本次总线交换的编码值，可以由数据线承载，选 **D**。读写控制线表达“本轮读或写”等时序和操作性质，并不负责逐位承载所有名称里带“控制”的字。

接口与设备侧交换数据、控制和设备状态，接口向CPU发送中断请求。打印机一般不会向其接口“接收中断请求信号”来获知下一个字符；这里要辨清信号的端点。串并转换、缓冲和速度匹配也在接口或设备控制电路中完成，主机内部总线并行并不要求磁盘写入盘面的位也并行。

8.2 查询方式：等待和搬运都由 CPU 安排

程序查询方式先启动设备，再读状态端口，未就绪就继续检查；就绪后由CPU执行指令，在数据端口与寄存器或主存之间搬运，并更新地址与计数。数据没准备好时，CPU若一直轮询，等待时间也占用了执行机会。

```
设置设备命令、目标地址和剩余数量
while 剩余数量 > 0:
    while 状态端口表示未就绪:
        继续检查
    从数据端口读一个单位并存入目标地址
    目标地址 += 单位大小
    剩余数量 -= 1
```

定时查询则在规定时刻检查，其余时间可以执行其他工作。是否会丢数据取决于设备速率、接口缓冲容量和最长查询间隔，不能把一种忙等程序的行为推广成“查询方式下CPU永远不能运行其他程序”。

例 8-2　定时查询占多少 CPU 时间

【2011】 某计算机处理器主频为50 MHz，采用定时查询方式控制设备A的I/O，查询程序运行一次所用的时钟周期数至少为500。在设备A工作期间，为保证数据不丢失，每秒需对其查询至少200次，则CPU用于设备A的I/O的时间占整个CPU时间的百分比至少是（　）。

A. 0.02%　B. 0.05%　C. 0.20%　D. 0.50%

解析。 每秒至少执行 $500 \times 200 = 100000$ 个查询周期，CPU每秒有 50×10^6 个周期，比例为0.002，即0.20%，选 **C**。200次/s先决定查询次数，不是设备每秒搬运200 B；题目也未要求把每次查询的500周期再当作500条指令。

若另给每个数据的搬运周期数，还要判断它已包含在查询程序开销中，还是必须另加。计算CPU占用率时，用CPU实际花掉的时间作分子，设备在外部独自准备数据的时间不直接算作CPU执行时间。

8.3 中断方式：先请求，再响应，再运行服务程序

中断I/O允许CPU启动设备后继续做其他工作，设备或接口就绪后提出中断请求。CPU在允许响应的边界检查未屏蔽请求，完成硬件响应，再执行中断服务程序，由程序读取或写入数据端口。等待不再要求CPU持续轮询，但每次软件搬运数据仍要CPU执行指令。

请求需要保存在接口或中断控制器的触发器中，因为外设产生事件时CPU未必能立即响应。中断请求的产生、被允许响应、被调度执行以及处理完成是不同时间点。CPU可能正在执行指令，处于关中断状态，或已有更高优先级请求需要先处理。

硬件保存断点，与软件保护现场分开

典型硬件响应包括暂时禁止相应中断、保存返回位置及规定的状态、确定中断服务入口。中断向量是用于定位处理程序的信息，中断向量地址是保存向量的位置，处理程序入口地址是最终执行代码的位置。三者在某种实现中存在固定联系，但不能始终当成同一数值。

服务程序进入后保存其将修改且须恢复的通用寄存器，处理事件，再恢复并返回。单重中断处理期间不允许同类可屏蔽中断嵌套；多重中断则在保护必要现场、设置屏蔽后重新允许某些请求打断当前服务程序。入口保护未完成就开放嵌套，可能覆盖尚未保存的返回信息。

在教材采用的一种单重中断序列中，软件部分是“保护现场→事件处理→恢复现场→开中断→中断返回”，保存断点和初始关中断已经由硬件响应完成。实际ISA可能由中断返回指令原子恢复状态和允许位；不能把教材序列中的“开中断”和返回之间的可重入窗口当作所有机器的共同实现。

屏蔽改变允许谁打断谁

中断响应优先级通常由硬件仲裁关系决定，多个未屏蔽请求同时到来时据此选一个。处理优先级描述服务过程中允许哪些请求打断当前服务，可通过各服务程序设置的屏蔽字形成。屏蔽会改变参与本次仲裁的集合，不会把仲裁电路本身的固定比较顺序改写。

例 8-3　响应顺序与完成顺序为什么可以不同

原创补充

有A、B、C三个请求源，硬件响应优先级A>B>C。屏蔽字按A、B、C排列，1表示屏蔽。要求处理优先级C>B>A，服务程序均在保存现场并设置屏蔽字后开中断。给出三者的屏蔽字，并追踪三请求同时待处理时的一次嵌套过程。

解析。 A处理中应屏蔽A自己，允许B、C，故为100；B处理中屏蔽A、B，允许C，故为110；C处理中三者都屏蔽，故为111。初始三者均允许响应时，硬件先选A，不能因希望C处理优先就把首次响应写成C。

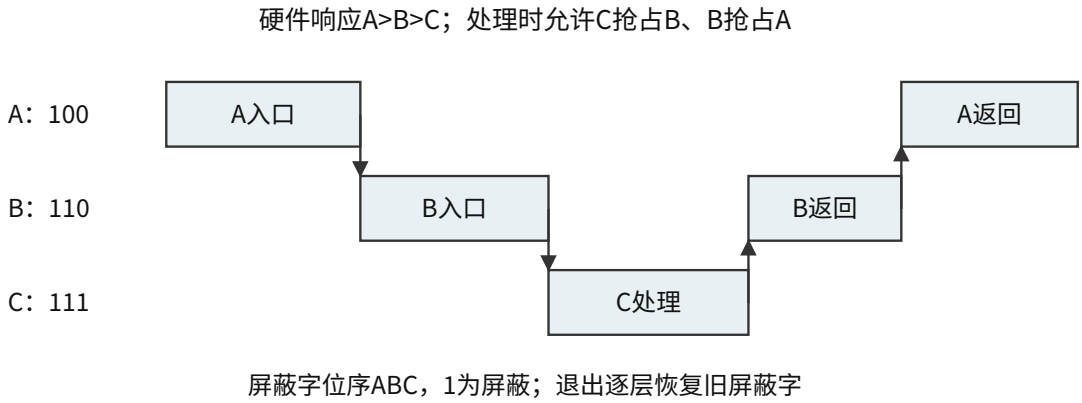


图 8.1: 屏蔽只改变可参与响应的集合；嵌套返回按栈次序进行

1. A保护现场、设100、开中断，B和C仍待处理，硬件在二者中选B。
2. B保护现场、设110、开中断，C可以响应，转入C。
3. C设111完成处理，恢复B的状态和屏蔽字，返回B。
4. B完成后恢复A，A最后完成。服务开始顺序A、B、C，完成顺序C、B、A。

题目要的是给定规则下的模型。各层必须保存并恢复旧屏蔽字，不能在C退出时直接恢复成最外层的全开放状态。屏蔽字的位序和0/1含义也必须从题干确定。

例 8-4　允许延迟不是额外的服务开销

【2014】 若某设备中断请求的响应和处理时间为100 ns，每400 ns发出一次中断请求，中断响应所允许的最长延迟时间为50 ns，则在该设备持续工作过程中，CPU用于该设备的I/O时间占整个CPU时间的百分比至少是（ ）。

A. 12.5%　B. 25%　C. 37.5%　D. 50%

解析。 每个请求实际占CPU100 ns，请求间隔400 ns，长期占用比例为 $100/400 = 25\%$，选 **B**。最长响应延迟50 ns约束请求产生后必须多快开始响应，不是额外需要执行50 ns的程序，不能加到100 ns上。

若题给设备数据率R B/s、每次中断交换q B、每次CPU开销t秒，在每次均交换q B且持续工作的模型中，请求率为R/q，CPU比例为 $(R/q)t$。若结果超过100%，说明该模型下CPU无法及时服务；不能继续当作可达到的利用率。

8.4 DMA：数据不经过 CPU 寄存器逐次搬运

DMA控制器在设备接口与主存之间组织直接传送。CPU仍需通过驱动程序设置方向、主存起始地址、传送数量和设备等参数，启动设备；传送过程中由控制器形成主存地址、请求总线、搬运数据并更新计数；结束或出错后再通知CPU处理。DMA减少逐个数据的指令开销，不表示CPU从头到尾完全不参与。

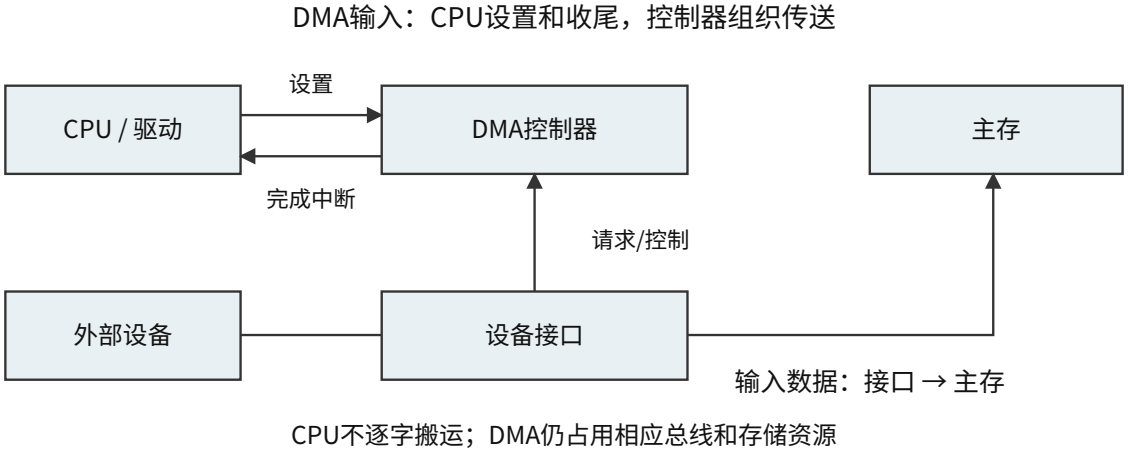


图 8.2: CPU设置和收尾，DMA传输阶段在接口与主存之间搬运

暂停CPU方式可在一块数据传送期间集中占用相关总线；周期挪用方式在设备准备好一个传送单位后申请一次或若干次总线使用；交替方式按约定把周期分给CPU和DMA。CPU能否同时访问某个存储体、Cache或另一条总线，要由具体资源结构决定。只要CPU本拍不需要被占用的资源，它仍可能继续内部运算。

周期挪用中，设备准备数据后向DMA控制器请求服务，DMA控制器再向系统申请总线。教材说“DMA请求”时可能指设备侧请求，也可能指总线申请，解题要看请求的发送者和接收者，不能只认四个字母。

例 8-5　周期挪用不等于整块期间封住主存

【2020】 若设备采用周期挪用DMA方式进行输入和输出，每次DMA传送的数据块大小为512字节，相应的I/O接口中有一个32位数据缓冲寄存器。对于数据输入过程，下列叙述中，错误的是（ ）。

A. 每准备好32位数据，DMA控制器就发出一次总线请求
B. 相对于CPU，DMA控制器的总线使用权的优先级更高
C. 在整个数据块的传送过程中，CPU不可以访问主存储器
D. 数据块传送结束时，会产生“DMA传送结束”中断请求

解析。 每次缓冲32位即4 B，512 B需要128次相应传送。周期挪用只在取得总线的时段占用资源，其余时段CPU仍可访问主存，不是整块传完前一直封锁，所以选 **C**。B描述本题采用的及时DMA服务模型，不表示任何系统的任意外部请求都永久压过CPU。

一次总线占用时间为b、每次搬q B时，DMA数据率R对应的总线占用比例约为 $(R/q)b$，前提是这些占用不重叠且没有额外启动代价。CPU实际损失还取决于它原本是否需要总线，因此不能把“DMA占总线10%”无条件改写成“程序变慢10%”。

例 8-6　DMA 的准备与完成仍需要软件

【2019】 下列关于DMA方式的叙述中，正确的是（　）。

I. DMA传送前由设备驱动程序设置传送参数
II. 数据传送前由DMA控制器请求总线使用权
III. 数据传送由DMA控制器直接控制总线完成
IV. DMA传送结束后的处理由中断服务程序完成

A. 仅 I、II　B. 仅 I、III、IV　C. 仅 II、III、IV　D. I、II、III、IV

解析。 I是CPU上的驱动程序进行准备，II、III是DMA硬件实际传输，IV是完成通知后的软件收尾，四项均正确，选 **D**。这条链把“CPU不逐字搬运”和“CPU完全不参与”清楚区分开。

方式	设备等待期间	数据搬运主体	主要约束
忙等查询	CPU反复读状态	CPU执行指令	等待和搬运都占执行机会
定时查询	两次查询间可做其他工作	CPU执行指令	查询间隔与缓冲容量
中断I/O	CPU可做其他工作	服务程序中的CPU指令	每次响应处理开销
DMA	CPU通常可继续其他工作	DMA硬件控制接口与主存	总线、存储带宽与传送组织

适用性取决于设备速率、传送粒度、缓冲和系统实现。字符型低速设备通常适合查询或中断，网络和块设备的大批量传送常用DMA；不是“中断方式适用于所有设备，DMA只能按某个固定速度门槛启用”。

自测

1. 【2024】下列关于中断I/O方式的叙述中，错误的是（　）。A. 中断屏蔽字用于确定中断响应的优先级；B. 保存断点和程序状态字在中断响应阶段完成；C. 保存通用寄存器和设置新中断屏蔽字由软件实现；D. 单重中断方式下中断处理时CPU处于关中断状态。
2. 【2024】DMA控制I/O方式下，设备的输入/输出由DMA控制器控制完成，此时DMA控制器控制的数据传输通路位于（　）。A. CPU和主存之间；B. CPU和DMA控制器之间；C. 设备接口和主存之间；D. 设备接口和DMA控制器之间。
3. 原创补充：设备数据率为1 MB/s，每次中断交换4 B，开销为2 μs，CPU占用多少？若改为每1024 B一块DMA，假设CPU每块仅需20 μs设置及收尾，CPU开销比例是多少？暂不计总线竞争。

答案。 1. A。按本章教材口径，屏蔽字规定允许的抢占关系和处理优先级，固定响应仲裁次序不能由它直接改写。2. C。3. 中断为 $(10^6/4)\times 2\times 10^{-6}=50\%$；DMA为 $(10^6/1024)\times 20\times 10^{-6}\approx 1.953\%$。后者只是CPU设置收尾开销，尚不包含DMA占用主存总线对程序造成的影响。

题目索引

第1章

例 1-1　硬件直接执行哪一种程序 【2015】 2
例 1-2　主频相同，怎样由指令组成求时间 【2022】 3
例 1-3　CPU 加快后，I/O 时间怎样处理 【2012】 3
自测 4

第2章

例 2-1　整数与小数分别换基数 〖2.1-001〗 5
例 2-2　无符号短整数扩展 【2012】 6
例 2-3　负的 short 转成 unsigned int 【2025】 6
例 2-4　减法器的两路输入不直接送负数符号 〖2.2-018〗 7
例 2-5　十六进制补码相减 【2018】 8
例 2-6　有符号减法为何仍会产生借位 【2023】 8
例 2-7　负小数怎样组成单精度机器数 【2022】 11
例 2-8　同为负浮点数时怎样比较 【2014】 11
例 2-9　哪些步骤可能造成指数越界 【2015】 12
自测 12

第3章

例 3-1　DRAM 的复用地址怎样计数 【2014】 14
例 3-2　已安装容量不是全部可编址空间 【2011】 14
例 3-3　同一模块不等于立即发生冲突 【2015】 15
例 3-4　ROM 与 RAM 分区要分别计算 【2009】 16
例 3-5　7200转每分不是7200转每秒 【2015】 16
例 3-6　读后写的数组访问怎样计缺失率 【2016】 17
例 3-7　8路组相联需要几个比较器 【2022】 18
例 3-8　Cache 总容量还包括哪些位 【2015】 19
例 3-9　页号的十六进制不能直接当表中十进制 【2022】 20
例 3-10　TLB 标记不包含页内偏移 【2024】 20
例 3-11　交换内外层循环，命中率一定降低吗 【2023】改编 21
自测 23

第4章

例 4-1 扩展操作码应逐层扣除哪些前缀 【2022】 24
例 4-2 相对转移用哪个 PC 【2009】 25
例 4-3 先确定结构布局，再看低字节 【2012】 26
例 4-4 RISC 设计能否支持流水线 【2025】 27
例 4-5 工具链顺序 【2022】 27
自测 29

第5章

例 5-1 哪些元件负责运算，哪些元件保存状态 【2023】 30
例 5-2 从单总线图确定控制信号与取指时序 【2022】 31
例 5-3 间接操作数经过哪些部件 【2019】 33
例 5-4 互斥类为什么还要一个空操作编码 【2012】 34
例 5-5 控制存储器地址字段怎样估位宽 【2014】 34
例 5-6 缺页后为什么重试当前指令 【2021】 35
自测 35

第6章

例 6-1 最慢的一段决定时钟下限 【2009】 36
例 6-2 装入后立即使用需要一个气泡 〖5.6-013〗 37
例 6-3 同一段序列里同时有数据与控制等待 【2023】 38
例 6-4 硬件多线程不等于多核 【2022】 40
自测 40

第7章

例 7-1 一个总线周期占两个时钟周期 【2009】 41
例 7-2 已经给出 MT/s 就不再乘4 【2025】 41
例 7-3 不支持突发，就要反复准备每个数据 【2023】 42
例 7-4 峰值带宽与整次事务的有效速率 【2024】 42
自测 44

第8章

例 8-1 命令字走哪组线 【2012】 45
例 8-2 定时查询占多少 CPU 时间 【2011】 46
例 8-3 响应顺序与完成顺序为什么可以不同 47
例 8-4 允许延迟不是额外的服务开销 【2014】 47
例 8-5 周期挪用不等于整块期间封住主存 【2020】 48
例 8-6 DMA 的准备与完成仍需要软件 【2019】 49
自测 49

方法索引

第1章

从程序看计算机的功能部件 1

存储程序怎样变成一次次指令执行 2

性能计算：先确定谁的时间在改变 3

第2章

位串与数值之间还差一个解释规则 5

定点编码：范围先于运算规则 5

截断、扩展与 C 类型转换 6

加法器怎样同时支持加与减 7

CF 与 OF 分别判断什么 7

乘除运算必须保留的中间量 8

IEEE 754：字段既规定精度，也规定特殊情况 10

浮点加减：对阶丢位以后还要判断舍入 11

第3章

为什么一个程序同时使用几层存储器 13

SRAM、DRAM 与 Flash 保存信息的方式 13

地址引脚不总等于地址位数 13

MAR 容量由地址空间决定 14

单体多字和多体交叉怎样提高带宽 14

主存芯片怎样连到 CPU 15

磁盘与 SSD 的一次访问花在哪些时间上 16

Cache 命中率怎样变成时间 17

地址拆分决定块能放在哪里 17

LRU 更新的是访问次序，不只是装入次序 18

写命中与写缺失是两个独立问题 19

虚拟存储器怎样让程序看到地址空间 19

页表与 TLB：地址偏移为何原样保留 19

段式与段页式地址为什么需要界限检查 21

跨页数组访问：页、Cache块与遍历次序分别计算 21

第4章

指令字段怎样决定可表示的操作和地址 24
从形式地址到有效地址 24
大端、小端和对齐解决不同问题 25
RISC 与 CISC：设计倾向不代替具体实现 26
编译、汇编、链接怎样确定程序中的地址 27
分支和循环怎样改变 PC 27
过程调用为什么要保存返回位置 28

第5章

寄存器的名字说明它暂存什么 30
指令周期、机器周期与时钟周期 31
一条指令怎样变为微操作 31
控制信号由组合逻辑还是微程序产生 33
异常、中断与返回位置 34

第6章

延迟和完成间隔是两个量 36
阶段寄存器保存的不只是一份数据 36
冒险先按冲突对象分类 37
超标量与动态流水线允许哪些重叠 39
一条指令处理多个数据，还是多个指令流 39
硬件线程、多核与共享内存 40

第7章

位宽、频率、传送率分别给出什么 41
一次总线事务从地址到应答 42
如何读总线时序图 43

第8章

端口是接口中可访问的位置 45
查询方式：等待和搬运都由 CPU 安排 45
中断方式：先请求，再响应，再运行服务程序 46
DMA：数据不经过 CPU 寄存器逐次搬运 48